

OPTIMIZACIÓN DE CARTERAS BASADA EN LA
PREDICCIÓN DE RETORNOS MEDIANTE
MODELOS DE SERIES TEMPORALES Y
APRENDIZAJE AUTOMÁTICO

DYNAMIC PORTFOLIO OPTIMIZATION BASED
ON RETURN FORECASTING USING TIME SERIES
AND MACHINE LEARNING MODELS



TRABAJO FIN DE MÁSTER
CURSO 2025-2026

AUTOR
ALEJANDRA LLORD MUÑOZ DE LA ESPADA

DIRECTOR
RAFAEL CABALLERO

MÁSTER EN INTELIGENCIA ARTIFICIAL
FACULTAD DE INFORMÁTICA
UNIVERSIDAD COMPLUTENSE DE MADRID

OPTIMIZACIÓN DE CARTERAS BASADA EN LA
PREDICCIÓN DE RETORNOS MEDIANTE
MODELOS DE SERIES TEMPORALES Y
APRENDIZAJE AUTOMÁTICO

DYNAMIC PORTFOLIO OPTIMIZATION BASED
ON RETURN FORECASTING USING TIME SERIES
AND MACHINE LEARNING MODELS

TRABAJO DE FIN DE MÁSTER EN INTELIGENCIA ARTIFICIAL
DEPARTAMENTO DE INFORMÁTICA

AUTOR
ALEJANDRA LLORD

DIRECTOR
RAFAEL CABALLERO

CONVOCATORIA: JUNIO 2026
CALIFICACIÓN:

MÁSTER EN INTELIGENCIA ARTIFICIAL
FACULTAD DE INFORMÁTICA
UNIVERSIDAD COMPLUTENSE DE MADRID

19 DE JUNIO DE 2026

DEDICATORIA

A Rafael,

porque un profesor como tú es difícil de encontrar

y tu pasión por enseñar, difícil de olvidar.

RESUMEN

Optimización de carteras basada en la predicción de retornos mediante modelos de series temporales y aprendizaje automático

Este trabajo estudia el uso de modelos predictivos para predecir los retornos futuros de distintos activos financieros. Además, se analiza si estas predicciones pueden aportar información útil para construir carteras con mejores resultados que las obtenidas mediante métodos tradicionales más sencillos, como la media histórica o el último valor observado.

El análisis se aplica concretamente a un conjunto de activos financieros conocidos como ETFs. A partir de sus datos históricos se calculan retornos diarios y semanales. Esta doble frecuencia permite comparar una visión más inmediata del mercado con otra más estable y menos afectada por el ruido diario. Sobre ambas frecuencias se aplican modelos de series temporales y modelos de aprendizaje automático. En el primer caso se aplican modelos ARIMA a cada activo de forma individual. En el segundo, se prueban modelos como *Ridge*, *Random Forest* y *Gradient Boosting*, incorporando información de varios activos, volumen y variables temporales.

Una vez comparados los modelos, las predicciones del modelo seleccionado se incorporan a un proceso de optimización de carteras basado en la teoría de Markowitz. Los resultados obtenidos se analizan junto con los de las estrategias tradicionales mencionadas anteriormente. De este modo, el trabajo evalúa si las predicciones tienen utilidad no solo desde el punto de vista estadístico, sino también desde el económico.

Palabras clave

Aprendizaje Automático, Predicción de Series Temporales, Fondos Cotizados, Optimización de Carteras, Modelo de Markowitz, ARIMA, Validación Temporal Progresiva, *backtesting*

ABSTRACT

Dynamic portfolio optimization based on return forecasting using time series and machine learning models

This thesis studies the use of predictive models to forecast the future returns of different financial assets. In addition, it analyses whether these predictions can provide useful information for building portfolios with better results than those obtained through simpler traditional methods, such as the historical mean or the last observed value.

The analysis is specifically applied to a set of financial assets known as ETFs. Based on their historical data, daily and weekly returns are calculated. This double frequency makes it possible to compare a more immediate view of the market with a more stable one, less affected by daily noise. Time series models and machine learning models are applied to both frequencies. In the first case, ARIMA models are applied to each asset individually. In the second, models such as Ridge, Random Forest and Gradient Boosting are tested, incorporating information from several assets, volume and temporal variables.

Once the models have been compared, the predictions from the selected model are incorporated into a portfolio optimization process based on Markowitz's theory. The results obtained are analysed together with those of the traditional strategies mentioned above. In this way, the work evaluates whether the predictions are useful not only from a statistical point of view, but also from an economic one.

Keywords

Machine Learning, Time Series Forecasting, ETFs, Portfolio Optimization, Markowitz Model, ARIMA, Walk-Forward, Backtesting

ÍNDICE DE CONTENIDOS

Dedicatoria.....	III
Resumen	IV
Abstract.....	VI
Índice de contenidos.....	VIII
Índice de figuras.....	XII
Índice de tablas	15
Capítulo 1 - INTRODUCCIÓN	18
1.1 Motivación.....	18
1.2 Objetivos.....	19
1.3 Plan de trabajo.....	20
1.4 Tecnologías utilizadas	21
Capítulo 2 - PRELIMINARES	24
2.1 Estado de la cuestión.....	24
2.2 ETFs.....	24
2.3 Modelos de series temporales	25
2.4 Modelos de aprendizaje automático.....	27
2.4.1 Regresión lineal	27
2.4.2 <i>Ridge</i>	28
2.4.3 <i>Random Forest</i>	29
2.4.4 <i>Gradient Boosting</i>	29
2.5 Optimización de carteras y modelo de Markowitz.....	29
2.6 Métricas de evaluación.....	30
Capítulo 3 - DATOS.....	34

3.1 Descripción de los datos	34
3.1.1 Mercado estadounidense.....	34
3.1.2 Factores y estilos	34
3.1.3 Sectores económicos.....	35
3.1.4 Mercados internacionales	36
3.1.5 Renta fija (Bonos)	37
3.1.6 Materias primas y activos reales	38
3.2 Variables principales.....	38
3.3 Análisis descriptivo inicial	39
3.3.1 Estadística descriptiva	40
3.3.2 Histogramas.....	40
3.3.3 <i>Boxplot</i>	41
3.3.4 Matriz de correlaciones.....	43
3.3.5 Periodo de estudio y división temporal	44
Capítulo 4 - MÉTODOS DE MODELIZACIÓN	46
4.1 Modelización mediante series temporales	46
4.1.1 Preprocesamiento de los datos.....	46
4.1.2 Modelo ARIMA	48
4.1.3 Resultados ARIMA	56
4.2 Modelización mediante aprendizaje automático.....	63
4.2.1 Preprocesamiento de los datos.....	64
4.2.2 Selección de Modelos.....	66
4.2.3 Resultados ML	70
Capítulo 5 - OPTIMIZACIÓN DE CARTERAS - MARKOWITZ	80
5.1 Estrategias comparadas.....	80

Estrategia 1: Markowitz con media histórica	80
Estrategia 2: Markowitz con último valor observado	81
Estrategia 3: Markowitz con predicciones ARIMA	81
5.2 Matriz de covarianzas	81
5.3 Formulación del problema de optimización.....	82
5.4 Funcionamiento del <i>backtest</i> semanal.....	83
5.5 Métricas de evaluación de estrategias	84
5.6 Registro de resultados en Google <i>Sheets</i>	85
5.7 Resultados Markowitz	86
Capítulo 6 - CONCLUSIONES Y TRABAJO FUTURO	90
6.1 Conclusiones generales	90
6.2 Trabajo futuro.....	91
Chapter 1 - INTRODUCTION	94
1.1 Motivation	94
1.2 Objectives	95
1.3 Work plan	96
1.4 Technologies used	97
Chapter 2 - CONCLUSIONS AND FUTURE WORK.....	100
2.1 General conclusions.....	100
2.2 Future work	101
Bibliografía	105
Apéndices.....	108

ÍNDICE DE FIGURAS

Figura 1. Cronograma del plan de trabajo seguido durante el desarrollo del proyecto, dividido en cuatro fases: preparación de datos, modelización, optimización de carteras y redacción final.....	21
Figura 2. Histogramas de retornos logarítmicos diarios de los ETFs: SPY, EWG e IAU	41
Figura 3. Diagrama de caja de los retornos logarítmicos diarios del ETF SPY. La línea discontinua marca el retorno cero y los puntos representan valores atípicos	41
Figura 4. Diagramas de caja de los retornos logarítmicos diarios de los ETFs analizados. La línea discontinua marca el retorno cero y los puntos fuera de los bigotes representan posibles valores atípicos.....	42
Figura 5. Matriz de correlación de los retornos logarítmicos diarios de los ETFs analizados. Los tonos rojos indican correlaciones positivas más altas, mientras que los tonos más claros indican correlaciones más bajas o cercanas a cero.....	43
Figura 6. Función de autocorrelación (ACF) de los retornos logarítmicos diarios del ETF SPY. La zona sombreada representa el intervalo de confianza y permite identificar qué retardos presentan autocorrelaciones relevantes.....	50
Figura 7. Función de autocorrelación parcial (PACF) de los retornos logarítmicos diarios del ETF SPY. La zona sombreada representa el intervalo de confianza y sirve como apoyo para analizar posibles relaciones directas con retardos anteriores.....	50
Figura 8. Valores de AIC de los modelos ARIMA candidatos para los retornos logarítmicos diarios del ETF SPY. Los valores más bajos indican un mejor equilibrio entre ajuste del modelo y complejidad	52
Figura 9. Valores de BIC de los modelos ARIMA candidatos para los retornos logarítmicos diarios del ETF SPY. Este criterio penaliza con mayor fuerza la complejidad, por lo que favorece modelos más sencillos	53
Figura 10. P-valores del test de Ljung-Box aplicado a los residuos de los modelos ARIMA candidatos para el ETF SPY.....	54
Figura 11. Comparación entre los retornos reales y las predicciones ARIMA para el ETF SPY en frecuencia diaria.....	58
Figura 12. Comparación entre los retornos reales y las predicciones ARIMA para el ETF DVY en frecuencia diaria.....	58

Figura 13. Comparación entre los retornos reales y las predicciones ARIMA multiplicadas por 10 para el ETF SPY en frecuencia diaria.....	58
Figura 14. Comparación entre los retornos reales y las predicciones ARIMA multiplicadas por 10 para el ETF DVY en frecuencia diaria.....	59
Figura 15. Valores de Kappa de Cohen por ETF para evaluar la capacidad del modelo ARIMA diario de predecir la dirección del retorno.....	59
Figura 16. Comparación entre los retornos reales y las predicciones ARIMA para el ETF SPY en frecuencia semanal	61
Figura 17. Comparación entre los retornos reales y las predicciones ARIMA para el ETF DVY en frecuencia semanal	62
Figura 18. Comparación entre los retornos reales y las predicciones ARIMA multiplicadas por 10 para el ETF SPY en frecuencia semanal	62
Figura 19. Comparación entre los retornos reales y las predicciones ARIMA multiplicadas por 10 para el ETF DVY en frecuencia semanal	62
Figura 20. Valores de Kappa de Cohen por ETF para evaluar la capacidad del modelo ARIMA semanal de predecir la dirección del retorno.....	63
Figura 21. Evolución del RMSE diario de Random Forest por ETF según el número de lags utilizado	72
Figura 22. Evolución del RMSE semanal de Ridge por ETF según el número de lags utilizado	74
Figura 23. Valores de Kappa de Cohen por ETF para el modelo ARIMA semanal, utilizados para evaluar si el modelo acierta la dirección del retorno mejor que el azar	76
Figura 24. Valores de Kappa de Cohen por ETF para el modelo Ridge semanal con 0 lags, ordenados de mayor a menor	77

ÍNDICE DE TABLAS

Tabla 1. ETFs seleccionados para representar el mercado estadounidense	34
Tabla 2. ETFs seleccionados según factores y estilos de inversión.....	35
Tabla 3. ETFs seleccionados para representar distintos sectores económicos	36
Tabla 4. ETFs seleccionados para representar mercados internacionales, incluyendo países desarrollados y emergentes.....	37
Tabla 5. ETFs de renta fija seleccionados.....	38
Tabla 6. ETFs seleccionados para representar materias primas y sector inmobiliario.....	38
Tabla 7. Estadísticas descriptivas de retornos logarítmicos diarios por ETF	40
Tabla 8. Interpretación conjunta de los tests ADF y KPSS para evaluar la estacionariedad	47
Tabla 9. Resultados de estacionariedad del ETF AGG en las variables: precio, logaritmo del precio, retorno simple y retorno logarítmico.	48
Tabla 10. Errores medios en test del modelo ARIMA diario y de los modelos de referencia baseline y zeros	56
Tabla 11. Resultados medios por grupo de activos del modelo ARIMA diario y comparación frente a los modelos baseline y zeros	57
Tabla 12. Errores medios en test del modelo ARIMA semanal y de los modelos de referencia baseline y zeros	60
Tabla 13. Resultados medios por grupo de activos del modelo ARIMA semanal y comparación frente a los modelos baseline y zeros	61
Tabla 14. Número de filas y columnas de los datasets diarios utilizados en los modelos de aprendizaje automático, según el número de lags incluido	65
Tabla 15. Número de filas y columnas de los datasets semanales utilizados en los modelos de aprendizaje automático, según el número de lags incluido	66
Tabla 16. RMSE medio en test de los modelos de aprendizaje automático en frecuencia diaria según el número de lags utilizado	71

Tabla 17. MAE medio en test de los modelos de aprendizaje automático en frecuencia diaria según el número de lags utilizado	71
Tabla 18. Resultados medios por grupo de activos del modelo Random Forest diario con 0 lags y comparación frente a los modelos baseline y zeros	72
Tabla 19. RMSE medio en test de los modelos de aprendizaje automático en frecuencia semanal según el número de lags utilizado	73
Tabla 20. MAE medio en test de los modelos de aprendizaje automático en frecuencia semanal según el número de lags utilizado	73
Tabla 21. Resultados medios por grupo de activos del modelo Ridge semanal con 0 lags y comparación frente a los modelos baseline y zeros	74
Tabla 22. Errores medios en test del modelo ganador de series temporales: ARIMA semanal y de los modelos de referencia baseline y zeros	75
Tabla 23. Errores medios en test del modelo ganador de ML: Ridge semanal con 0 lags y de los modelos de referencia baseline y zeros.....	76
Tabla 24. Resultados del backtest de las carteras de Markowitz para las cuatro configuraciones de cartera y las tres estrategias de estimación del retorno esperado, evaluadas mediante rentabilidad, volatilidad, Sharpe y máximo drawdown	86

Capítulo 1 - INTRODUCCIÓN

1.1 Motivación

Predecir el comportamiento de los mercados financieros es uno de los problemas más estudiados y, al mismo tiempo, más difíciles de resolver en finanzas. Los precios de los activos dependen de muchos factores, como la situación económica, las decisiones políticas, los resultados de las empresas, los eventos internacionales o las expectativas de los inversores. Muchos de estos elementos son difíciles de medir y no siempre pueden incorporarse directamente a un modelo. Esto reduce la capacidad de cualquier modelo para predecir con precisión la evolución futura de los activos.

Esta dificultad es más alta en el caso de los retornos financieros. Los retornos suelen tener valores muy cercanos a cero, cambian de comportamiento según el periodo y tienen poca relación con sus valores pasados. Por ello, que un activo haya subido o bajado en un día no suele aportar mucha información sobre lo que hará en el siguiente.

En este contexto, este trabajo analiza si es posible obtener información predictiva a partir de los retornos, tomando como caso de estudio un conjunto amplio de ETFs. Los fondos cotizados, conocidos habitualmente como ETFs por las siglas inglesas *exchange-traded funds*, pueden comprarse y venderse durante la sesión bursátil de forma semejante a las acciones, a diferencia de los fondos de inversión tradicionales. La elección de ETFs permite trabajar con activos diversificados y de distinto tipo, como renta variable, renta fija, sectores económicos, mercados internacionales y materias primas. Para estudiar el problema de predicción se comparan dos enfoques: modelos de series temporales y modelos de aprendizaje automático. Los primeros analizan cada ETF a partir de su propio histórico individual, mientras que los segundos pueden incorporar más variables, como información de otros activos, volumen o señales temporales.

El trabajo no se limita a medir el error de las predicciones. El objetivo final es comprobar si esas predicciones pueden ser útiles en una decisión de inversión, ya que una predicción con menor error no siempre implica una mejor cartera. Las predicciones se utilizan como entrada en un modelo de optimización de carteras basado en la teoría de Markowitz [1], donde actúan como estimaciones de rentabilidad esperada. De esta forma, el estudio permite analizar si el uso de predicciones puede mejorar la creación de una cartera en comparación con estrategias de construcción de carteras más sencillas.

1.2 Objetivos

El objetivo principal de este trabajo es estudiar, aplicar y comparar modelos de series temporales y aprendizaje automático para la predicción de retornos de ETFs, y analizar si sus predicciones pueden utilizarse posteriormente en la construcción de una cartera optimizada mediante el modelo de Markowitz.

Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

- Descargar, procesar y preparar datos históricos de un conjunto amplio de ETFs agrupados en distintas categorías de activos.
- Construir *datasets* diarios y semanales que permitan estudiar la predicción de retornos en dos frecuencias distintas: diarias y semanales.
- Aplicar modelos de series temporales ARIMA para predecir los retornos de cada ETF de forma individual.
- Aplicar modelos de aprendizaje automático añadiendo nuevas variables particulares por cada tipo de frecuencia.
- Evaluar los modelos mediante validación *walk-forward*, reentrenando en cada paso con la información disponible hasta ese momento.
- Analizar si la incorporación de información de periodos anteriores, mediante distintos números de retardos temporales (*lags*), mejora las predicciones de los modelos de aprendizaje automático.
- Comparar los modelos mediante métricas de error como RMSE (*Root Mean Square Error*) y MAE (*Mean Absolute Error*), frente a modelos de referencia sencillos, como el último valor observado o la predicción de retorno cero.
- Seleccionar el modelo predictivo con mejor rendimiento a partir de los resultados obtenidos.
- Incorporar las predicciones seleccionadas al modelo de Markowitz para construir y optimizar la cartera.
- Comparar la cartera basada en predicciones con dos estrategias de referencia, una basada en la media histórica y otra en el último retorno observado, para valorar si las predicciones permiten obtener mejores resultados de inversión.

1.3 Plan de trabajo

El desarrollo del trabajo se ha organizado en cuatro fases principales, siguiendo un orden progresivo desde la preparación de los datos hasta la evaluación final de las carteras. Esta estructura permite avanzar de forma ordenada y conectar cada parte del trabajo con la siguiente.

- La primera fase corresponde al **preprocesado y análisis inicial de los datos**. En esta etapa se descargan los datos históricos de los ETFs, se revisa su estructura y se construyen las variables necesarias para el estudio. También se calculan los retornos, se analiza la estacionariedad de las series y se realiza un primer análisis descriptivo mediante estadísticas y gráficos. El objetivo de esta fase es entender el comportamiento general de los activos antes de aplicar modelos de predicción.
- La segunda fase se centra en la **modelización de los retornos**. En esta parte se aplican modelos de series temporales y modelos de aprendizaje automático, tanto con datos diarios como con datos semanales. Para las series temporales se utilizan modelos ARIMA, mientras que en el caso del aprendizaje automático se prueban modelos como Ridge, Random Forest y Gradient Boosting. Además, se comparan los resultados frente a modelos base, como la predicción del último valor observado o la predicción de retorno cero. Esta fase permite identificar qué enfoque ofrece mejores resultados para el problema planteado.
- La tercera fase corresponde a la **optimización de carteras mediante el modelo de Markowitz**. Una vez seleccionadas las predicciones más adecuadas, estas se utilizan como rentabilidades esperadas dentro de una cartera de inversión. El objetivo de esta fase es comprobar si las predicciones no solo son útiles desde el punto de vista estadístico, sino también desde el punto de vista económico, es decir, si ayudan a construir una cartera con mejor comportamiento.
- Por último, la cuarta fase está dedicada a la **redacción de la memoria y cierre del trabajo**. En esta etapa se organizan los resultados obtenidos, se preparan las tablas y figuras necesarias, se redactan los distintos capítulos de la memoria y se revisa el documento final. También se incluyen las conclusiones del trabajo, las limitaciones encontradas y posibles líneas de mejora para futuros estudios. Podemos ver la cronología de las cuatro fases en la Figura 1:

Optimización de carteras basada en la predicción de retornos mediante modelos de Machine Learning y Series Temporales

Universidad Complutense de Madrid
Master en Inteligencia Artificial
Alejandra Llord

Inicio del proyecto: mi, 17/2/2026
Semana para mostrar: 1
5 de enero de 2026

TAREA	PROGRESO	INICIO	FIN	1	2	3	4	5	6	7	8	9	10	11
Tarea 1: Revisión conceptos y planificación del proyecto	100%	7-1-26	14-1-26											
Tarea 2: Descarga y entendimiento de datos históricos de ETFs con <i>yfinance</i>	100%	7-1-26	21-1-26											
Tarea 3: Preprocesado: cálculo de retornos y test de estacionariedad	100%	14-1-26	28-1-26											
Tarea 4: Construcción de los datasets diario y semanal	100%	14-1-26	31-1-26											
Tarea 5: Análisis descriptivo de retornos y correlaciones	100%	21-1-26	31-1-26											
Fase 2: Modelización series temporales y ML (8 semanas)														
Tarea 1: Modelos ARIMA diarios con walk-forward, baseline y zeros	100%	1-2-26	28-2-26											
Tarea 2: Modelos ARIMA semanales con walk-forward, baseline y zeros	100%	14-2-26	14-3-26											
Tarea 3: Modelos de Machine Learning: Ridge, Random Forest y GBR	100%	1-3-26	21-3-26											
Tarea 4: Exploración de lags [0-4] como variables predictoras	100%	7-3-26	21-3-26											
Tarea 5: Comparación de modelos y selección del mejor	100%	21-3-26	31-3-26											
Fase 3: Optimización de carteras Markowitz (5 semanas)														
Tarea 1: Diseño del backtest semanal con walk-forward	100%	1-4-26	14-4-26											
Tarea 2: Implementación de las estrategias de Markowitz	100%	7-4-26	21-4-26											
Tarea 3: Evaluación de resultados	100%	21-4-26	7-5-26											
Tarea 4: Análisis comparativo entre las tres estrategias	100%	14-4-26	10-5-26											
Tarea 5: Interpretación de los resultados del backtest	100%	28-4-26	10-5-26											
Fase 4: Redacción de la memoria y cierre (10 semanas)														
Tarea 1: Redacción de introducción, datos y estado del arte	100%	1-4-26	15-5-26											
Tarea 2: Redacción de metodología y resultados	100%	1-5-26	31-5-26											
Tarea 3: Preparación de figuras, tablas y apéndices	100%	15-5-26	5-6-26											
Tarea 4: Revisión final del documento	100%	25-5-26	7-6-26											
Tarea 5: Entrega del borrador (12 de junio de 2026)	100%	7-6-26	12-6-26											

Figura 1. Cronograma del plan de trabajo seguido durante el desarrollo del proyecto, dividido en cuatro fases: preparación de datos, modelización, optimización de carteras y redacción final.

1.4 Tecnologías utilizadas

Todo el proceso de análisis se ha realizado en *Python*, utilizando *Jupyter Notebooks* como entorno principal de desarrollo. A continuación, se describen las principales librerías y herramientas utilizadas en cada etapa.

- Para la obtención y manipulación de datos se utilizaron *pandas* y *numpy*. Los datos históricos de precios y volumen se descargaron mediante *yfinance*, que permite obtener información financiera desde *Yahoo Finance*.
- Para el análisis descriptivo y la visualización se usaron *matplotlib* y *seaborn*. Estas librerías permitieron generar histogramas, *boxplots*, matrices de correlación y gráficos de resultados.
- Los modelos de series temporales, en concreto los modelos ARIMA, se implementaron con *statsmodels*. Los modelos de aprendizaje automático se desarrollaron con *scikit-learn*.
- La optimización de carteras se realizó con *PyPortfolioOpt* [2], una librería de *Python* que permite aplicar el modelo de Markowitz. Para calcular el riesgo entre los ETFs se utilizó la matriz de

covarianzas con el método de Ledoit-Wolf. Después, el problema de optimización se resolvió con *cvxpy* y el solver *OSQP*.

- Para guardar los experimentos de aprendizaje automático y los resultados de la cartera se utilizó *Google Sheets*. Desde *Python* se conectó con la hoja de cálculo mediante la API de Google y la librería *gsread*. Así, se registraban automáticamente las métricas y predicciones de los modelos, los pesos de inversión y la evolución de cada cartera. Esto permitió revisar y comparar todos los resultados de forma más sencilla.
- Durante el desarrollo del trabajo se ha hecho un uso responsable de herramientas de inteligencia artificial generativa. Estas herramientas se han utilizado como apoyo en tareas de programación, depuración y revisión de la redacción. El código utilizado en el trabajo ha sido revisado, comprendido, adaptado e integrado por la autora.
- El código desarrollado se encuentra disponible en el repositorio de *GitHub* asociado al trabajo: <https://github.com/aleellord/TFM>
En él se incluyen los scripts y notebooks utilizados para la descarga y preparación de datos, el entrenamiento y evaluación de modelos, y la optimización de carteras.
- Todas las tablas, gráficos y figuras incluidos en esta memoria son de elaboración propia, generados a partir de los datos, experimentos y resultados obtenidos durante el desarrollo del trabajo.

Capítulo 2 - PRELIMINARES

2.1 Estado de la cuestión

La predicción de retornos financieros lleva décadas siendo uno de los temas más investigados en finanzas. Una de las teorías más conocidas es la hipótesis de los mercados eficientes, desarrollada por Eugene Fama [3]. Según esta teoría, en un mercado eficiente los precios de los activos reflejan la información disponible en cada momento. Esto implica que la información que aportan los precios y volúmenes pasados ya estaría incorporada en los precios actuales. Por tanto, sería difícil obtener predicciones consistentes utilizando únicamente datos históricos de mercado.

Sin embargo, algunos estudios han encontrado patrones en los retornos pasados que pueden estar relacionados con los retornos futuros. Jegadeesh y Titman [4] documentaron el efecto *momentum*, el cual dice que los activos que han tenido un buen comportamiento en los últimos meses tienden a seguir comportándose bien a corto plazo y viceversa. Por otro lado, DeBondt y Thaler [5] observaron que, a largo plazo, algunos activos con fuertes caídas previas tienden a recuperarse. Estos resultados no invalidan la hipótesis de los mercados eficientes [3], pero sí muestran que los datos históricos pueden tener ciertos patrones que merece la pena analizar.

Aun así, predecir retornos financieros es una tarea especialmente compleja. Cont [6] recopiló algunas de las propiedades estadísticas más habituales de los retornos financieros, como la presencia de movimientos extremos, la baja autocorrelación lineal y la existencia de periodos de alta volatilidad seguidos de otros más tranquilos. Estas características hacen que la señal sea débil y que gran parte de los movimientos observados estén dominados por ruido.

Por este motivo, este trabajo no parte de la idea de que el mercado pueda predecirse de forma exacta. El objetivo es más limitado: probar distintos modelos, medir qué capacidad predictiva tienen y analizar si sus predicciones pueden aportar valor dentro de una cartera de inversión.

2.2 ETFs

Un ETF (*Exchange Traded Fund*) es un producto financiero que agrupa muchas empresas o activos dentro de un solo fondo. En lugar de comprar acciones individuales que representan una sola empresa, como Apple o Banco Santander. Un ETF permite invertir en un conjunto amplio de empresas al mismo tiempo

(por ejemplo, el índice S&P 500 incluye las 500 principales empresas de Estados Unidos). Estos se compran y venden en bolsa de forma continua igual que una acción [7]

Desde su aparición en los años noventa, los ETFs han ganado una gran importancia dentro de los mercados financieros. Su crecimiento se debe a que permiten invertir de forma diversificada, sencilla y con costes reducidos. Por este motivo, se han convertido en instrumentos muy utilizados tanto por inversores individuales como por gestores de carteras [8].

La elección de ETFs en este trabajo se debe a que su comportamiento suele ser más estable que el de una acción individual. Una empresa concreta puede tener cambios muy bruscos por noticias o eventos propios. En cambio, un ETF incluye muchas empresas o activos, por lo que las subidas y bajadas de unas suelen compensarse con las de otras. Esto puede hacer que sus precios y retornos tengan cambios menos fuertes, lo que los hace adecuados para aplicar modelos de predicción.

2.3 Modelos de series temporales

Una serie temporal es un conjunto de observaciones ordenadas en el tiempo. En este trabajo, cada ETF puede entenderse como una serie temporal, ya que cada activo está formado por una secuencia de precios, volúmenes o retornos observados en distintos días. Además, en este trabajo se considera que las observaciones están ordenadas en intervalos regulares, ya sean diarios o semanales. Por ello, el tiempo queda representado por el orden de los datos y no es necesario incluirlo como una variable adicional. La característica principal de este tipo de datos es que el orden temporal importa: una observación no se interpreta de forma aislada, sino que se relaciona con las observaciones anteriores.

Los modelos de series temporales son métodos estadísticos que intentan describir y predecir la evolución de una variable a lo largo del tiempo. Su objetivo es identificar si existe algún patrón en el pasado que pueda ayudar a explicar el comportamiento futuro. En el contexto financiero, este tipo de modelos se ha utilizado para estudiar precios, retornos, volatilidad y otros indicadores de mercado [9].

Antes de modelizar una serie temporal, es necesario entender cómo se comporta. Algunas series tienen una tendencia, es decir, una subida o bajada mantenida durante el tiempo. Otras presentan estacionalidad, cuando ciertos patrones se repiten de forma regular, por ejemplo, cada mes o cada año. También hay que estudiar si la serie es estacionaria, ya que esta propiedad es importante para aplicar modelos clásicos de series temporales[10]. Una serie estacionaria mantiene un comportamiento estable

en el tiempo, con una media y una variabilidad similares, sin subidas y bajadas. Si la media o la variabilidad cambian con el tiempo, la serie es no estacionaria y requiere un tratamiento previo antes de aplicar modelos.

En finanzas, los precios de los activos suelen ser no estacionarios, porque pueden subir o bajar durante largos periodos. Por eso, en lugar de trabajar directamente con precios, se trabaja con retornos [11], que sí suelen ser estacionarios. Los retornos miden la variación entre el precio de cierre de un día ($P_{i,t}$) y el del día anterior ($P_{i,t-1}$):

$$R_{i,t} = \frac{P_{i,t} - P_{i,t-1}}{P_{i,t-1}}$$

Los retornos suelen moverse alrededor de cero y no presentan una tendencia marcada como los precios. Por ello, son más estables para aplicar modelos de series temporales.

Para modelar y predecir este tipo de datos, uno de los enfoques más utilizados es el modelo ARIMA, cuyas siglas corresponden a *AutoRegressive Integrated Moving Average* [9]. El modelo ARIMA tiene tres componentes:

- Componente autorregresiva (AR): el valor actual se explica como una combinación lineal de los valores pasados de la propia serie. El parámetro p indica cuántos valores pasados se incluyen.
- Componente de integración (I): sirve para transformar una serie que no es estacionaria. Para ello, se calculan diferencias entre un valor y el anterior. En este trabajo no se trabaja con precios directamente, sino con retornos, que ya miden el cambio entre periodos y son estacionarios. Por eso, no se aplica ninguna diferencia adicional y se fija el parámetro $d = 0$. Esta decisión simplifica el proceso de selección del modelo, al reducir el espacio de combinaciones posibles entre los parámetros.
- Componente de media móvil (MA): utiliza los errores de predicción pasados para corregir la predicción actual. El parámetro q indica cuántos errores pasados se incluyen.

Para seleccionar los parámetros p y q se sigue la metodología de Box, Jenkins y Reinsel [9], apoyándose en criterios como AIC[12] y BIC [13]. Estos criterios permiten comparar distintos modelos y seleccionar una opción que tenga buen ajuste sin aumentar innecesariamente la complejidad.

La principal ventaja de ARIMA es que es sencillo e interpretable. Su limitación es que analiza cada ETF por separado y solo detecta relaciones lineales. Por eso, en este trabajo se compara con modelos de aprendizaje automático, que pueden incorporar información de varios activos a la vez y capturar patrones más complejos.

2.4 Modelos de aprendizaje automático

El aprendizaje automático (*Machine Learning*) permite crear modelos que aprenden patrones a partir de datos. En este trabajo se utiliza aprendizaje supervisado, porque se quiere predecir una variable conocida en el histórico: el retorno futuro de cada ETF.

Estos modelos son útiles porque pueden trabajar con muchas variables al mismo tiempo, como retornos pasados, volumen, información de otros ETFs y variables temporales. Esto permite analizar si existen relaciones que no se observan al estudiar cada activo por separado.

Aun así, aplicar estos modelos a datos financieros presenta dificultades importantes. Los retornos suelen ser ruidosos, tienen una señal débil y cambian con el tiempo. Esto aumenta el riesgo de sobreajuste, es decir, que un modelo se adapte demasiado a los datos históricos y no funcione igual de bien con datos nuevos.

En este trabajo se utilizan varios modelos de aprendizaje automático supervisado: regresión lineal, *Ridge*, *Random Forest* y *Gradient Boosting*. Se han elegido estos porque permiten comparar modelos de distinta complejidad. La regresión lineal y *Ridge* representan enfoques más simples e interpretables, mientras que *Random Forest* y *Gradient Boosting* permiten estudiar relaciones más complejas y relaciones no lineales entre las variables. Se han seleccionado estos porque son los modelos más habituales en predicción financiera [14].

2.4.1 Regresión lineal

La regresión lineal es uno de los modelos más simples dentro del aprendizaje supervisado. Su objetivo es explicar una variable dependiente, en este caso el retorno futuro de un ETF, como una combinación lineal de varias variables explicativas. Estas variables pueden ser retornos pasados, cambios en el volumen, variables temporales u otras variables disponibles. Su fórmula es:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

Donde $\hat{y}$ representa la predicción del retorno futuro, $x_1, x_2, \dots, x_p$ son las variables explicativas utilizadas por el modelo y $\beta_0, \beta_1, \dots, \beta_p$ son los coeficientes estimados.

Su principal ventaja es la interpretabilidad. Cada coeficiente indica la relación entre una variable de entrada y el retorno que se quiere predecir. Sin embargo, esta simplicidad también es una limitación. La regresión lineal solo puede capturar relaciones lineales y puede tener problemas cuando hay muchas variables o cuando estas están muy correlacionadas entre sí. En este trabajo se incluye como modelo base para comprobar hasta qué punto un modelo lineal simple es suficiente para predecir retornos.

2.4.2 Ridge

Ridge es una extensión de la regresión lineal propuesta por Hoerl y Kennard [15]. La idea principal es mantener la estructura lineal del modelo, pero añadiendo una penalización sobre el tamaño de los coeficientes. Esta penalización, conocida como regularización del modelo, evita que algunos coeficientes tomen valores demasiado grandes y ayuda a reducir el sobreajuste.

La predicción de *Ridge* se escribe igual que en la regresión lineal:

$$\hat{y} = \hat{\beta}_0^{Ridge} + \hat{\beta}_1^{Ridge} x_1 + \hat{\beta}_2^{Ridge} x_2 + \dots + \hat{\beta}_p^{Ridge} x_p$$

La diferencia está en cómo se obtienen esos coeficientes. En *Ridge*, los valores de $\hat{\beta}^{Ridge}$ se obtienen minimizando una función formada por dos partes: el error de predicción y una penalización sobre el tamaño de los coeficientes:

$$Función\ a\ minimizar = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

El primer término mide el error de predicción del modelo. El segundo término penaliza los coeficientes grandes. El parámetro λ controla la fuerza de la penalización: cuanto mayor es, más se reducen los coeficientes.

Este modelo ayuda a corregir las limitaciones de la regresión lineal, se utiliza cuando se trabaja con muchos datos de entrada y con variables relacionadas entre sí. En el caso de los ETFs, esto es importante porque muchos activos se mueven de forma parecida y pueden estar altamente correlacionados.

2.4.3 Random Forest

Random Forest es un modelo propuesto por Breiman [16] y basado en árboles de decisión. Un árbol de decisión separa los datos mediante reglas sencillas, por ejemplo, comprobando si una variable supera cierto valor. Al hacer estas divisiones sucesivas, el modelo puede captar relaciones no lineales entre las variables, ya que no obliga a que la relación entre entrada y salida sea lineal.

En lugar de usar un solo árbol, *Random Forest* construye muchos árboles y combina sus resultados. Cada árbol se entrena con una parte distinta de los datos y con una selección de variables. Después, la predicción final se calcula como el promedio de las predicciones de todos los árboles. Esto hace que el modelo sea más estable que un árbol individual y reduce el riesgo de ajustarse demasiado a los datos de entrenamiento.

2.4.4 Gradient Boosting

Gradient Boosting también utiliza árboles de decisión, pero de una forma diferente. Mientras que *Random Forest* construye muchos árboles de forma paralela e independiente, *Gradient Boosting* los construye de manera secuencial. Cada nuevo árbol intenta corregir los errores generados por los árboles anteriores.

De esta manera, el modelo mejora poco a poco. Primero se construye un árbol sencillo. Después se observa dónde se ha equivocado más y se entrena un nuevo árbol para corregir esos errores.

Este enfoque fue propuesto por Friedman [17] y puede ser útil en predicción financiera porque es capaz de detectar patrones débiles y relaciones complejas entre variables. Su principal riesgo es el sobreajuste, es decir, que el modelo aprenda demasiado bien los datos de entrenamiento y luego no funcione con datos nuevos. Para evitarlo, es necesario ajustar parámetros como el número de árboles, su profundidad o la tasa de aprendizaje.

2.5 Optimización de carteras y modelo de Markowitz

La teoría moderna de carteras, formulada por Markowitz en 1952 [1], plantea que una cartera no debe analizarse solo por la rentabilidad esperada de cada activo, sino también por el riesgo de la cartera en conjunto. La idea principal es que combinar activos que no se mueven exactamente igual puede reducir el riesgo total. Este es el principio básico de la diversificación.

El modelo de Markowitz busca una combinación de activos que mantenga un equilibrio entre rentabilidad y riesgo. De forma simplificada, este equilibrio puede expresarse como:

$$\max_w (w^T \mu - \lambda w^T \Sigma w)$$

En esta expresión,

- w representa los pesos asignados a cada activo.
- μ es el vector de rentabilidades esperadas.
- Σ es la matriz de covarianzas entre los activos.
- El primer término, $w^T \mu$, representa la rentabilidad esperada de la cartera.
- El segundo término, $w^T \Sigma w$, representa el riesgo de la cartera, medido mediante la varianza.
- El parámetro λ indica la importancia que se da al riesgo, cuanto mayor es, más conservadora es la cartera.

Una de las partes más importantes del modelo es el vector de rentabilidades esperadas. Este vector representa la rentabilidad que se espera obtener de cada activo. Como esas rentabilidades futuras no se conocen, normalmente se estiman con métodos simples, como la media histórica de los retornos. En este trabajo se analiza si las predicciones obtenidas mediante modelos de series temporales y aprendizaje automático pueden utilizarse como una alternativa para estimar esas rentabilidades dentro del modelo de Markowitz.

2.6 Métricas de evaluación

Para evaluar la calidad de las predicciones se utilizan dos métricas de error habituales en problemas de regresión: RMSE y MAE. Ambas comparan el valor predicho por el modelo con el valor real observado.

El RMSE (*Root Mean Squared Error*) mide el error medio del modelo. Esta métrica da más peso a los errores grandes, porque eleva las diferencias al cuadrado antes de hacer la media. Su fórmula es:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

donde y_i es el valor real, $\hat{y}_i$ es la predicción del modelo y n es el número total de observaciones. Un valor más bajo de RMSE indica una mejor precisión.

El MAE (*Mean Absolute Error*) mide el error medio en valor absoluto. Es una métrica más directa de interpretar, porque indica cuánto se aleja, de media, la predicción del valor real. Su fórmula es:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Además, los resultados de cada modelo se compararán con dos modelos de referencia simples. El primero es el modelo *naive*, que predice que el retorno del siguiente periodo será igual al último retorno observado. El segundo es el modelo *zero*, que predice siempre un retorno igual a cero. Aunque es una regla muy simple, puede funcionar razonablemente bien ya que los retornos son pequeños y se mueven cerca de cero. Por eso, superar este modelo indica que la predicción aporta información adicional. Para estos dos modelos también se calculan RMSE y MAE, de forma que todos los métodos se comparan con las mismas métricas.

De forma complementaria, se utiliza la Kappa de Cohen como métrica para estudiar si el modelo acierta la dirección del movimiento. Para ello, los retornos se clasifican como positivos o negativos. Esta métrica compara los aciertos reales del modelo con los aciertos que podrían darse por azar. Por eso resulta útil como complemento a RMSE y MAE, ya que permite analizar no solo el tamaño del error, sino también si el modelo predice correctamente el signo del movimiento. La Kappa de Cohen se define como:

$$\kappa = \frac{p_o - p_e}{1 - p_e}$$

donde p_o representa la proporción de aciertos reales entre la dirección predicha y la dirección observada, y p_e representa la proporción de aciertos que podrían darse simplemente por azar.

Un valor de κ cercano a 1 indica que la dirección predicha coincide con la dirección real. Un valor cercano a 0 indica que el modelo no mejora una coincidencia aleatoria. Si el valor es negativo significa que el modelo coincide menos con el valor real que una elección aleatoria.

Capítulo 3 - DATOS

3.1 Descripción de los datos

Para este trabajo se ha seleccionado un conjunto de 63 ETFs con el objetivo de representar distintos tipos de activos y tener una muestra variada. Estos ETFs se agrupan en seis grandes categorías: renta variable estadounidense e internacional, estilos de inversión, sectores económicos, renta fija y materias primas. Esta clasificación permite trabajar con activos de diferente comportamiento y analizar si los modelos son capaces de predecir retornos en distintos sectores del mercado.

3.1.1 Mercado estadounidense

Esta categoría incluye ETFs que siguen algunos de los índices más importantes de Estados Unidos. Estos fondos permiten analizar el comportamiento general de la bolsa estadounidense, desde grandes empresas hasta empresas medianas y pequeñas.

ETF	Nombre comercial	Qué representa
SPY	SPDR S&P 500 ETF	Índice S&P 500
IVV	iShares Core S&P 500	
VOO	Vanguard S&P 500 ETF	
QQQ	Invesco QQQ Trust	Índice Nasdaq 100
VTI	Vanguard Total Stock Market	Mercado total de acciones de EEUU
ITOT	iShares Core Total US Market	
DIA	SPDR Dow Jones ETF	Índice Dow Jones Industrial Average
IWM	iShares Russell 2000	Empresas pequeñas de Estados Unidos
IJR	iShares Core S&P Small-Cap	Empresas pequeñas de Estados Unidos
MDY	SPDR S&P MidCap 400	Empresas medianas de Estados Unidos

Tabla 1. ETFs seleccionados para representar el mercado estadounidense

3.1.2 Factores y estilos

Son ETFs que seleccionan empresas según determinadas características, como crecimiento, valor, calidad o baja volatilidad.

ETF	Nombre comercial	Qué representa
VUG	Vanguard Growth ETF	Empresas con altas expectativas de crecimiento
IWF	iShares Russell 1000 Growth	
VTV	Vanguard Value ETF	Empresas de valor con altas expectativas de crecimiento
IWD	iShares Russell 1000 Value	
SCHD	Schwab US Dividend Equity	Empresas que pagan dividendos
VIG	Vanguard Dividend Appreciation	
DVY	iShares Select Dividend	
MTUM	iShares MSCI USA Momentum	Activos con tendencia positiva reciente
QUAL	iShares MSCI USA Quality	Empresas con buenos indicadores financieros
USMV	iShares MSCI Minimum Volatility	Empresas con menor volatilidad, más estables
VLUE	iShares MSCI USA Value Factor	Empresas de valor

Tabla 2. ETFs seleccionados según factores y estilos de inversión

3.1.3 Sectores económicos

Esta categoría incluye ETFs que invierten en sectores concretos de la economía, como tecnología, finanzas, salud o energía. En lugar de seguir todo el mercado, se centran en una parte específica de la actividad económica.

ETF	Nombre comercial	Qué representa
XLK	Technology Select Sector SPDR	Tecnología
XLF	Financial Select Sector SPDR	Finanzas
XLV	Health Care Select Sector SPDR	Salud
XLY	Consumer Discretionary SPDR	Consumo cíclico

XLP	Consumer Staples SPDR	Consumo básico
XLE	Energy Select Sector SPDR	Energía
XLI	Industrial Select Sector SPDR	Industria
XLU	Utilities Select Sector SPDR	Servicios públicos
XLB	Materials Select Sector SPDR	Materiales
XLRE	Real Estate Select Sector SPDR	Sector inmobiliario

Tabla 3. ETFs seleccionados para representar distintos sectores económicos

3.1.4 Mercados internacionales

Los ETFs internacionales permiten invertir en mercados fuera de Estados Unidos. Esta categoría incluye tanto países desarrollados como países emergentes.

ETF	Nombre comercial	Qué representa
VEA	Vanguard FTSE Developed Markets	Mercados desarrollados fuera de Estados Unidos
IEFA	iShares Core MSCI EAFE	Europa, Asia y otros mercados desarrollados
VWO	Vanguard Emerging Markets	Mercados Emergentes
IEMG	iShares Core Emerging Markets	
EEM	iShares MSCI Emerging Markets	
EFA	iShares MSCI EAFE	Mercados desarrollados fuera de Estados Unidos
EWJ	iShares MSCI Japan	Japón
EWG	iShares MSCI Germany	Alemania
EWU	iShares MSCI UK	Reino Unido
EWQ	iShares MSCI France	Francia
INDA	iShares MSCI India	India

EWZ	iShares MSCI Brazil	Brasil
FXI	iShares China Large-Cap	Grandes empresas de China
MCHI	iShares MSCI China	Mercado China
EWT	iShares MSCI Taiwan	Taiwán
EWY	iShares MSCI South Korea	Corea del Sur

Tabla 4. ETFs seleccionados para representar mercados internacionales, incluyendo países desarrollados y emergentes

3.1.5 Renta fija (Bonos)

Esta categoría incluye ETFs de bonos públicos y corporativos. Estos activos suelen tener un comportamiento diferente al de la renta variable y pueden aportar estabilidad a una cartera. Dentro del grupo se incluyen bonos de corto, medio y largo plazo, así como bonos corporativos con distinto nivel de riesgo.

ETF	Nombre comercial	Qué representa
BND	Vanguard Total Bond Market	Mercado amplio de bonos de Estados Unidos
AGG	iShares Core US Aggregate Bond	Bonos agregados de Estados Unidos
IEF	iShares 7-10 Year Treasury	Bonos del Tesoro a medio plazo
TLT	iShares 20+ Year Treasury	Bonos del Tesoro a largo plazo
SHY	iShares 1-3 Year Treasury	Bonos del Tesoro a corto plazo
LQD	iShares Investment Grade Corporate	Bonos corporativos de buena calidad
HYG	iShares High Yield Corporate	Bonos corporativos de mayor riesgo
JNK	SPDR Bloomberg High Yield Bond	Bonos de alto rendimiento
TIP	iShares TIPS Bond	Bonos ligados a inflación
BIL	SPDR 1-3 Month T-Bill	Letras del Tesoro a muy corto plazo

Tabla 5. ETFs de renta fija seleccionados

3.1.6 Materias primas y activos reales

Esta categoría incluye ETFs de activos físicos como oro, plata o petróleo, a índices de materias primas o del sector inmobiliario. Estos activos suelen comportarse de forma diferente a las acciones y los bonos, especialmente en momentos de inflación o incertidumbre económica.

ETF	Nombre comercial	Qué representa
GLD	SPDR Gold Shares	Oro
IAU	iShares Gold Trust	
SLV	iShares Silver Trust	Plata
USO	United States Oil Fund	Petróleo
DBC	Invesco DB Commodity Index	Materias primas
VNQ	Vanguard Real Estate ETF	Sector inmobiliario

Tabla 6. ETFs seleccionados para representar materias primas y sector inmobiliario

3.2 Variables principales

Para cada ETF se recogieron dos variables principales: el precio ajustado de cierre y el volumen negociado.

- El **precio ajustado de cierre** es el precio del ETF al final de cada día, teniendo en cuenta dividendos y otros ajustes. Esta variable se utiliza porque permite analizar mejor cómo ha evolucionado el ETF en el tiempo. Llamaremos precio ajustado del activo i en el día t como: $P_{\{i,t\}}$
- El **volumen diario** indica cuántas participaciones del ETF se compraron y vendieron en un día. Un volumen alto significa que hubo mucha actividad en el mercado y que muchos inversores compraron o vendieron ese ETF. Se expresa como: $V_{\{i,t\}}$
- El **retorno simple** mide la variación porcentual entre el precio ajustado de cierre de un día y el del día anterior. Se calcula como:

$$R_{i,t} = \frac{P_{i,t} - P_{i,t-1}}{P_{i,t-1}}$$

donde $P_{i,t}$ es el precio ajustado de cierre del ETF i en el día t , y $P_{i,t-1}$ es el precio ajustado de cierre del día anterior. Este es más intuitivo porque indica directamente el porcentaje de subida o bajada entre un día y el anterior. Por ejemplo, si un ETF pasa de 100 a 102 euros, el retorno simple es del 2 %.

- El **retorno logarítmico** mide también la variación entre dos precios, pero transforma el retorno simple a logaritmo utilizando el logaritmo natural.

$$R_{i,t} = \frac{P_{i,t} - P_{i,t-1}}{P_{i,t-1}} \quad \rightarrow \quad 1 + R_{i,t} = \frac{P_{i,t}}{P_{i,t-1}} \quad \rightarrow \quad \ln(1 + R_{i,t}) = \ln\left(\frac{P_{i,t}}{P_{i,t-1}}\right)$$

Por lo tanto, el retorno logarítmico es:

$$r_{i,t} = \ln(1 + R_{i,t}) = \ln\left(\frac{P_{i,t}}{P_{i,t-1}}\right) = \ln(P_{i,t}) - \ln(P_{i,t-1})$$

Y su transformación para volver al retorno simple:

$$r_{i,t} = \ln(1 + R_{i,t}) \quad \rightarrow \quad e^{r_{i,t}} = 1 + R_{i,t} \quad \rightarrow \quad R_{i,t} = e^{r_{i,t}} - 1$$

En este trabajo se utiliza el retorno logarítmico porque facilita el análisis cuando se estudian retornos de varios días seguidos. La ventaja principal es que los retornos logarítmicos se pueden sumar. Es decir, si se quiere calcular el retorno de una semana, se pueden sumar los retornos diarios de esa semana y así analizar la evolución de los ETFs en distintos periodos.

Además, cuando los cambios de precio entre días son pequeños, como suele ocurrir en muchos retornos diarios, el retorno simple y el retorno logarítmico son muy parecidos. Por eso, el retorno logarítmico sigue teniendo una magnitud muy cercana al retorno simple, pero ofrece una forma más práctica de trabajar con series temporales financieras.

3.3 Análisis descriptivo inicial

Antes de aplicar modelos de predicción y construir carteras, se analizan las propiedades estadísticas básicas de los ETFs. Para poder entender cómo se comportan los retornos.

3.3.1 Estadística descriptiva

ETF	Retorno medio diario	Desv. típica diaria	Retorno mínimo	Percentil 5%	Percentil 25%	Mediana	Percentil 75%	Percentil 95%	Retorno máximo
SLV	0.000824	0.021201	-0.336037	-0.027873	-0.009590	0.000462	0.011420	0.032051	0.087487
USO	0.000662	0.021036	-0.123962	-0.033490	-0.011637	0.001509	0.013694	0.032124	0.076115
FXI	-0.000042	0.019867	-0.105268	-0.029030	-0.011263	-0.000725	0.010424	0.030209	0.192612
MCHI	-0.000132	0.019373	-0.114395	-0.028250	-0.010620	-0.000662	0.009846	0.030597	0.190103
EWZ	0.000329	0.017723	-0.077276	-0.029867	-0.009296	0.000973	0.011436	0.028281	0.093990
...	...	...	...	...	...	...	...	...	...
TIP	0.000035	0.003941	-0.016982	-0.006396	-0.002078	0.000092	0.002259	0.005759	0.017516
AGG	-0.000016	0.003798	-0.016529	-0.006085	-0.002254	0.000000	0.002203	0.006009	0.021243
BND	-0.000018	0.003760	-0.016284	-0.006109	-0.002221	0.000000	0.002222	0.006029	0.020491
SHY	0.000062	0.001222	-0.005101	-0.001844	-0.000494	0.000000	0.000605	0.001976	0.009924
BIL	0.000120	0.000185	-0.002841	-0.000109	0.000000	0.000109	0.000218	0.000437	0.007065

Tabla 7. Estadísticas descriptivas de retornos logarítmicos diarios por ETF

En primer lugar, se analiza la estadística descriptiva de los retornos logarítmicos diarios de los ETFs. La media diaria es muy cercana a cero en todos los casos. Esto indica que, en periodos cortos, las subidas y bajadas tienden a compensarse y que los retornos diarios suelen tener valores muy pequeños.

La desviación típica permite observar la volatilidad de cada ETF. Los activos relacionados con renta variable, materias primas o mercados más específicos presentan una mayor variabilidad, mientras que los ETFs de renta fija muestran valores más bajos. Esto confirma que no todos los activos tienen el mismo nivel de riesgo y que existen diferencias entre categorías.

También se analizan los valores mínimos, máximos y percentiles para detectar movimientos extremos en algunos ETFs. Por ejemplo, los activos de materias primas o de mercados concretos pueden presentar caídas o subidas más fuertes, como ocurre con SLV, que alcanza un retorno mínimo de -0,3360. En cambio, los fondos de renta fija tienden a mostrar movimientos más estables, como BIL, cuyo retorno mínimo es de -0,0028.

En conjunto, esta tabla muestra que los retornos diarios suelen ser pequeños y cercanos a cero, aunque la volatilidad cambia según el tipo de activo. Por esta razón, en el apartado de modelización de a continuación, se compara cada modelo con una referencia simple: predecir siempre un retorno igual a cero.

3.3.2 Histogramas

Los histogramas permiten visualizar la forma de la distribución de los retornos logarítmicos diarios.




Figura 2. Histogramas de retornos logarítmicos diarios de los ETFs: SPY, EWG e IAU

En la Figura 2 observamos de nuevo que la mayoría de los retornos se concentran alrededor de cero. Además, las distribuciones tienen forma aproximadamente acampanada, aunque algunos ETFs presentan valores más repartidos que otros. Los ETFs amplios de mercado, como SPY, muestran retornos más concentrados alrededor de cero, por lo que sus cambios diarios suelen ser más moderados. En cambio, algunos ETFs de mercados internacionales o sectores más concretos, como EWG, tienen colas más largas, con más días de subidas y bajadas. Por otro lado, los ETFs de materias primas, como IAU, muestran una mayor dispersión y más valores extremos. Sus retornos pueden variar más de un día a otro, lo que muestra un comportamiento menos estable que el de los ETFs más amplios.

3.3.3 Boxplot

Los *boxplots* permiten complementar el análisis anterior mostrando: la mediana, el rango intercuartílico y *outliers*.




Figura 3. Diagrama de caja de los retornos logarítmicos diarios del ETF SPY. La línea discontinua marca el retorno cero y los puntos representan valores atípicos

En el caso por ejemplo del ETF SPY500, como se muestra en la Figura 3, se observa una mediana cercana a cero y un rango intercuartílico muy reducido. Además, encontramos algunos valores extremos tanto positivos como negativos, estos reflejan días con movimientos anormalmente altos, generalmente

asociados a eventos macroeconómicos, crisis, perturbaciones de mercado... La presencia de estos valores extremos confirma que la volatilidad no es constante y que los mercados tienen momentos de alta incertidumbre, lo que afecta en la precisión de sus predicciones.




Figura 4. Diagramas de caja de los retornos logarítmicos diarios de los ETFs analizados. La línea discontinua marca el retorno cero y los puntos fuera de los bigotes representan posibles valores atípicos

El *boxplot* conjunto permite comparar visualmente la volatilidad entre activos. Podemos observar en la Figura 4:

- Los ETFs de renta variable (SPY, QQQ, VTI o IWM) presentan mayor dispersión que los de renta fija (BND, AGG, SHY o BIL). Esto es lógico ya que las acciones suelen moverse más que los bonos. Por eso, los ETFs de renta variable presentan cambios más fuertes, mientras que los de renta fija suelen tener movimientos más pequeños.
- Materias primas (GLD, SLV o USO) y algunos mercados emergentes (EEM, EWJ o FXI) presentan un mayor rango de variación y una mayor cantidad de *outliers*, reflejando episodios de mayor inestabilidad.
- Los activos del mismo tipo tienden a mostrar comportamientos similares.

Este resultado es coherente con la teoría financiera: activos con mayor riesgo presentan mayor variabilidad de retornos.

3.3.4 Matriz de correlaciones

La matriz de correlación permite analizar cómo se mueven conjuntamente los activos.




Figura 5. Matriz de correlación de los retornos logarítmicos diarios de los ETFs analizados. Los tonos rojos indican correlaciones positivas más altas, mientras que los tonos más claros indican correlaciones más bajas o cercanas a cero.

En la matriz de correlaciones de la Figura 5, se observa cómo se relacionan los retornos de los distintos ETFs. Los tonos más rojos indican una correlación más alta, es decir, activos que tienden a moverse en la misma dirección.

El gráfico muestra varios bloques de color más intenso. Esto significa que existen grupos de ETFs con comportamientos parecidos. Por ejemplo, muchos ETFs de renta variable estadounidense presentan correlaciones elevadas entre sí, ya que dependen en gran parte de la evolución general del mercado. En cambio, otros activos, como algunos ETFs de renta fija o materias primas, muestran una relación menor con el resto.

Este resultado es importante para el trabajo por dos razones. Por un lado, muestra que muchos ETFs están relacionados entre sí, algo que puede afectar a los modelos lineales cuando usan muchas variables parecidas. Por ello se incluye Ridge, que ayuda a controlar este problema mediante regularización. Por otro lado, también es importante para la optimización de carteras, si todos los ETFs se movieran igual, no habría beneficio por combinarlos. Al existir correlaciones distintas entre grupos, Markowitz puede repartir el peso entre activos con comportamientos diferentes.

3.3.5 Periodo de estudio y división temporal

El periodo de estudio abarca desde enero de 2021 hasta febrero de 2026, con datos diarios de mercado. A partir de estos datos se calculan los retornos logarítmicos utilizados después en los modelos de predicción.

Para evaluar los modelos de forma ordenada, el conjunto de datos se divide en dos partes: entrenamiento y *test*. El periodo de entrenamiento se utiliza para ajustar los modelos, mientras que el periodo de prueba se reserva para comprobar cómo funcionan con datos no vistos por el modelo anteriormente.

La división temporal se mantiene fija durante todo el trabajo. En el periodo de entrenamiento se utilizan los datos comprendidos desde la semana 2021-W01, que comienza el 4 de enero de 2021, hasta la semana 2024-W29, que finaliza el 21 de julio de 2024. El periodo de prueba comienza en la semana 2024-W30, 22 de julio de 2024, y finaliza en la semana 2026-W06, el 8 de febrero de 2026. Esto supone aproximadamente un 70 % de datos para entrenamiento y un 30 % para *test*. Esta separación permite comparar los resultados de los distintos modelos bajo las mismas condiciones.

Esta forma de dividir los datos es importante porque en series temporales tiene que respetarse el orden de los datos. En cada predicción, el modelo solo debe utilizar información disponible hasta ese momento. Por ello, en series temporales no se utiliza una división clásica en entrenamiento, validación y *test*, ya que una validación aleatoria podría romper el orden temporal de los datos.

En los modelos de aprendizaje automático sí se realiza una validación para elegir los mejores hiperparámetros, pero también siempre respetando el orden temporal. Este proceso se detalla de forma más desarrollada en el apartado siguiente.

Capítulo 4 - MÉTODOS DE MODELIZACIÓN

4.1 Modelización mediante series temporales

Una vez explicados los fundamentos de los modelos ARIMA en los preliminares, este apartado describe su aplicación a la predicción de retornos de ETFs. A continuación, se explica la preparación de los datos, la selección de los parámetros p , d y q , el proceso de predicción y los criterios utilizados para evaluar los resultados.

4.1.1 Preprocesamiento de los datos

Construcción de la serie de retornos

El punto de partida es el archivo *adj_close.csv*, que contiene los precios de cierre ajustados de los 63 ETFs para el periodo comprendido entre el 4 de enero de 2021 y el 2 de febrero de 2026, con un total de 1.276 días de cotización. A partir de estos precios se calculan, como hemos visto previamente, los retornos logarítmicos diarios:

$$r_{i,t} = \ln(P_{i,t}) - \ln(P_{i,t-1})$$

La variable objetivo que se modela con ARIMA son los retornos logarítmicos, no los precios. Esta decisión se debe a que los precios de los activos suelen presentar tendencia y, por tanto, no suelen ser estacionarios. En cambio, los retornos logarítmicos miden cambios relativos entre periodos, suelen mostrar un comportamiento más estable y son adecuados para el análisis con modelos de series temporales. Además, tienen la ventaja de ser aditivos en el tiempo, lo que facilita trabajar con distintas frecuencias, como la diaria y la semanal.

El estudio se realiza con frecuencia diaria y semanal para analizar cómo afecta la agrupación temporal al rendimiento del modelo ARIMA. Los datos diarios parten de más observaciones y reflejan cambios más inmediatos, aunque también presentan más ruido. En cambio, los datos semanales reducen parte de esa variación, pero cuentan con menos observaciones.

- **Serie diaria.** Para el modelo ARIMA diario se trabaja directamente con esta serie: cada observación es el retorno logarítmico de un día de trading. El modelo se ajusta ETF a ETF y se evalúa sobre el periodo de *test* con datos de frecuencia diaria.

- **Serie semanal.** Para el modelo ARIMA semanal, los retornos logarítmicos diarios se agrupan por semana del calendario ISO (YYYY-Www). En esta fase, cada semana se representa mediante la media de los retornos logarítmicos diarios de cada ETF durante esa semana. Esta misma agregación se utiliza en el preprocesado de los modelos de aprendizaje automático, lo que permite comparar ambos enfoques bajo las mismas condiciones.

Estacionariedad

Como se ha explicado anteriormente, una serie temporal es estacionaria cuando sus propiedades estadísticas como media y varianza no cambian a lo largo del tiempo. Es importante que se cumpla esta propiedad para poder aplicar los modelos ARIMA. Una serie no estacionaria tiene una tendencia o varianza cambiante que el modelo no podría capturar correctamente. Para evaluar la estacionariedad se aplican dos *tests* complementarios sobre los retornos logarítmicos de cada ETF:

- ADF (Augmented Dickey-Fuller)[18]: su hipótesis nula establece que la serie no es estacionaria. Si el p-valor es menor que 0,05, se rechaza esta hipótesis y hay evidencia estadística a favor de que la serie es estacionaria.
- KPSS (Kwiatkowski-Phillips-Schmidt-Shin)[19]: este *test* parte de la hipótesis contraria, es decir, que la serie sí es estacionaria. Si el p-valor es menor que 0,05, se rechaza la hipótesis y hay evidencia estadística a favor de que la serie sea no ser estacionaria.

Como ambas pruebas parten de hipótesis contrarias, sus resultados se analizan de forma conjunta:

ADF	KPSS	Conclusión
$p < 0,05$	$p > 0,05$	Estacionaria
$p > 0,05$	$p < 0,05$	No estacionaria
$p > 0,05$	$p > 0,05$	No concluyente
$p < 0,05$	$p < 0,05$	Inconsistente

Tabla 8. Interpretación conjunta de los tests ADF y KPSS para evaluar la estacionariedad

La Tabla 9 muestra los resultados obtenidos para el ETF AGG como ejemplo para entender por qué trabajamos con retornos:

ETF	Formato de los datos	Conclusión Estacionariedad
AGG	Adj_close	No estacionario
AGG	log(Adj_close)	No estacionario
AGG	retorno_simple	Estacionario
AGG	retorno_logaritmico	Estacionario

Tabla 9. Resultados de estacionariedad del ETF AGG en las variables: precio, logaritmo del precio, retorno simple y retorno logaritmico.

El resultado para AGG es el esperado: el precio y su logaritmo no son estacionarios, mientras que los retornos y los logaritmos de los retornos sí lo son. Este patrón se repite en la mayoría de ETFs. Sin embargo, cinco ETFs (BIL, EWY, GLD, IAU y SHY) presentan retornos no estacionarios o con resultados inconsistente. Estos activos se eliminaron para trabajar con series que cumplieran las mismas condiciones y aplicar el mismo procedimiento a todos los ETFs. El conjunto final consta de 58 ETFs, que son los que se usan en todos los modelos del trabajo.

4.1.2 Modelo ARIMA

Estructura del modelo ARIMA

Como se explicó en el apartado 2.3, un modelo ARIMA(p,d,q) combina tres componentes. La parte autorregresiva, AR(p), utiliza los p valores anteriores de la serie para estimar el valor actual. La parte de integración, I(d), aplica diferencias cuando la serie no es estacionaria. Por último, la parte de media móvil, MA(q), utiliza los q errores de predicción anteriores para ajustar la nueva predicción.

La forma general utilizada es:

$$r_t = c + \sum_{i=1}^p \phi_i r_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

- r_t : retorno a predecir.

- c : constante del modelo.
- r_{t-i} : retornos de periodos anteriores.
- ϕ_i : coeficientes de la parte autorregresiva. Indican cuánto influye cada retorno pasado en el retorno a predecir.
- ε_t : error del modelo, la parte que no consigue explicar.
- ε_{t-j} : errores cometidos en periodos anteriores.
- θ_j : coeficientes de la parte de media móvil. Indican cuánto influye cada error pasado en la predicción actual.
- p : número de retornos anteriores utilizados.
- q : número de errores anteriores utilizados.

Como los retornos logarítmicos utilizados en el estudio son estacionarios, no es necesario aplicar nuevas diferencias y se fija $d = 0$. Esta diferenciación no aparece en la ecuación, ya que la se realizaría antes de ajustar el modelo. Por tanto, todos los modelos tienen la forma $ARIMA(p,0,q)$, equivalente a un modelo $ARMA(p, q)$. El modelo se ajusta de forma independiente para cada ETF. De este modo, cada serie puede tener valores distintos de p y q , seleccionados mediante el procedimiento que se explicará en los apartados posteriores.

Análisis de autocorrelación: ACF y PACF

Antes de seleccionar los parámetros del modelo $ARIMA$, se analiza cualitativamente si los retornos actuales están relacionados con los retornos de periodos anteriores. Para ello se utilizan la función de autocorrelación (ACF) y la función de autocorrelación parcial (PACF).

La ACF mide la relación entre el retorno actual y sus valores pasados para distintos retardos. Por ejemplo, el retardo 1 compara el retorno actual con el del periodo anterior, mientras que el retardo 2 lo compara con el de dos periodos anteriores. Esta gráfica sirve como una orientación para elegir el parámetro q , asociado a la componente de media móvil.

La PACF mide la relación directa entre el retorno actual y un retardo concreto, eliminando el efecto de los retardos intermedios. Por ello, se utiliza como orientación inicial para elegir el parámetro autorregresivo p .

En ambas gráficas, el valor del primer retardo tiene un valor de 1, ya que representa la relación de la serie consigo misma. La zona sombreada muestra el intervalo dentro del cual la autocorrelación puede considerarse cercana a cero.

En el trabajo estudiamos los gráficos de ACF y PACF para cada ETF. Para simplificar, vamos a ver los gráficos de un ETF concreto, en este caso SPY500. Como observamos en el gráfico siguiente, la mayoría de los valores están cerca de cero y dentro del intervalo sombreado. Aunque aparecen algún retardo fuera de este intervalo, no se observa una relación fuerte ni un patrón que se mantenga durante varios periodos.




Figura 6. Función de autocorrelación (ACF) de los retornos logarítmicos diarios del ETF SPY. La zona sombreada representa el intervalo de confianza y permite identificar qué retardos presentan autocorrelaciones relevantes

Si vemos el gráfico PACF de la misma serie. De nuevo, la mayoría de los valores son pequeños y se encuentran dentro del intervalo de confianza. No aparece una caída clara después de uno o varios retardos concretos, por lo que la gráfica tampoco señala un valor claro para p .




Figura 7. Función de autocorrelación parcial (PACF) de los retornos logarítmicos diarios del ETF SPY. La zona sombreada representa el intervalo de confianza y sirve como apoyo para analizar posibles relaciones directas con retardos anteriores

En conjunto, ambas figuras muestran que los retornos de SPY tienen poca relación lineal con sus valores anteriores. Tampoco se observa un patrón que se repita de forma regular, por lo que no se aprecia una estacionalidad clara en la serie. Este comportamiento se repite en todos los ETFs. Como las gráficas no permiten elegir con claridad los parámetros p y q , se prueban distintas combinaciones y se comparan mediante los criterios AIC, BIC y el *test* de Ljung-Box. Este resultado no es extraño, ya que la predicción de retornos financieros es un problema difícil y con mucha incertidumbre. Por ello, el objetivo del trabajo no es obtener predicciones con un acierto muy elevado, sino comprobar si los modelos propuestos consiguen mejorar a modelos de referencia sencillos.

Criterios de selección de los parámetros del modelo ARIMA: AIC, BIC y *test* de Ljung-Box

Como se trabaja con retornos logarítmicos estacionarios, no es necesario aplicar una nueva diferencia. Por ello, el parámetro de integración se fija en $d = 0$.

La búsqueda se centra en los parámetros p y q . Tanto para los modelos diarios como semanales se prueban todas las combinaciones comprendidas entre 0 y 5 (36 combinaciones):

$$p, q \in \{0, 1, 2, 3, 4, 5\}$$

Para cada ETF se ajusta un modelo ARIMA $(p, 0, q)$ por cada combinación. Después, los modelos candidatos se comparan mediante el AIC, el BIC y el *test* de Ljung-Box.

- **Criterio AIC.** AIC se calcula como:

$$AIC = 2k - 2 \ln(L)$$

donde k es el número de parámetros del modelo y L indica lo bien que el modelo explica los datos observados.

El AIC[12] busca un equilibrio entre ajuste y complejidad. Un modelo con más parámetros puede ajustarse mejor, pero también puede aprender demasiado los datos de entrenamiento (sobreajuste). Por ello, el AIC añade una penalización por cada parámetro nuevo. Se elige el modelo con el AIC más negativo.

En este trabajo se utiliza el AIC como criterio principal porque el objetivo es predecir retornos futuros. Como se ha explicado, estos dependen de muchos factores que no se incluyen directamente en el modelo y que pueden reflejarse en los errores de predicción. Al penalizar menos la complejidad que el BIC, el AIC puede mantener componentes de media móvil que

utilizan esos errores anteriores y que podrían aportar información adicional. Su utilidad se analizará posteriormente en los resultados.

La Figura 8 muestra los valores de AIC obtenidos para las distintas combinaciones probadas en SPY. Cada punto representa un modelo ARIMA diferente. Se observan diferencias entre los modelos, lo que muestra que algunas de las 36 combinaciones de p y q se ajustan mejor que otras.




Figura 8. Valores de AIC de los modelos ARIMA candidatos para los retornos logarítmicos diarios del ETF SPY. Los valores más bajos indican un mejor equilibrio entre ajuste del modelo y complejidad

En la Figura 8, los valores más bajos corresponden a ARIMA(0,0,0) y ARIMA(0,0,3). El modelo (0,0,0) se excluye porque no utiliza retornos ni errores pasados, por lo que realiza siempre la misma predicción, normalmente la media de la serie. Una vez eliminado, se selecciona ARIMA(0,0,3), que utiliza los errores de los tres periodos anteriores para ajustar la predicción.

- **Criterio BIC.** El Criterio BIC se calcula como:

$$BIC = k \ln(n) - 2 \ln(L)$$

donde n es el número de observaciones utilizadas para ajustar el modelo y de nuevo, L indica lo bien que el modelo explica los datos observados.

El BIC [13] también compara el ajuste y la complejidad, pero penaliza más los modelos con muchos parámetros. Por eso, suele elegir modelos más sencillos que el AIC.

En la Figura 9 se muestran los valores de BIC para las 36 combinaciones de modelos candidatos para SPY. Igual que en el AIC, el modelo preferido es el que presenta el valor más bajo. En este

trabajo, el BIC se utiliza como criterio secundario. Si dos modelos presentan valores de AIC muy parecidos, se elige el que tenga el BIC más bajo.




Figura 9. Valores de BIC de los modelos ARIMA candidatos para los retornos logarítmicos diarios del ETF SPY. Este criterio penaliza con mayor fuerza la complejidad, por lo que favorece modelos más sencillos

En la Figura 8 (AIC), veíamos que los modelos ARIMA(0,0,0) y ARIMA(0,0,3) tenían valores muy parecidos. Esto significa que, para el AIC, la mejora obtenida al incluir parámetros compensa el aumento de complejidad. En cambio, en la Figura 9 (BIC), existe una diferencia mucho mayor entre los primeros modelos que son claramente mejores, ya que el BIC penaliza con más fuerza los parámetros adicionales y favorece claramente al modelo ARIMA(0,0,0). Se aprecia que el paso de combinaciones de $q=2$ a $q=3$ produce una variación pequeña en el criterio BIC. Esto indica que añadir el tercer término de media móvil no supone un aumento excesivo de complejidad, por lo que ARIMA(0,0,3) continúa siendo mejor valor también en este criterio.

- **Test de Ljung-Box.** Después de ajustar cada modelo ARIMA, se analiza si los residuos mantienen autocorrelación. Los residuos son la diferencia entre el retorno real y el retorno predicho:

$$\varepsilon_t = r_t - \hat{r}_t$$

Si los residuos tienen autocorrelación, significa que todavía queda información en la serie que el modelo no ha conseguido entender. El test de Ljung-Box [20] permite comprobar si existe esta información. Su hipótesis nula establece que los residuos obtenidos después de ajustar el modelo no presentan autocorrelación.

- Si el p-valor es mayor que 0,05, no se rechaza la hipótesis nula. No se encuentra una relación clara entre los residuos y por ello, no tenemos razones para rechazar el modelo.

- Si el p-valor es menor o igual que 0,05, se rechaza la hipótesis nula, por lo que el modelo puede haber dejado información sin explicar




Figura 10. P-valores del test de Ljung-Box aplicado a los residuos de los modelos ARIMA candidatos para el ETF SPY

La Figura 10 muestra los p-valores del *test* de Ljung-Box para los modelos candidatos de SPY. Todos los valores son superiores a 0,05, por lo que no quedaría autocorrelación significativa en sus residuos y ninguno de los modelos queda descartado por este criterio.

Relación entre la ACF, la PACF y el modelo seleccionado

Las gráficas ACF y PACF vistas antes, mostraban que la autocorrelación de los retornos era generalmente baja y ambas tenderían por el modelo (0,0,0). En el proceso de búsqueda hemos seleccionado modelos con $p > 0$ o $q > 0$, esto no supone una contradicción ya que las gráficas muestran que no existe una dependencia fuerte, pero puede haber relaciones pequeñas que ayuden a reducir el error posterior de la predicción. El AIC permite comprobar si esa mejora compensa el aumento de complejidad del modelo.

Por tanto, la ACF y la PACF se utilizan para comprender la serie y orientar la búsqueda, mientras que la elección definitiva se realiza mediante los valores de AIC, BIC y Ljung-Box.

Predicción *walk-forward*

La evaluación de los modelos diarios y semanales se realiza mediante el método *walk-forward*. Este procedimiento simula cómo se utilizaría el modelo en una situación real, donde solo se dispone de la información conocida hasta el momento de realizar cada predicción.

En cada paso se sigue el mismo proceso:

1. El modelo se ajusta con todos los datos disponibles hasta ese momento.
2. Se genera la predicción del periodo siguiente.
3. La predicción se guarda para compararla después con el valor real y poder calcular errores de predicción.
4. Cuando se conoce el retorno real, este se añade al conjunto histórico.
5. El modelo se vuelve a entrenar con todo el conjunto histórico actualizado y el proceso se repite.

En el análisis diario, el modelo predice el retorno del siguiente día de mercado. En el análisis semanal, predice el retorno de la semana siguiente. Se mantiene la partición temporal de entrenamiento y *test* definida en el capítulo de datos. El reentrenamiento en cada paso permite que el modelo utilice toda la información disponible hasta esa fecha y así ajustarse a los cambios del mercado. Esto es importante en datos financieros, ya que su comportamiento puede variar en periodos cortos de tiempo.

Evaluación de las predicciones

Las métricas utilizadas para evaluar los modelos son el RMSE, el MAE y la Kappa de Cohen, que se explicaron en el apartado 2.6. En esta fase se calculan estas métricas para todas las predicciones obtenidas durante el *test*.

El RMSE se utiliza como métrica principal, ya que da más peso a los errores grandes. El MAE se emplea como medida complementaria para conocer cuánto se aleja, de media, la predicción del retorno real. También se calcula la Kappa de Cohen para estudiar si el modelo acierta la dirección del retorno. Esta métrica permite comprobar si el modelo acierta las subidas y bajadas más de lo que podría esperarse por azar.

Los resultados, además, se comparan con dos modelos de referencia:

- Modelo *naive*: utiliza el retorno observado en el periodo anterior como predicción del siguiente.
- Modelo *zero*: predice siempre un retorno igual a cero.

Para estos dos modelos también se calculan RMSE y MAE. De esta forma, no solo se comparan los distintos modelos ARIMA entre sí, sino que también se comprueba si mejoran sus métricas de predicción.

La selección final se hace comparando principalmente el RMSE de cada uno de los 3 modelos (ARIMA, *naive* y *zeros*), pero se revisan también el MAE y la Kappa de Cohen para obtener una valoración más

completa. Un modelo puede tener un error bajo y, al mismo tiempo, no acertar correctamente la dirección de los retornos, por lo que ambas formas de evaluación aportan información diferente.

Tras completar este proceso para todos los ETFs y para las dos frecuencias (semanal y diaria), se presentan los resultados obtenidos en el siguiente apartado

4.1.3 Resultados ARIMA

Modelo diario

El modelo diario se aplica a 56 de los 58 ETFs seleccionados. En los casos de HYG y JNK, ninguna de las combinaciones ARIMA probadas supera el *test* de Ljung-Box, ya que sus residuos siguen presentando autocorrelación. La Tabla 10 resume los errores medios obtenidos por ARIMA y por los dos modelos de referencia durante el *test*.

Modelo	RMSE medio	MAE medio
ARIMA	0,01127	0,00787
<i>Baseline</i> (t-1)	0,01613	0,01149
<i>Zeros</i>	0,01124	0,00785

Tabla 10. Errores medios en test del modelo ARIMA diario y de los modelos de referencia *baseline* y *zeros*

En la Tabla 10 se observa que ARIMA mejora al modelo *baseline*, tanto en RMSE como en MAE. Sin embargo, sus resultados son ligeramente peores a los del modelo *zero*. Esta comparación es importante porque los retornos diarios suelen tomar valores muy cercanos a cero. Por ello, una predicción constante de cero puede obtener un error reducido sin detectar ningún patrón. Si ARIMA consigue mejorar este resultado, significa que está aprovechando información de los retornos pasados para acercarse más al valor real.

La Tabla 11 presenta los resultados por grupos de activos. Las dos últimas columnas muestran cuántos ETFs de cada grupo obtienen un RMSE menor que el *baseline* y que el modelo *zeros*:

Grupo	N	RMSE ARIMA	RMSE BASE	RMSE ZEROS	MAE ARIMA	Bate base	Bate zeros
Core US	10	0,01190	0,01730	0,01187	0,00802	10/10	1/10
Factores	11	0,01055	0,01518	0,01051	0,00722	11/11	0/11
Sectores	11	0,01176	0,01686	0,01171	0,00841	11/11	0/11
Internacional	15	0,01232	0,01764	0,01230	0,00870	15/15	3/15
Renta fija	6	0,00403	0,00557	0,00403	0,00312	6/6	3/6
Materias primas	3	0,01921	0,02657	0,01921	0,01311	3/3	1/3

Tabla 11. Resultados medios por grupo de activos del modelo ARIMA diario y comparación frente a los modelos baseline y zeros

ARIMA diario obtiene un RMSE menor que el *baseline* en todos los ETFs analizados, con una reducción media del error del 30,13 %. El *baseline* utiliza el último retorno observado como predicción del siguiente, pero los retornos diarios suelen tener poca relación con el día anterior. Por ello, repetir el último valor genera un error mayor que las predicciones de ARIMA.

ARIMA diario solo supera al modelo zero en 8 de los 56 ETFs. Como los retornos suelen estar cerca de cero, predecir siempre cero produce poco error. ARIMA intenta predecir si el retorno subirá o bajará, pero no siempre acierta la dirección. Por eso, en la mayoría de los ETFs no consigue mejorar al modelo *zero*.

Las diferencias de RMSE entre grupos están relacionadas principalmente con la volatilidad de los activos. La renta fija presenta el menor error, con un RMSE medio de 0,00403, porque sus retornos diarios suelen tener cambios más pequeños y estables. Además, 3 de sus 6 ETFs superan al modelo *zeros*, el mejor resultado entre los grupos.

Las materias primas tienen el error más alto. Activos como la plata o el petróleo pueden tener movimientos fuertes por cambios en la oferta, la demanda o el contexto internacional, factores que no se incluyen directamente en ARIMA.

En conjunto, el modelo diario reduce de forma clara el error frente al *baseline*, pero empeora frente a la predicción constante de cero. Esto muestra que gran parte de su buen resultado se debe a generar valores pequeños, pero que la información temporal que consigue extraer de los retornos es limitada.

A modo de ejemplo, el gráfico siguiente muestra las predicciones del modelo ARIMA para dos ETFs: SPY y DVY, durante el periodo de *test*. En la versión a escala original se observa cómo las predicciones son de

magnitud muy pequeña comparada con los retornos reales y en la versión de ARIMA multiplicada por 10 para aumentar su escala, se pueden ver la forma de las predicciones que el modelo genera.




Figura 11. Comparación entre los retornos reales y las predicciones ARIMA para el ETF SPY en frecuencia diaria




Figura 12. Comparación entre los retornos reales y las predicciones ARIMA para el ETF DVY en frecuencia diaria




Figura 13. Comparación entre los retornos reales y las predicciones ARIMA multiplicadas por 10 para el ETF SPY en frecuencia diaria




Figura 14. Comparación entre los retornos reales y las predicciones ARIMA multiplicadas por 10 para el ETF DVY en frecuencia diaria

En cuanto a la dirección del movimiento, el modelo ARIMA diario obtiene una Kappa media de $-0,0012$ y un porcentaje medio de aciertos del 49,65%. Estos valores están muy cerca del azar, que sería aproximadamente un 50%.

Los resultados cambian según el ETF. Una Kappa negativa indica que la dirección predicha coincide con la real menos de lo que se esperaría por azar. En la Figura 15, las barras verdes representan valores positivos de Kappa para cada ETF y las rojas valores negativos.




Figura 15. Valores de Kappa de Cohen por ETF para evaluar la capacidad del modelo ARIMA diario de predecir la dirección del retorno

En conjunto, los resultados diarios no son muy alentadores. El porcentaje medio de aciertos se mantiene alrededor del 50 %, un valor muy cercano al azar. Esto también se refleja en la Figura 15, donde los valores de Kappa aparecen repartidos entre positivos y negativos. Aun así, este comportamiento es coherente con la dificultad de predecir retornos diarios, que suelen ser ruidosos y poco dependientes de los valores anteriores. Por este motivo, en el siguiente apartado se analiza la frecuencia semanal, donde se espera reducir parte del ruido diario y comprobar si el rendimiento mejora ligeramente.

Modelo semanal

El modelo semanal se aplica a los 58 ETFs seleccionados. En esta frecuencia, todos los activos encuentran al menos una combinación ARIMA válida según el test de Ljung-Box. La agrupación semanal reduce parte de las variaciones diarias y permite trabajar con series más estables. La Tabla 12 muestra los errores medios globales en el período de *test*:

Modelo	RMSE medio	MAE medio
ARIMA	0,00492	0,00365
<i>Baseline</i> (t-1)	0,00714	0,00537
<i>Zeros</i>	0,00492	0,00367

Tabla 12. Errores medios en test del modelo ARIMA semanal y de los modelos de referencia *baseline* y *zeros*

ARIMA supera al *baseline* en los 58 ETFs y obtiene un RMSE medio un 31 % más bajo. A diferencia de lo observado en el modelo diario, donde el modelo *zero* obtenía un RMSE ligeramente mejor que ARIMA, en la frecuencia semanal ambos modelos presentan el mismo RMSE medio. Además, ARIMA obtiene un MAE ligeramente menor, de 0,00365 frente a 0,00367, por lo que en este caso es el mejor de los tres modelos comparados. También supera al modelo *zero* en 30 de los 58 ETFs, frente a solo 8 en el análisis diario. Esto indica que agrupar los datos por semanas permite reducir parte del ruido diario y aprovechar mejor la información de periodos anteriores.

La Tabla 13 muestra los resultados por tipo de activo. Las dos últimas columnas, como en el caso anterior, indican cuántos ETFs de cada grupo presentan un RMSE menor que el *baseline* y que el modelo *zero*.

Grupo	N	RMSE ARIMA	RMSE BASE	RMSE ZEROS	MAE ARIMA	Bate base	Bate zeros
Core US	10	0,00509	0,00777	0,00513	0,00383	10/10	10/10
Factores	11	0,00458	0,00694	0,00461	0,00344	11/11	9/11
Sectores	11	0,00521	0,00769	0,00519	0,00400	11/11	5/11
Internacional	15	0,00551	0,00765	0,00547	0,00417	15/15	2/15
Renta fija	8	0,00187	0,00269	0,00185	0,00139	8/8	2/8
Materias primas	3	0,00973	0,01311	0,00971	0,00666	3/3	2/3

Tabla 13. Resultados medios por grupo de activos del modelo ARIMA semanal y comparación frente a los modelos baseline y zeros

Los mejores resultados frente al modelo *zero* aparecen en Core US y Factores. Esto supone una gran mejora respecto al análisis diario y muestra que los índices estadounidenses tienen un comportamiento más aprovechable cuando se estudian por semanas. La renta fija vuelve a presentar los errores más bajos. Sin embargo, solo 2 de los 8 ETFs superan al modelo *zero*, precisamente porque sus retornos están muy concentrados alrededor de ese valor. Las materias primas siguen teniendo el RMSE más alto, con un valor medio de 0,00973.

En conjunto, la frecuencia semanal mantiene la mejora frente al *baseline* y aumenta el número de ETFs que superan al modelo *zero*. La reducción del ruido diario permite que ARIMA obtenga mejores resultados.

En los gráficos semanales se observa que las predicciones de ARIMA son mucho más pequeñas que los retornos reales y se mantienen cerca de cero. Por eso, el modelo no capta del todo bien las semanas con subidas o bajadas fuertes. Al multiplicar las predicciones por 10 para ver mejor la dirección del modelo, se aprecia que en algunos ETFs, como SPY, ARIMA sigue parte de los cambios de dirección, aunque no acierta su tamaño. En otros, como DVY, la predicción se mantiene casi plana, lo que muestra que hay poca información útil en los valores anteriores.




Figura 16. Comparación entre los retornos reales y las predicciones ARIMA para el ETF SPY en frecuencia semanal




Figura 17. Comparación entre los retornos reales y las predicciones ARIMA para el ETF DVY en frecuencia semanal




Figura 18. Comparación entre los retornos reales y las predicciones ARIMA multiplicadas por 10 para el ETF SPY en frecuencia semanal




Figura 19. Comparación entre los retornos reales y las predicciones ARIMA multiplicadas por 10 para el ETF DVY en frecuencia semanal

En cuanto a la dirección del movimiento, el modelo semanal obtiene una kappa media de 0,0290 y un porcentaje de acierto medio del 50,30 %. La Figura 20 muestra los valores de kappa de Cohen por ETF,

donde se observa que la kappa media mejora respecto al caso diario, aunque los resultados no siguen un patrón claro según el grupo de activos.




Figura 20. Valores de Kappa de Cohen por ETF para evaluar la capacidad del modelo ARIMA semanal de predecir la dirección del retorno

Comparación entre frecuencia diaria y semanal

En ambas frecuencias, ARIMA mejora al modelo *baseline* en aproximadamente un 30%. La diferencia más clara aparece al compararlos con el modelo *zero*. El modelo diario lo supera en 8 de los 56 ETFs, mientras que el semanal lo hace en 30 de los 58. Por tanto, al agrupar los datos por semanas, ARIMA consigue aprovechar mejor la información de los periodos anteriores.

La predicción de la dirección también mejora ligeramente. La Kappa media pasa de $-0,0012$ en diario a $0,0290$ en semanal. Aunque los valores siguen siendo bajos, la frecuencia semanal obtiene mejores resultados.

Por estos motivos, se selecciona el modelo ARIMA semanal como la mejor opción dentro de los modelos de series temporales. A continuación, se comparará con modelos de aprendizaje automático para decidir qué enfoque ofrece las predicciones más útiles para la cartera de Markowitz.

4.2 Modelización mediante aprendizaje automático

Después del análisis con modelos de series temporales, entramos la predicción de retornos mediante aprendizaje automático supervisado. La principal diferencia es que ARIMA analiza cada ETF por separado utilizando solo sus datos históricos. En cambio, los modelos de *machine learning* pueden usar al mismo

tiempo información de todos los ETFs, del volumen y de variables temporales y así poder añadir relaciones entre activos.

4.2.1 Preprocesamiento de los datos

Se construyen de nuevo dos versiones de distinta frecuencia, una diaria y otra semanal. En ambas frecuencias se parte de los mismos datos de origen que en los modelos ARIMA: precios ajustados de cierre descargados con *yfinance* para el período 2021-01-04 a 2026-02-02, utilizando el 70% de las observaciones más antiguas para el conjunto de entrenamiento y el 30% restante para el conjunto de *test*. Además, los modelos de aprendizaje automático añaden el volumen diario por ETF como una variable de entrada adicional.

También se mantienen los mismos 58 ETFs. Se eliminan BIL, EWY, GLD, IAU y SHY porque sus retornos no mostraron un comportamiento estacionario. De esta forma, ambos enfoques trabajan con los mismos activos y sus resultados pueden compararse en las mismas condiciones.

Preprocesado para la frecuencia diaria

El *dataset* diario toma como base los retornos logarítmicos diarios y el cambio logarítmico del volumen. Cada fila representa un día de mercado y contiene el estado completo del universo en ese momento.

Variables de retorno logarítmico diario. Igual que en el análisis ARIMA, a partir de los precios ajustados de cierre se calculan los retornos diarios de los 58 ETFs, obteniendo una columna de retornos por cada activo.

Variables de diferencia logarítmica de volumen. Para cada ETF se calcula el cambio del volumen respecto al día anterior mediante logaritmos. Esta variable permite medir si la actividad de compra y venta ha aumentado o disminuido. En total, se añaden 58 columnas de volumen.

Variables de calendario. Se incorporan variables temporales para recoger posibles efectos asociados al calendario. En el caso diario, se incluyen variables binarias para identificar el día de la semana, además de variables que indican si la fecha corresponde al inicio o al final de un mes, o al inicio o al final de un trimestre. Estas variables se añaden como información auxiliar para que los modelos puedan disponer de referencias temporales adicionales durante el entrenamiento. En total, se incorporan nueve variables de calendario.

Variable objetivo (*target*). Para cada ETF se crea una columna llamada *target* con el retorno logarítmico real del día siguiente. Así, cada fila contiene la información conocida en el día actual y el valor que el modelo debe aprender a predecir. La última fila se elimina porque no existe un día posterior del que obtener el retorno. Durante el entrenamiento, el *target* se utiliza para que el modelo aprenda. En el periodo de *test*, se mantiene separado y solo se usa después para comparar el retorno real con la predicción obtenida.

Lags (retardos). Un *lag* es el valor que tuvo una variable en un periodo anterior. Por ejemplo, el *lag* 1 es el retorno del día anterior, el *lag* 2 es el retorno de hace dos días. Para comprobar si esta información mejora la predicción, se crean cinco versiones del conjunto de datos. La primera utiliza solo el retorno del día actual. Las demás añaden los retornos de uno, dos, tres o cuatro días anteriores. Las dimensiones de cada *dataset* diario son:

Dataset	Lags	Filas	Columnas
<i>df_diario.csv</i>	0	1.275	125
<i>df_diario_1.csv</i>	1	1.274	183
<i>df_diario_2.csv</i>	2	1.273	241
<i>df_diario_3.csv</i>	3	1.272	299
<i>df_diario_4.csv</i>	4	1.271	357

Tabla 14. Número de filas y columnas de los datasets diarios utilizados en los modelos de aprendizaje automático, según el número de lags incluido

Al añadir cada retardo se incorporan 58 columnas nuevas, una por cada ETF. El número de filas disminuye en una observación por cada *lag* añadido, ya que los primeros días no tienen datos anteriores suficientes. Estas filas iniciales, que contienen valores vacíos, se eliminan del conjunto de datos.

Preprocesado para la frecuencia semanal

Para construir el conjunto de datos semanal, primero se agrupan los datos diarios por semanas del calendario ISO, con formato YYYY-Www.

Variables de retorno logarítmico semanal. Para cada ETF se utiliza la misma forma de agrupación que en el modelo ARIMA semanal para poder comparar ambos enfoques en las mismas condiciones.

Variables de diferencia logarítmica del volumen semanal. El volumen se calcula como la media diaria de cada semana. De esta forma, se pueden comparar semanas con distinto número de días de mercado. Después, se calcula su cambio logarítmico respecto a la semana anterior.

Variables de calendario. Se añaden cuatro variables binarias que indican si la semana contiene el inicio o el final de un mes o de un trimestre. Estas variables permiten comprobar si esos momentos del calendario influyen en los retornos.

Variable objetivo y lags. El *target* de cada ETF es el retorno de la semana siguiente. Igual que en el caso diario, se crean cinco versiones del conjunto de datos: sin retardos y con uno, dos, tres o cuatro retornos semanales anteriores. Las dimensiones de cada dataset semanal son:

Dataset	Lags	Filas	Columnas
df_semanal.csv	0	264	182
df_semanal_1.csv	1	264	240
df_semanal_2.csv	2	263	298
df_semanal_3.csv	3	262	356
df_semanal_4.csv	4	261	414

Tabla 15. Número de filas y columnas de los datasets semanales utilizados en los modelos de aprendizaje automático, según el número de lags incluido

El primer retardo no reduce de nuevo el número de filas porque la primera semana ya se había eliminado al calcular la diferencia logarítmica del volumen. A partir del segundo retardo, cada *lag* adicional elimina una observación más por falta de información histórica. Estas cinco versiones permiten comprobar si los retornos de semanas anteriores aportan información útil y ayudan a mejorar la predicción del retorno de la semana siguiente.

4.2.2 Selección de Modelos

Se prueban cuatro modelos de regresión: *Regresión Lineal*, *Ridge*, *Random Forest* y *Gradient Boosting*. Su funcionamiento general se explicó en el capítulo de preliminares. Cada modelo se entrena con los cinco archivos CSV creados anteriormente, que contienen entre 0 y 4 *lags*. Así, se puede comparar tanto qué

modelo obtiene mejores resultados como si añadir retardos al modelo mejora las predicciones. En este apartado se explican las decisiones tomadas para entrenar cada modelo y ajustar sus parámetros.

Regresión lineal

La regresión lineal se incluye como el modelo más sencillo y sirve como punto de partida para comparar el resto. No tiene hiperparámetros que ajustar, por lo que se entrena directamente con los datos disponibles.

Para este modelo, el número de variables es elevado en comparación con el número de observaciones, especialmente en el conjunto semanal. Al añadir retardos, el modelo dispone de muchas columnas y puede ajustarse demasiado a los datos de entrenamiento, pero no saber adaptarse con datos nuevos (sobreajuste).

Ridge

Ridge parte de una regresión lineal, pero añade una penalización que evita que los coeficientes alcancen valores demasiado altos. Esto es útil en nuestro caso ya que hay muchas variables iniciales.

Antes de entrenar el modelo, las variables se escalan mediante *StandardScaler*. Este paso coloca todas las variables en una escala parecida, evitando que la penalización afecte de forma distinta a variables como los retornos, el volumen o los indicadores de calendario.

El principal hiperparámetro de *Ridge* es *alpha*, que controla la fuerza de la penalización. Un valor mayor reduce más los coeficientes, mientras que un valor menor hace que el modelo se parezca más a una regresión lineal normal.

El valor de *alpha* se selecciona antes de comenzar la evaluación *walk-forward*. Para ello, se utiliza *RidgeCV* que prueba distintos valores de *Alpha* entre 100 y 100.000 utilizando una validación temporal *TimeSeriesSplit* con cinco divisiones del conjunto de train. En cada división, el modelo se entrena con datos anteriores y se valida con un periodo posterior, sin mezclar observaciones futuras y pasadas. Tras las cinco comprobaciones, se elige el valor de *Alpha* que obtiene el menor error medio. A continuación, el modelo se entrena de nuevo con el parámetro seleccionado y se aplica el proceso *walk-forward* durante todo el periodo de *test*.

Random Forest

Random Forest construye muchos árboles de decisión y calcula la predicción final como la media de todos ellos. Cada árbol utiliza una parte diferente de los datos y de las variables, lo que reduce la dependencia de un único árbol y ayuda a controlar el sobreajuste.

Este modelo puede detectar relaciones no lineales mediante reglas sucesivas sobre las variables. Además, no necesita escalado previo, ya que los árboles comparan cada variable con distintos valores límite y no dependen de que todas estén medidas en la misma escala.

Primero se realiza una fase de validación para encontrar los mejores hiperparámetros de *Random Forest*. Para ello, *RandomizedSearchCV* prueba 30 combinaciones elegidas al azar entre todas las posibles de a continuación y utiliza también *TimeSeriesSplit* con cinco divisiones. Los parámetros probados son:

- *N_estimators*: número de árboles, con valores de 50, 100, 200 y 300.
- *Max_depth*: profundidad máxima de los árboles, con valores None, 3, 5, 10, 15 y 20.
- *Min_samples_leaf*: número mínimo de observaciones que debe contener cada hoja final del árbol, con valores 1, 2, 5 y 10.
- *Max_features*: cantidad de variables que puede utilizar cada árbol en una división, con valores *sqrt*, 30%, 50%, 70% y 100%. El valor *sqrt* utiliza la raíz cuadrada del número total de variables.

En total hay $4 \times 6 \times 4 \times 5 = 480$ combinaciones posibles de parámetros, pero solo se prueban 30 para reducir el tiempo de ejecución. La búsqueda se hace una vez por cada archivo CSV usando un ETF como referencia. Después, esos parámetros se aplican al resto de ETFs del mismo archivo. Esta decisión se toma para evitar un tiempo de cálculo demasiado elevado. Una vez elegida la configuración, comienza la evaluación *walk-forward*.

Gradient Boosting

Gradient Boosting también utiliza árboles de decisión, pero los construye de forma consecutiva. Cada nuevo árbol intenta corregir parte de los errores realizados por los anteriores.

Este modelo puede estudiar relaciones no lineales, aunque necesita un mayor control para evitar el sobreajuste, especialmente en el conjunto semanal, que contiene pocas observaciones.

La búsqueda de hiperparámetros sigue el mismo procedimiento que en *Random Forest*: *RandomizedSearchCV* con 30 combinaciones y una validación *TimeSeriesSplit* de cinco divisiones. Además, se añaden 2 nuevos hiperparámetros propios de este modelo:

- *Learning_rate*: controla cuánto influye cada nuevo árbol en la predicción final. Se prueban los valores 0'01, 0'05, 0'1 y 0'2. Un valor pequeño realiza correcciones más suaves y suele necesitar más árboles, mientras que un valor alto corrige más rápido, pero puede aumentar el riesgo de sobreajuste.
- *Subsample*: indica qué parte de las observaciones se utiliza para entrenar cada árbol. Se prueban valores del 60 %, 80 % y 100 % del conjunto de entrenamiento. Utilizar menos observaciones añade variedad entre los árboles y puede reducir el sobreajuste, mientras que un valor del 100 % utiliza todos los datos disponibles.

El espacio total contiene $4 \times 6 \times 4 \times 5 \times 4 \times 3 = 5760$ combinaciones posibles, de las que se prueban 30. Los parámetros *max_depth*, *learning_rate* y *subsample* ayudan a controlar cuánto aprende el modelo y evitan que se ajuste demasiado a los datos de entrenamiento.

Predicción *walk-forward* y evaluación de predicciones

La evaluación de los modelos de aprendizaje automático sigue el mismo procedimiento utilizado en ARIMA. Se mantiene la misma división temporal y se aplica el método de predicción *walk-forward*. En cada paso, el modelo se entrena con toda la información disponible hasta ese momento, predice el periodo siguiente y después incorpora el valor real al conjunto histórico y repite el proceso.

Para evaluar los resultados también se utilizan las mismas métricas y modelos de referencia que en ARIMA: RMSE, MAE y Kappa de Cohen, junto con el modelo *baseline* y el modelo *zeros*. Mantener el mismo periodo de prueba, las mismas métricas y las mismas referencias permite comparar de forma directa los resultados de los modelos de series temporales y de aprendizaje automático.

Registro de experimentos con Google Sheets

La combinación de 5 archivos csv de datos por cada una de las frecuencias, 58 ETFs y 4 modelos ML, genera un total de 1.160 experimentos por frecuencia, 2.320 en total. Para gestionar este volumen, el *notebook*

de entrenamiento está organizado como una cola de experimentos y los resultados se guardan automáticamente en una hoja de Google *Sheets* accesible en tiempo real mediante la API de Google Drive.

Cada fila de la hoja representa un experimento e incluye:

- Identificación: archivo de datos, modelo, ETF objetivo.
- Estado: pendiente, en ejecución, error o completado.
- Fechas de inicio y fin de ejecución.
- Resultados: RMSE, MAE, RMSE_*baseline*, RMSE_*zeros*, MAE_*baseline*, MAE_*zeros*.
- Hiperparámetros encontrados de los modelos: *Alpha* (*Ridge*), *n_estimators*, *max_depth*, *min_samples_leaf*, *max_features* (RF y GBR), *learning_rate*, *subsample* (GBR).
- Rango temporal de predicciones: FechaPredIni, FechaPredFin, FechaTrainIni, FechaTrainFin.

Este registro permite detener y reanudar la ejecución sin perder los resultados ya obtenidos. Esto es necesario porque el proceso necesita mucho tiempo de ejecución y puede interrumpirse por algún error o cierre inesperado. Además, la hoja se utiliza como base de datos para analizar y comparar posteriormente los resultados.

4.2.3 Resultados ML

De nuevo, para cada combinación de modelo y número de lags se calcula el RMSE y MAE medios sobre los 58 ETFs en el período de *test*. Los resultados se presentan primero para la frecuencia diaria, después para la semanal, y a continuación se comparan ambas frecuencias para seleccionar el modelo de aprendizaje automático con mejores resultados.

Resultados del modelo diario

Las tablas 16 y 17 muestran el RMSE y MAE medio global por modelo y número de *lags* en frecuencia diaria del período de *test* (aproximadamente 385 días por ETF):

Lags	RMSE Reg. Lin.	RMSE <i>Ridge</i>	RMSE RF	RMSE GBR	RMSE base	RMSE <i>Zeros</i>
0	0,01203	0,01126	0,01124	0,01125	0,01616	0,01123
1	0,01278	0,01132	0,01129	0,01129	0,01616	0,01123
2	0,01364	0,01129	0,01127	0,01129	0,01616	0,01123

3	0,01432	0,01127	0,01126	0,01132	0,01616	0,01123
4	0,01485	0,01128	0,01126	0,01124	0,01616	0,01123

Tabla 16. RMSE medio en test de los modelos de aprendizaje automático en frecuencia diaria según el número de lags utilizado

Lags	MAE Lin. Reg.	MAE Ridge	MAE RF	MAE GBR	MAE base	MAE Zeros
0	0,00852	0,00770	0,00769	0,00769	0,01124	0,00769
1	0,00898	0,00775	0,00771	0,00771	0,01124	0,00769
2	0,00959	0,00772	0,00771	0,00773	0,01124	0,00769
3	0,01014	0,00772	0,00770	0,00770	0,01124	0,00769
4	0,01078	0,00772	0,00770	0,00768	0,01124	0,00769

Tabla 17. MAE medio en test de los modelos de aprendizaje automático en frecuencia diaria según el número de lags utilizado

Ridge, *Random Forest* y *Gradient Boosting* obtienen resultados muy parecidos. En los tres modelos, añadir retardos no mejora la predicción y, en general, aumenta ligeramente el error. Esto confirma lo observado con ARIMA: los retornos de días anteriores aportan muy poca información sobre el retorno del día siguiente. En la regresión lineal, el empeoramiento es mucho más claro, ya que el aumento del número de variables tiende al sobreajuste.

Los tres modelos mejoran al *baseline*, con una reducción del RMSE cercana al 30%. Sin embargo, sus resultados son prácticamente iguales y ligeramente peores que los del modelo *zero*. *Random Forest* con 0 lags obtiene uno de los menores MAE y el menor RMSE, con un valor de 0,01124. Por este motivo, se selecciona como la mejor configuración diaria para las comparaciones posteriores.

La Figura 21 muestra la evolución del RMSE de *Random Forest* para cada ETF al aumentar el número de lags. Las líneas se mantienen prácticamente horizontales, lo que confirma que añadir retornos de días anteriores casi no modifica el error de predicción.




Figura 21. Evolución del RMSE diario de Random Forest por ETF según el número de lags utilizado

Una vez seleccionado *Random Forest* con 0 lags, se analizan sus resultados por grupos de ETFs. La tabla 18 muestra el error medio de cada grupo y el número de ETFs que superan al modelo base y al modelo *zeros*.

Grupo	N	RMSE RF	RMSE BASE	RMSE ZEROS	MAE RF	Bate base	Bate zeros
Core US	10	0,01236	0,01725	0,01236	0,00810	10/10	6/10
Factores	11	0,01106	0,01623	0,01105	0,00738	11/11	7/11
Sectores	11	0,01221	0,01714	0,01221	0,00856	11/11	3/11
Internacional	15	0,01209	0,01673	0,01210	0,00848	15/15	9/15
Renta fija	8	0,00376	0,00521	0,00378	0,00280	8/8	3/8
Materias primas	3	0,02029	0,02775	0,02021	0,01340	3/3	1/3

Tabla 18. Resultados medios por grupo de activos del modelo Random Forest diario con 0 lags y comparación frente a los modelos *baseline* y *zeros*

Los resultados por grupos siguen un patrón parecido al observado en ARIMA: la renta fija presenta los errores más bajos y las materias primas los más altos. Por tanto, las diferencias de RMSE dependen mucho del nivel de variación de cada tipo de activo.

Random Forest supera al *baseline* en todos los ETFs, pero los resultados frente al modelo *zero* son más variados. El grupo internacional obtiene el mejor resultado, habiendo 9 de 15 ETFs que superan a *zero*,

seguido de Factores, con 7 de 11, y Core US, con 6 de 10. En los demás grupos, la mejora aparece en menos activos.

En conjunto, *Random Forest* con 0 lags tiene el mejor rendimiento en frecuencia diaria. Sin embargo, sus resultados son casi iguales a los del modelo *zero*, por lo que la mejora que aporta este modelo es muy pequeña.

Resultados del modelo semanal

Las Tablas 19 y 20 muestran el RMSE y el MAE medios respectivamente, obtenidos por cada uno de los 4 modelos según el número de *lags* utilizados.

Lags	RMSE Reg. Lin.	RMSE Ridge	RMSE RF	RMSE GBR	RMSE base	RMSE Zeros
0	0,00784	0,00490	0,00491	0,00494	0,00717	0,00494
1	0,01437	0,00492	0,00492	0,00491	0,00717	0,00494
2	0,02840	0,00492	0,00491	0,00493	0,00717	0,00494
3	0,01782	0,00492	0,00492	0,00491	0,00717	0,00494
4	0,01419	0,00492	0,00493	0,00498	0,00717	0,00494

Tabla 19. RMSE medio en test de los modelos de aprendizaje automático en frecuencia semanal según el número de lags utilizado

Lags	MAE Reg. Lin.	MAE Ridge	MAE RF	MAE GBR	MAE base	MAE Zeros
0	0,00605	0,00365	0,00367	0,00372	0,00539	0,00369
1	0,01064	0,00366	0,00368	0,00367	0,00539	0,00369
2	0,02047	0,00367	0,00366	0,00369	0,00539	0,00369
3	0,01400	0,00366	0,00367	0,00366	0,00539	0,00369
4	0,01127	0,00366	0,00367	0,00378	0,00539	0,00369

Tabla 20. MAE medio en test de los modelos de aprendizaje automático en frecuencia semanal según el número de lags utilizado

Ridge, *Random Forest* y *Gradient Boosting* presentan resultados muy parecidos en todas las configuraciones. Igual que en el análisis diario, añadir retornos de semanas anteriores no mejora de forma clara la predicción, ya que el error se mantiene casi igual o aumenta ligeramente entre 0 y 4 *lags*. De nuevo, la regresión lineal muestra un comportamiento diferente. Al añadir retardos, su error aumenta de forma considerable, especialmente con 2 *lags*.

Además, *Ridge*, *Random Forest* y *Gradient Boosting* superan al *baseline* en todas las configuraciones y también obtienen un error algo menor que el modelo *zero*, algo que no ocurría en el análisis diario.

Ridge con 0 *lags* obtiene el menor RMSE, con un valor de 0,00490, y el menor MAE, con 0,00365. También supera al *baseline* en los 58 ETFs y al modelo *zero* en 44 de ellos. Por ello, se selecciona como la mejor configuración semanal de aprendizaje automático.

La Figura 22 muestra la evolución del RMSE de *Ridge* para cada ETF al aumentar el número de *lags*. Al igual que en el modelo diario, las líneas se mantienen casi horizontales, lo que confirma que añadir retornos de semanas anteriores casi no cambia el error y apoya la elección de la configuración sin *lags*.




Figura 22. Evolución del RMSE semanal de Ridge por ETF según el número de lags utilizado

Los resultados por grupo de activos con Ridge 0 lags los observamos en la Tabla 21:

Grupo	N	RMSE Ridge	RMSE BASE	RMSE ZEROS	MAE Ridge	Bate base	Bate zeros
Core US	10	0,00507	0,00782	0,00514	0,00380	10/10	10/10
Factores	11	0,00455	0,00698	0,00462	0,00339	11/11	11/11
Sectores	11	0,00519	0,00773	0,00521	0,00394	11/11	7/11
Internacional	15	0,00550	0,00766	0,00550	0,00415	15/15	11/15
Renta fija	8	0,00186	0,00271	0,00186	0,00139	8/8	3/8
Materias primas	3	0,00974	0,01319	0,00975	0,00656	3/3	2/3

Tabla 21. Resultados medios por grupo de activos del modelo Ridge semanal con 0 lags y comparación frente a los modelos *baseline* y *zeros*

Los resultados por grupos mantienen el patrón observado anteriormente: la renta fija presenta el RMSE más bajo y las materias primas el más alto. La principal mejora aparece frente al modelo *zero*, ya que todos los ETFs de Core US y Factores consiguen superarlo. Sectores e Internacional muestran resultados intermedios, mientras que en renta fija solo 3 de 8 ETFs mejoran a *zero*, debido a que sus retornos suelen estar muy próximos a ese valor. En conjunto, Ridge con 0 lags supera al *baseline* en todos los ETFs y al modelo *zero* en la mayoría de ellos.

Comparación entre frecuencia semanal y diaria

El mejor resultado diario corresponde a *Random Forest* con 0 lags, mientras que en frecuencia semanal destaca *Ridge* con 0 lags. Ambos mejoran claramente al *baseline*, pero la diferencia principal aparece frente al modelo *zero*. En diario, *Random Forest* obtiene resultados prácticamente iguales a esta referencia. En cambio, *Ridge* semanal consigue mejorar ligeramente tanto el RMSE como el MAE y supera al modelo *zero* en 44 de los 58 ETFs. Por ello, *Ridge* con 0 lags en frecuencia semanal se selecciona como el mejor modelo de aprendizaje automático para estos datos.

4.3 Comparación entre ML y Series Temporales y selección del modelo predictor para Markowitz

En los apartados anteriores se seleccionó el mejor modelo de cada enfoque: ARIMA semanal para las series temporales y *Ridge* semanal con 0 lags para el aprendizaje automático. Ambos parten de las mismas condiciones: frecuencia semanal, mismo periodo de prueba y los mismos 58 ETFs.

ARIMA semanal

De los 58 ETFs analizados, ARIMA semanal obtiene un RMSE menor que el modelo *zero* en 30. Los resultados medios, como hemos visto antes, son:

Modelo	RMSE medio	MAE medio
ARIMA	0,00492	0,00365
<i>Baseline</i> (t-1)	0,00714	0,00537
<i>Zeros</i>	0,00492	0,00367

Tabla 22. Errores medios en test del modelo ganador de series temporales: ARIMA semanal y de los modelos de referencia *baseline* y *zeros*

Los resultados de la Kappa de Cohen (Figura 23) son más favorables que los obtenidos con Ridge (Figura 24). 21 de los 58 ETFs presentan una Kappa negativa, mientras que en los 37 restantes ARIMA acierta la dirección semanal mejor que una elección al azar.




Figura 23. Valores de Kappa de Cohen por ETF para el modelo ARIMA semanal, utilizados para evaluar si el modelo acierta la dirección del retorno mejor que el azar

Ridge 0 lags semanal

Ridge obtiene un RMSE menor que el modelo *zero* en 44 de los 58 ETFs. Las métricas medias de este conjunto son:

Modelo	RMSE medio	MAE medio
Ridge (0 lags)	0,00490	0,00365
Baseline (t-1)	0,00717	0,00539
Zeros	0,00494	0,00369

Tabla 23. Errores medios en test del modelo ganador de ML: Ridge semanal con 0 lags y de los modelos de referencia baseline y zeros

Sin embargo, los resultados de Kappa son menos favorables. Solo 13 de los 58 ETFs tienen una Kappa positiva. En los 45 restantes, el modelo no acierta la dirección mejor que el azar.

Esto muestra que un RMSE bajo no significa que el signo de la predicción sea correcto. El RMSE mide cuánto se aleja la predicción del valor real, pero no indica si ambos tienen el mismo signo. Como los retornos suelen estar cerca de *zero*, Ridge puede obtener un error bajo, aunque no acierte si el ETF sube o baja. Por eso, la Kappa permite completar el análisis y comprobar si la dirección predicha es correcta.




Figura 24. Valores de Kappa de Cohen por ETF para el modelo Ridge semanal con 0 lags, ordenados de mayor a menor

Comparativa final de los modelos

Aunque Ridge obtiene un RMSE ligeramente menor que ARIMA, ARIMA presenta mejores resultados al predecir la dirección del retorno: obtiene una Kappa positiva en 37 de los 58 ETFs, mientras que Ridge solo en 13 de 58.

Este resultado es importante para Markowitz, ya que el modelo utiliza los retornos esperados para repartir el peso de la cartera. Si se predice una subida, el optimizador puede asignar más peso a ese activo. Si el signo es incorrecto, la cartera puede aumentar la inversión en un ETF que finalmente baja o reducirla en uno que sube. Por ello, para esta aplicación no solo importa que el error sea pequeño, sino también acertar la dirección del movimiento.

Una posible explicación del mejor resultado direccional de ARIMA es que sus componentes de media móvil utilizan errores anteriores para ajustar nuevas predicciones. Estos errores pueden reflejar parte del efecto de noticias o cambios externos que no se incluyen directamente en los datos. Además, mediante el proceso *walk-forward*, el modelo se actualiza cada semana con la nueva información. Ridge con 0 lags, en cambio, no utiliza directamente el error de la predicción anterior. Esta diferencia puede ser la explicación de por qué ARIMA capta mejor algunos cambios de dirección.

Por estos motivos, se selecciona ARIMA semanal como predictor para la optimización de Markowitz. En el apartado siguiente se explica cómo se utilizan sus predicciones para construir y evaluar la cartera.

Capítulo 5 - OPTIMIZACIÓN DE CARTERAS - MARKOWITZ

Como se explicó en el capítulo de preliminares, el modelo de Markowitz reparte el capital entre distintos activos teniendo en cuenta dos elementos: la rentabilidad que se espera obtener y el riesgo de la cartera. Busca una combinación de activos que permita obtener una buena rentabilidad para un nivel de riesgo dado. A partir de estos valores, el modelo calcula los pesos, es decir, el porcentaje del capital que debe invertirse en cada ETF. En este capítulo se aplica este método a los activos estudiados anteriormente.

La rentabilidad esperada es el retorno que se estima para cada ETF durante la semana siguiente. Para calcularla se comparan tres estrategias: la media histórica, el retorno de la última semana y la predicción de ARIMA.

El riesgo se calcula a partir de los retornos anteriores y tiene en cuenta tanto la variación de cada ETF como la relación entre ellos. Las tres estrategias utilizan los mismos 58 ETFs, el mismo periodo y la misma frecuencia semanal para que la comparación se realice en las mismas condiciones.

5.1 Estrategias comparadas

Se evalúan tres estrategias de Markowitz que utilizan distintas formas de calcular el retorno esperado μ de la semana siguiente. En todas se mantienen el mismo cálculo del riesgo y las mismas restricciones, por lo que las diferencias en los resultados se deben únicamente a la forma de estimar el retorno.

Estrategia 1: Markowitz con media histórica

En esta estrategia, el retorno esperado de cada ETF se calcula como la media de todos sus retornos semanales anteriores, donde:

$$\mu_{i,t+1} = \frac{1}{T} \sum_{s=1}^T r_{i,s}$$

$\mu_{i,t+1}$ es el retorno esperado del ETF i para la semana siguiente.

$r_{i,s}$ es el retorno semanal del ETF i en la semana s .

T es el número de semanas disponibles hasta ese momento.

Esta estimación utiliza toda la información histórica disponible, por lo que suele ser estable y cambia poco entre semanas. Sin embargo, tarda más en reflejar los cambios recientes del mercado, ya que los retornos antiguos tienen el mismo peso que los más actuales. Esta estrategia se utiliza como referencia porque es una forma sencilla y habitual de calcular el retorno esperado en Markowitz [1].

Estrategia 2: Markowitz con último valor observado

Esta estrategia sigue la misma idea que el modelo de referencia basado en el último valor observado utilizado en el capítulo anterior, pero aplicada ahora al proceso de optimización de carteras. En lugar de utilizar el último retorno como predicción para evaluar un modelo, se emplea como estimación del retorno esperado que necesita el modelo de Markowitz. En este caso, se utiliza el retorno de la última semana como estimación para la semana siguiente:

$$\mu_{i,t+1} = r_{i,t}$$

Por tanto, se supone que el ETF continuará con el mismo comportamiento que tuvo en la semana anterior. Si el último retorno fue positivo, se espera una nueva subida; si fue negativo, se espera una bajada.

Esta estrategia responde de forma rápida a los cambios del mercado, pero también es muy sensible a movimientos puntuales. Un cambio muy fuerte en una semana puede hacer que el optimizador modifique bastante la distribución de la cartera, aunque ese comportamiento haya sido puntual y no continúe la semana siguiente.

Estrategia 3: Markowitz con predicciones ARIMA

En esta estrategia, el retorno esperado de cada ETF se obtiene a partir de la predicción del modelo ARIMA semanal correspondiente a ese ETF. Conviene recordar que no se utiliza un único modelo ARIMA común para todos los activos, sino que cada ETF tiene sus propios parámetros (p) y (q), seleccionados de forma individual en el capítulo anterior. Las predicciones se generan mediante *walk-forward*, por lo que en cada momento solo se utilizan datos anteriores.

5.2 Matriz de covarianzas

La matriz de covarianzas permite calcular el riesgo de la cartera. Por una parte, recoge cuánto varían los retornos de cada ETF. Por otra, muestra si dos activos suelen moverse en la misma dirección o de forma

diferente. Esta relación es importante porque combinar ETFs que no se comportan igual puede reducir el riesgo total de la cartera.

Al trabajar con 58 ETFs, hay que calcular 58 x 58 relaciones diferentes a partir de un número limitado de semanas. Por ello, algunas estimaciones pueden cambiar mucho por movimientos puntuales del mercado. Como Markowitz utiliza estas relaciones para calcular los pesos, pequeñas variaciones en la matriz pueden producir cambios importantes en la distribución de la cartera y hacer que se concentre demasiado capital en unos pocos activos.

Para conseguir una estimación más estable se utiliza el método de Ledoit-Wolf [21]. Este método parte de la matriz calculada con los datos históricos y suaviza las relaciones menos fiables entre activos. De esta forma se reduce el ruido y se evita que el optimizador se apoye demasiado en valores extremos. Además, se aplica una corrección con *PyPortfolioOpt* para que la matriz cumpla las condiciones que necesita el optimizador.

La matriz se vuelve a calcular cada semana utilizando únicamente los retornos conocidos hasta ese momento. Así, la estimación del riesgo se actualiza con la nueva información sin utilizar datos futuros.

5.3 Formulación del problema de optimización

Como se explicó en el capítulo de preliminares, el modelo de Markowitz busca una combinación de activos que equilibre la rentabilidad esperada y el riesgo. En cada semana del *backtest*, es decir, de la simulación histórica de la cartera, se resuelve el siguiente problema de optimización:

$$\max_w (w^T \mu - \lambda w^T \Sigma w)$$

Los términos de esta expresión ya se explicaron anteriormente. En este capítulo, w contiene los pesos asignados a los 58 ETFs, μ recoge los retornos esperados calculados mediante cada una de las tres estrategias y Σ es la matriz de covarianzas estimada con el método Ledoit-Wolf.

La optimización debe cumplir varias restricciones. En primer lugar, la suma de los pesos debe ser igual a uno, por lo que todo el capital disponible se invierte en la cartera. Además, los pesos no pueden ser negativos, de modo que la cartera solo reparte el capital disponible entre los ETFs seleccionados, lo que simplifica el problema de optimización. Por último, ningún ETF puede superar el peso máximo fijado mediante el parámetro *MAX_WEIGHT*.

Este límite permite controlar la concentración de la cartera. Por ejemplo, si *MAX_WEIGHT* es igual a 0,10, ningún ETF puede representar más del 10 % del capital, por lo que la inversión debe repartirse entre al menos diez activos.

El parámetro λ , representado en el código mediante *RISK_AVERSION*, controla la importancia que se da al riesgo en el optimizador. Un valor bajo hace que el modelo se centre más en los ETFs con mayor retorno esperado, mientras que un valor alto favorece carteras con menor variación.

El problema planteado es un problema de optimización porque existen muchas formas posibles de repartir el capital entre los 58 ETFs y se busca la combinación de pesos que ofrece el mejor equilibrio entre rentabilidad esperada y riesgo, cumpliendo las restricciones establecidas. Para resolverlo se utiliza *PyPortfolioOpt*, una librería de *Python* que construye el problema matemático. A su vez, esta librería utiliza *OSQP*, un *solver* o programa encargado de realizar los cálculos numéricos necesarios para encontrar la mejor solución posible. *OSQP* se utiliza como primera opción porque está preparado para resolver este tipo de problemas de forma eficiente[22].

5.4 Funcionamiento del *backtest* semanal

El *backtest* simula cómo habría funcionado la cartera durante el periodo de prueba, comprendido entre 2024-W30 y 2026-W05. En total, se realizan 79 semanas de inversión. La cartera se actualiza una vez por semana. En cada semana se sigue el mismo proceso:

1. **Cálculo de la información disponible.** Se utilizan todos los retornos conocidos hasta esa semana para calcular la matriz de covarianzas. También se calcula el retorno esperado de cada ETF según la estrategia utilizada: media histórica, último retorno observado o predicción ARIMA.
2. **Cálculo de los pesos.** Markowitz utiliza los retornos esperados, la matriz de covarianzas, la aversión al riesgo y el peso máximo permitido para decidir qué porcentaje del capital debe asignarse a cada ETF.
3. **Inversión durante la semana siguiente.** Los pesos calculados se aplican a los retornos reales de la semana posterior. El retorno de la cartera se obtiene sumando el retorno de cada ETF multiplicado por su peso. Como los datos se encuentran en forma de retornos logarítmicos, primero se transforman en retornos simples.

4. **Actualización del capital.** El retorno obtenido se incorpora al capital disponible. El capital final de esa semana pasa a ser el capital inicial de la siguiente, se calculan métricas y el proceso vuelve a repetirse.

La cantidad de información histórica aumenta durante el *backtest*. En la primera decisión se dispone de los datos comprendidos entre 2021-W01 y 2024-W29. Después de cada semana, el nuevo retorno real se añade al historial y se utiliza en los siguientes cálculos. Por tanto, se emplea una ventana expandible.

La matriz de covarianzas se calcula una sola vez en cada semana y se utiliza en las tres estrategias. De esta forma, todas trabajan con la misma estimación del riesgo y las diferencias en los resultados dependen de la forma utilizada para calcular el retorno esperado.

5.5 Métricas de evaluación de estrategias

- **Capital final.** Indica el valor de la cartera al terminar el *backtest*, partiendo de un capital inicial de 100 euros. Cada semana, el capital se actualiza a partir del retorno obtenido por la cartera.
- **Rentabilidad acumulada.** Muestra el porcentaje total ganado o perdido durante todo el periodo de prueba. Se calcula comparando el capital final con el capital inicial:

$$\text{Rentabilidad acumulada} = \left(\frac{\text{Capital final}}{\text{Capital inicial}} - 1 \right) \times 100$$

- **Volatilidad anualizada.** Mide cuánto varía la cartera a lo largo del tiempo y expresa ese nivel de variación en términos anuales. Para calcular este valor, primero se obtiene el resultado semanal de la cartera teniendo en cuenta el peso asignado a cada ETF. Después, se obtiene la desviación típica de todos esos retornos semanales. Un valor bajo indica que la cartera tiene una evolución estable, mientras que un valor alto indica subidas y bajadas más fuertes. Finalmente, el resultado se multiplica por $\sqrt{52}$ para expresarlo en términos anuales. Aunque se presenta en escala anual, el cálculo utiliza todas las semanas del periodo de prueba.
- **Sharpe anualizado** Mide si la rentabilidad obtenida compensa el riesgo de la cartera. Primero se calcula la media de todos los retornos semanales obtenidos durante el periodo de prueba y se multiplica por 52 para expresarla en términos anuales. Después, este valor se divide entre la volatilidad anualizada de la cartera. En este trabajo se considera una tasa libre de riesgo igual a

cero. Un valor más alto indica que la cartera ha obtenido una mayor rentabilidad en relación con las variaciones que ha sufrido.

$$Sharpe = \frac{\bar{R}_{\text{semanal}} \times \sqrt{52}}{\sigma_{\text{semanal}}}$$

donde $\bar{R}_{\text{semanal}}$ es la media de los retornos semanales de la cartera y σ_{semanal} es su desviación típica semanal.

- **Máximo *drawdown*.** Representa la mayor caída de la cartera desde un valor máximo hasta el mínimo alcanzado después. Por ejemplo, un valor del -15% significa que, en el peor momento, la cartera perdió un 15 % respecto al máximo que había alcanzado. Cuanto más cerca de cero se encuentre, menor habrá sido la peor caída.

5.6 Registro de resultados en Google Sheets

Los resultados del *backtest* se guardan automáticamente en Google Sheets al finalizar la ejecución. Esto permite consultarlos, compararlos y analizarlos sin tener que volver a ejecutar el notebook. La información se organiza en un resumen general y en varias hojas con el detalle semanal.

Tras probar distintos valores de *MAX_WEIGHT* y *RISK_AVERSION*, se seleccionan cuatro configuraciones representativas de diferentes perfiles de cartera. Cada una se evalúa con las tres estrategias de retorno esperado, por lo que el resumen general contiene 12 resultados. Para cada combinación se guardan los parámetros utilizados, el periodo analizado y las métricas finales: capital inicial y final, rentabilidad acumulada, volatilidad anualizada, *Sharpe* anualizado, máximo *drawdown* y número de semanas positivas.

Además, para cada configuración se guarda una hoja con los resultados de cada semana y estrategia. Como el periodo de prueba contiene 79 semanas y se comparan tres estrategias, cada hoja incluye 237 registros. Cada registro contiene la configuración y la estrategia utilizadas, las semanas de decisión e inversión, la evolución del capital, el retorno de la cartera, la rentabilidad acumulada y el *drawdown*. También se guardan los pesos asignados a los 58 ETFs, los retornos estimados utilizados por el optimizador y los retornos reales del histórico. Esta información permite revisar cualquier semana del *backtest* y comprobar qué decisión tomó el optimizador y cuál fue el resultado obtenido.

5.7 Resultados Markowitz

El objetivo del análisis no es elegir únicamente la cartera con mayor rentabilidad, sino encontrar un buen equilibrio entre rentabilidad y riesgo. Por ello, los resultados se valoran principalmente mediante *Sharpe*, aunque también se considera la rentabilidad acumulada, la volatilidad y el máximo *drawdown*. Una cartera puede obtener una rentabilidad elevada, pero no ser la mejor opción si para conseguirla presenta cambios muy fuertes o grandes caídas.

Se estudian cuatro configuraciones representativas, que permiten aumentar de forma progresiva la concentración de la cartera y modificar la importancia del riesgo. Cada una se evalúa con las tres formas de calcular el retorno esperado: media histórica, último valor observado y predicciones ARIMA. En total, se obtiene la Tabla 24 con doce resultados, durante las 79 semanas del periodo de prueba y utilizando los mismos 58 ETF.

Config	Max Weight	Risk Aversion	Estrategia	Rent	Vol	Sharpe	Max Drawdown
Diversificada	10%	0.10	Media histórica	26.23 %	15.47 %	1.0701	-15.88 %
Diversificada	10%	0.10	Último valor	12.22 %	12.80 %	0.6573	-11.71 %
Diversificada	10%	0.10	ARIMA	22.96 %	12.85 %	1.1236	-12.11 %
Intermedia	20%	0.40	Media histórica	26.26 %	17.55 %	0.9639	-15.78 %
Intermedia	20%	0.40	Último valor	17.63 %	15.92 %	0.7509	-13.81 %
Intermedia	20%	0.40	ARIMA	18.78 %	13.65 %	0.8989	-15.07 %
Agresiva	30%	0.10	Media histórica	25.54 %	20.79 %	0.8253	-17.39 %
Agresiva	30%	0.10	Último valor	19.47 %	20.64 %	0.6697	-21.82 %
Agresiva	30%	0.10	ARIMA	21.19 %	15.46 %	0.8960	-16.44 %
Muy concentrada	50%	0.10	Media histórica	18.30 %	27.20 %	0.5421	-17.37 %
Muy concentrada	50%	0.10	Último valor	17.35 %	25.74 %	0.5365	-24.87 %
Muy concentrada	50%	0.10	ARIMA	11.40 %	18.94 %	0.4703	-18.92 %

Tabla 24. Resultados del backtest de las carteras de Markowitz para las cuatro configuraciones de cartera y las tres estrategias de estimación del retorno esperado, evaluadas mediante rentabilidad, volatilidad, Sharpe y máximo drawdown

Los resultados de la Tabla 24 muestran que el peso máximo permitido por ETF influye de forma clara en el comportamiento de las carteras. Cuando este valor es bajo, el capital debe repartirse entre un mayor número de activos, lo que mantiene la diversificación y evita que el resultado dependa demasiado de un único ETF. En cambio, al aumentar el peso máximo, el optimizador puede concentrar una parte mayor del capital en pocos activos. Si la estimación del retorno esperado no se cumple, el efecto negativo sobre la cartera también es mayor.

Este patrón se observa especialmente en ARIMA. Como sus predicciones suelen ser pequeñas y parecidas entre los ETFs, funcionan mejor para realizar pequeños ajustes en una cartera diversificada que para hacer una inversión elevada en un solo activo. En la configuración diversificada, con un peso máximo del 10 % y una aversión al riesgo de 0,10, ARIMA obtiene el mayor valor *Sharpe* de todas las configuraciones, con un valor de 1,124. Aunque la media histórica alcanza la mayor rentabilidad, ARIMA presenta una volatilidad y una caída máxima (*Max Drawdown*) menores, por lo que ofrece una mejor relación entre rentabilidad y riesgo.

En la configuración intermedia, con un peso máximo del 20 % y una aversión al riesgo de 0,40, la media histórica obtiene el mayor *Sharpe* y la mayor rentabilidad. sus estimaciones de retorno son suficientemente grandes para orientar los pesos y el tener un valor más alto de aversión al riesgo evita una concentración excesiva. ARIMA mantiene una volatilidad menor, pero también consigue una rentabilidad más baja, por lo que no llega a superar a la media histórica.

En la configuración agresiva, con un peso máximo del 30 % y una aversión al riesgo de 0,10, ARIMA vuelve a obtener el mayor *Sharpe*. La media histórica consigue una rentabilidad más alta, pero también presenta una volatilidad mucho mayor. En este caso, la menor variación de la cartera ARIMA compensa su menor rentabilidad y permite obtener una mejor relación entre ambos valores.

Los peores resultados aparecen en la configuración muy concentrada, que permite asignar hasta el 50 % del capital a un solo ETF. En este caso se pierde gran parte de la diversificación y las tres estrategias empeoran. ARIMA es la más perjudicada, si el ETF seleccionado no se comporta como se esperaba, la pérdida afecta a una parte demasiado grande de la cartera. En esta configuración, la estrategia del último valor supera a ARIMA en rentabilidad y *Sharpe*. El retorno de la semana anterior suele tener una magnitud mayor en estimación de retornos comparado con las otras dos estrategias y puede llevar al optimizador a realizar apuestas más claras y concentradas. Si la tendencia de cada ETF continúa, la cartera puede obtener una ganancia elevada. Sin embargo, esta estrategia también presenta una volatilidad alta y el

peor *drawdown*, lo que muestra que depender únicamente del último movimiento produce resultados poco estables.

En general, la media histórica obtiene la mayor rentabilidad acumulada en las cuatro configuraciones. Como se calcula con todos los datos anteriores, sus estimaciones cambian poco entre semanas y suelen favorecer a los activos con mejor comportamiento pasado. Cuando aumenta el peso máximo permitido, el optimizador puede concentrar más capital en esos activos, lo que reduce la diversificación y aumenta la volatilidad de la cartera.

La estrategia basada en el último valor es la más sensible a los movimientos puntuales. Después de una fuerte subida puede aumentar el peso de un ETF justo antes de una corrección y, después de una caída, puede reducirlo antes de una recuperación. Esto explica que presente los valores de *Sharpe* más bajos en todas las configuraciones.

ARIMA obtiene una rentabilidad superior al último valor en las configuraciones diversificada, intermedia y agresiva. Además, presenta una volatilidad menor que la media histórica en todos los casos y menor que la del último valor en tres de las cuatro configuraciones. Su principal ventaja no es conseguir siempre la mayor rentabilidad, sino construir carteras más estables y con una mejor relación entre rentabilidad y riesgo.

Para comprobar si este comportamiento se mantiene con otros valores de los parámetros, se realiza un análisis de sensibilidad con las tres estrategias. Para ello, se prueban distintos niveles de aversión al riesgo y diferentes pesos máximos por activo. Al aumentar la aversión al riesgo, Markowitz da más importancia a reducir la variación de la cartera y menos al retorno esperado. En ARIMA, esto reduce ligeramente la volatilidad, pero también disminuye la rentabilidad, ya que sus predicciones pequeñas influyen menos en el reparto de los pesos. Como la pérdida de rentabilidad es mayor que la reducción de la volatilidad, *Sharpe* también empeora. El efecto del peso máximo es más claro: con límites bajos las carteras están más diversificadas, mientras que una mayor concentración aumenta la volatilidad y las caídas. En conjunto, el peso máximo influye más que la aversión al riesgo.

Entre las doce combinaciones analizadas en la Tabla 24, ARIMA con la configuración diversificada obtiene el mayor valor de *Sharpe*. Aunque no alcanza la rentabilidad más alta, mantiene un resultado elevado con una de las volatilidades más bajas y una de las menores caídas máximas. Por ello, es la alternativa que ofrece el mejor equilibrio entre rentabilidad y riesgo durante el periodo estudiado.

Capítulo 6 - CONCLUSIONES Y TRABAJO FUTURO

6.1 Conclusiones generales

En este trabajo se ha estudiado y analizado si los modelos de series temporales y de aprendizaje automático pueden aportar información útil para predecir retornos de un conjunto de ETFs. El objetivo no ha sido demostrar que los mercados puedan predecirse con exactitud, sino comprobar si una señal predictiva podía tener valor práctico al aplicarse en una decisión de inversión.

Los resultados mostraron que la predicción de retornos financieros sigue siendo un problema difícil. Los retornos suelen ser pequeños, inestables y con movimientos difíciles de explicar sólo a partir de los datos históricos. Además, los retornos pueden verse afectados por factores externos que no se incluyen directamente en los modelos, como noticias económicas, cambios políticos, etc. Por ello, a lo largo del trabajo se ha visto que no basta con evaluar los modelos sólo mediante métricas clásicas como RMSE o MAE, sino que también es importante analizar si sus predicciones ayudan a tomar mejores decisiones dentro de una cartera.

En este sentido, hemos encontrado que la frecuencia semanal resulta más adecuada que la diaria, ya que reduce parte del ruido de los datos y permite obtener señales algo más estables. Además, la comparación entre modelos muestra que el modelo con menor error no tiene por qué ser el más útil para la optimización de carteras. Aunque *Ridge* presenta un error ligeramente menor, ARIMA ofrece mejores resultados al predecir mejor la dirección del movimiento, lo que también es importante cuando las predicciones se usan para repartir los pesos de una cartera.

La posterior aplicación en el método de Markowitz para la elaboración de carteras confirma esta idea. Las predicciones de ARIMA son pequeñas y no permiten anticipar grandes movimientos, pero sí ayudan a orientar el reparto entre activos cuando la cartera está suficientemente diversificada. En cambio, cuando se limita el peso máximo por ETF, la cartera depende menos de un único activo y las pequeñas señales del modelo pueden aprovecharse mejor. Esto permite obtener mejores resultados que la estrategia clásica, que utiliza la media histórica como estimación del retorno futuro.

Como conclusión final, el trabajo muestra que los modelos predictivos pueden aportar información útil, aunque la predicción de retornos financieros siga siendo limitada. La comparación realizada permite ver que no solo importa reducir el error, sino también entender qué tipo de señal genera cada modelo y cómo esa señal puede aprovecharse después. Por tanto, el valor principal del trabajo está en conectar la

evaluación de los modelos con su utilidad práctica en una decisión de inversión, mostrando que una señal pequeña puede ayudar a construir una cartera con mejor equilibrio entre rentabilidad y riesgo.

6.2 Trabajo futuro

Como continuación de este trabajo, una primera línea sería ampliar el universo de inversión. En este caso se ha trabajado con un conjunto concreto de ETFs, pero en futuros estudios podrían incluirse más fondos, acciones individuales u otros activos. Esto permitiría analizar si el comportamiento observado también aparece al trabajar con una cartera más amplia y con más alternativas de inversión.

Otra posible mejora sería añadir variables externas. En este trabajo se han utilizado principalmente precios, retornos y volumen, pero los mercados también dependen de otros factores, como los tipos de interés, la inflación, la volatilidad del mercado, los indicadores económicos o las noticias financieras. Estos datos podrían obtenerse mediante bases de datos económicas, APIs financieras o técnicas de *web scraping*. En ese caso, habría que controlar bien la fecha en la que cada dato estuvo disponible, para no utilizar información futura en el entrenamiento o en el *backtest*.

También se podría estudiar una selección de modelos por grupos de activos. En este trabajo se selecciona un modelo principal para aplicarlo al conjunto global de ETFs, pero los resultados muestran que algunos modelos funcionan mejor en determinados grupos. Por ejemplo, en algunos sectores o mercados internacionales, Ridge presenta una mayor capacidad para predecir los retornos que ARIMA. Por ello, en futuros estudios podría construirse una estrategia híbrida, utilizando el modelo más adecuado para cada grupo de activos. Esto permitiría aprovechar mejor las ventajas de cada método y comprobar si una selección por grupos mejora los resultados de la cartera.

Además, se podrían probar modelos más avanzados, como *XGBoost* o redes neuronales. Estos modelos podrían captar relaciones más complejas entre las variables. En este caso, la evaluación no debería centrarse solo en reducir el RMSE, sino también en comprobar si estos modelos mejoran la predicción de la dirección del retorno, ya que esta característica ha sido importante para la construcción de la cartera.

Desde el punto de vista de la evaluación, sería interesante complementar los resultados puntuales con intervalos de confianza. Esto permitiría valorar si un método es realmente mejor que otro desde el punto de vista estadístico.

Además, se podría repetir el análisis con otras frecuencias y horizontes de predicción. Por ejemplo, podrían estudiarse retornos mensuales o datos intradía, como datos por hora durante la sesión de

mercado. También podrían probarse otros métodos de construcción de carteras además de Markowitz, como Black-Litterman, que permite combinar la información del mercado con las predicciones del modelo.

El *backtest* podría hacerse más realista incorporando costes de transacción y límites a los cambios de pesos entre semanas. Esto permitiría comprobar si las estrategias siguen siendo útiles cuando se tienen en cuenta los costes de comprar, vender y rebalancear la cartera.

Finalmente, sería interesante evaluar los modelos con datos que no hayan formado parte del trabajo. Una vez terminado el estudio, se podrían generar nuevas predicciones posteriores al periodo de *test* utilizado y compararlas con los retornos que se observen después en el mercado. Esto permitiría comprobar si los modelos mantienen su utilidad en datos completamente nuevos y en una situación más cercana al uso real.

Chapter 1 - INTRODUCTION

1.1 Motivation

Predicting the behaviour of financial markets is one of the most studied problems in finance and, at the same time, one of the most difficult to solve. Asset prices depend on many factors, such as the economic situation, political decisions, company results, international events and investors' expectations. Many of these elements are difficult to measure and cannot always be included directly in a model. This reduces the ability of any model to predict the future evolution of assets accurately.

This difficulty is even greater in the case of financial returns. Returns usually have values very close to zero, their behaviour changes depending on the period, and they often have little relationship with their past values. For this reason, the fact that an asset has gone up or down on one day does not usually provide much information about what it will do on the following day.

In this context, this work analyses whether it is possible to obtain predictive information from returns, using a broad set of ETFs as a case study. Exchange-traded funds, commonly known as ETFs, are financial assets that can be bought and sold during the trading session in a similar way to stocks. Unlike traditional investment funds, ETFs are traded on the market throughout the day. The choice of ETFs makes it possible to work with diversified assets of different types, such as equities, fixed income, economic sectors, international markets and commodities. To study the prediction problem, two approaches are compared: time series models and machine learning models. The former analyse each ETF based on its own individual history, while the latter can include more variables, such as information from other assets, volume or temporal signals.

The work is not limited to measuring the error of the predictions. The final objective is to check whether these predictions can be useful in an investment decision, since a prediction with a lower error does not always lead to a better portfolio. The predictions are used as input in a portfolio optimization model based on Markowitz's theory [1], where they act as estimates of expected return. In this way, the study makes it possible to analyse whether the use of predictions can improve portfolio construction compared with simpler portfolio construction strategies.

1.2 Objectives

The main objective of this work is to study, apply and compare time series and machine learning models for predicting ETF returns, and to analyse whether their predictions can later be used in the construction of a portfolio optimized through the Markowitz model.

To achieve this general objective, the following specific objectives are proposed:

- Download, process and prepare historical data from a broad set of ETFs grouped into different asset categories.
- Build daily and weekly *datasets* to study return prediction at two different frequencies: daily and weekly.
- Apply ARIMA time series models to predict the returns of each ETF individually.
- Apply machine learning models by adding new variables specific to each frequency.
- Evaluate the models using *walk-forward* validation, retraining at each step with the information available up to that moment.
- Analyse whether the incorporation of information from previous periods, through different numbers of temporal lags, improves the predictions of the machine learning models.
- Compare the models using error metrics such as RMSE (Root Mean Square Error) and MAE (Mean Absolute Error), against simple reference models, such as the last observed value or the prediction of zero return.
- Select the predictive model with the best performance based on the results obtained.
- Incorporate the selected predictions into the Markowitz model to build and optimize the portfolio.
- Compare the prediction portfolio with two reference strategies, one based on the historical mean and another based on the last observed return, in order to assess whether the predictions make it possible to obtain better investment results.

1.3 Work plan

The development of the work has been organized into four main phases, following a progressive order from data preparation to the final evaluation of the portfolios. This structure makes it possible to advance in an organized way and connect each part of the work with the next one.

- The first phase corresponds to data preprocessing and initial analysis. In this stage, the historical data of the ETFs are downloaded, their structure is reviewed and the variables needed for the study are built. Returns are also calculated, the stationarity of the series is analysed, and an initial descriptive analysis is carried out using statistics and graphs. The aim of this phase is to understand the general behaviour of the assets before applying prediction models.
- The second phase focuses on return modelling. In this part, time series models and machine learning models are applied, using both daily and weekly data. For time series, ARIMA models are used, while in the case of machine learning, models such as Ridge, Random Forest and Gradient Boosting are tested. In addition, the results are compared against base models, such as the prediction of the last observed value or the prediction of zero return. This phase makes it possible to identify which approach offers better results for the problem considered.
- The third phase corresponds to portfolio optimization using the Markowitz model. Once the most suitable predictions have been selected, they are used as expected returns within an investment portfolio. The aim of this phase is to check whether the predictions are useful not only from a statistical point of view, but also from an economic point of view, that is, whether they help to build a portfolio with better behaviour.
- Finally, the fourth phase is dedicated to writing the report and closing the work. In this stage, the results obtained are organized, the necessary tables and figures are prepared, the different chapters of the report are written and the final document is reviewed. The conclusions of the work, the limitations found and possible lines of improvement for future studies are also included. The chronology of the four phases can be seen in the next figure:

Optimización de carteras basada en la predicción de retornos mediante modelos de Machine Learning y Series Temporales

Universidad Complutense de Madrid
Master en Inteligencia Artificial
Alejandra Llord

Inicio del proyecto: mi, 17/2/2026
Semana para mostrar: 1
5 de enero de 2026

TAREA	PROGRESO	INICIO	FIN	1	2	3	4	5	6	7	8	9	10	11
Tarea 1: Revisión conceptos y planificación del proyecto	100%	7-1-26	14-1-26											
Tarea 2: Descarga y entendimiento de datos históricos de ETFs con gfinance	100%	7-1-26	21-1-26											
Tarea 3: Preprocesado: cálculo de retornos y test de estacionariedad	100%	14-1-26	28-1-26											
Tarea 4: Construcción de los datasets diario y semanal	100%	14-1-26	31-1-26											
Tarea 5: Análisis descriptivo de retornos y correlaciones	100%	21-1-26	31-1-26											
Fase 2: Modelización series temporales y ML (8 semanas)														
Tarea 1: Modelos ARIMA diarios con walk-forward, baseline y zeros	100%	1-2-26	28-2-26											
Tarea 2: Modelos ARIMA semanales con walk-forward, baseline y zeros	100%	14-2-26	14-3-26											
Tarea 3: Modelos de Machine Learning: Ridge, Random Forest y GBR	100%	1-3-26	21-3-26											
Tarea 4: Exploración de lags [0-4] como variables predictoras	100%	7-3-26	21-3-26											
Tarea 5: Comparación de modelos y selección del mejor	100%	21-3-26	31-3-26											
Fase 3: Optimización de carteras Markowitz (5 semanas)														
Tarea 1: Diseño del backtest semanal con walk-forward	100%	1-4-26	14-4-26											
Tarea 2: Implementación de las estrategias de Markowitz	100%	7-4-26	21-4-26											
Tarea 3: Evaluación de resultados	100%	21-4-26	7-5-26											
Tarea 4: Análisis comparativo entre las tres estrategias	100%	14-4-26	10-5-26											
Tarea 5: Interpretación de los resultados del backtest	100%	28-4-26	10-5-26											
Fase 4: Redacción de la memoria y cierre (10 semanas)														
Tarea 1: Redacción de introducción, datos y estado del arte	100%	1-4-26	15-5-26											
Tarea 2: Redacción de metodología y resultados	100%	1-5-26	31-5-26											
Tarea 3: Preparación de figuras, tablas y apéndices	100%	15-5-26	5-6-26											
Tarea 4: Revisión final del documento	100%	25-5-26	7-6-26											
Tarea 5: Entrega del borrador (12 de junio de 2026)	100%	7-6-26	12-6-26											

Timeline of the work plan followed during the development of the project, divided into four phases: data preparation, modelling, portfolio optimization and final writing

1.4 Technologies used

The whole analysis process was carried out in Python, using Jupyter Notebooks as the main development environment. The main libraries and tools used in each stage are described below.

- For data collection and manipulation, pandas and numpy were used. Historical price and volume data were downloaded using yfinance, which allows financial information to be obtained from Yahoo Finance.
- For descriptive analysis and visualization, matplotlib and seaborn were used. These libraries made it possible to generate histograms, *boxplots*, correlation matrices and result plots.
- The time series models, specifically the ARIMA models, were implemented with statsmodels. The machine learning models were developed with scikit-learn.

- Portfolio optimization was carried out with PyPortfolioOpt, a Python library that makes it possible to apply the Markowitz model. To calculate the risk between ETFs, the covariance matrix was estimated using the Ledoit-Wolf method. Afterwards, the optimization problem was solved with cvxpy and the OSQP solver.
- Google Sheets was used to store the machine learning experiments and the portfolio results. From Python, the spreadsheet was connected through the Google API and the gspread library. In this way, the model metrics and predictions, the investment weights and the evolution of each portfolio were recorded automatically. This made it easier to review and compare all the results.
- During the development of the work, generative artificial intelligence tools were used responsibly. These tools were used as support for programming, debugging and reviewing the writing. The code used in the work was reviewed, understood, adapted and integrated by the author.
- The developed code is available in the GitHub repository associated with the work:
<https://github.com/aleellord/TFM>
It includes the scripts and notebooks used for data download and preparation, model training and evaluation, and portfolio optimization.
- All the tables, graphs and figures included in this report are original work, generated from the data, experiments and results obtained during the development of the project.

Chapter 2 - CONCLUSIONS AND FUTURE WORK

2.1 General conclusions

In this work, it has been studied and analysed whether time series and machine learning models can provide useful information to predict the returns of a set of ETFs. The objective has not been to prove that markets can be predicted with complete accuracy, but to check whether a predictive signal can have practical value when applied to an investment decision.

The results showed that predicting financial returns remains a difficult problem. Returns are usually small, unstable and difficult to explain only from historical data. In addition, returns can be affected by external factors that are not directly included in the models, such as economic news or political changes. For this reason, throughout the work it has been shown that it is not enough to evaluate the models only with classical metrics such as RMSE or MAE. It is also important to analyse whether their predictions help to make better decisions within a portfolio.

In this sense, it has been found that the weekly frequency is more suitable than the daily frequency, since it reduces part of the noise in the data and makes it possible to obtain slightly more stable signals. In addition, the comparison between models shows that the model with the lowest error is not necessarily the most useful for portfolio optimization. Although Ridge presents a slightly lower error, ARIMA offers better results when predicting the direction of the movement, which is also important when the predictions are used to distribute the weights of a portfolio.

The later application of the Markowitz method for portfolio construction confirms this idea. ARIMA predictions are small and do not make it possible to anticipate large movements, but they do help to guide the allocation between assets when the portfolio is sufficiently diversified. When the maximum weight per ETF is limited, the portfolio depends less on a single asset and the small signals generated by the model can be used more effectively. This makes it possible to obtain better results than the classical strategy, which uses the historical mean as an estimate of future return.

As a final conclusion, this work shows that predictive models can provide useful information, although the prediction of financial returns remains limited. The comparison carried out shows that reducing the error is not the only important aspect. It is also important to understand what type of signal each model generates and how that signal can be used afterwards. Therefore, the main value of this work lies in

connecting the evaluation of the models with their practical use in an investment decision, showing that a small signal can help to build a portfolio with a better balance between return and risk.

2.2 Future work

As a continuation of this work, a first future line would be to expand the investment universe. In this study, a specific set of ETFs has been used, but future studies could include more funds, individual stocks or other assets. This would make it possible to analyse whether the behaviour observed also appears when working with a broader portfolio and more investment alternatives.

Another possible improvement would be to add external variables. In this work, prices, returns and volume have mainly been used, but markets also depend on other factors, such as interest rates, inflation, market volatility, economic indicators or financial news. These data could be obtained from economic databases, financial APIs or web scraping techniques. In that case, it would be necessary to carefully control the date on which each piece of information was available, in order to avoid using future information during training or in the backtest.

It would also be possible to study a model selection strategy by asset group. In this work, one main model is selected and applied to the whole set of ETFs, but the results show that some models work better in certain groups. For example, in some sectors or international markets, Ridge shows a better ability to predict the direction of the return than ARIMA. For this reason, future studies could build a hybrid strategy, using the most suitable model for each asset group. This would make it possible to take better advantage of each method and check whether a group-based selection improves the portfolio results.

In addition, more advanced models could be tested, such as XGBoost or neural networks. These models could capture more complex relationships between the variables. In this case, the evaluation should not focus only on reducing RMSE, but also on checking whether these models improve the prediction of the direction of the return, since this aspect has been important for portfolio construction.

From the point of view of evaluation, it would be interesting to complement the point results with confidence intervals. This would make it possible to assess whether one method is really better than another from a statistical point of view.

The analysis could also be repeated with other frequencies and prediction horizons. For example, monthly returns or intraday data, such as hourly data during the trading session, could be studied. Other portfolio

construction methods besides Markowitz could also be tested, such as Black-Litterman, which makes it possible to combine market information with the model predictions.

The backtest could be made more realistic by including transaction costs and limits on changes in portfolio weights between weeks. This would make it possible to check whether the strategies remain useful when the costs of buying, selling and rebalancing the portfolio are taken into account.

Finally, it would be interesting to evaluate the models with data that were not part of this work. Once the study is finished, new predictions could be generated after the test period and compared with the returns later observed in the market. This would make it possible to check whether the models remain useful with completely new data and in a situation closer to real use

BIBLIOGRAFÍA

- [1] H. Markowitz, "Portfolio Selection," *J. Finance*, vol. 7, no. 1, p. 77, Mar. 1952, doi: 10.2307/2975974.
- [2] R. Martin, "PyPortfolioOpt: portfolio optimization in Python," *J. Open Source Softw.*, vol. 6, no. 61, p. 3066, May 2021, doi: 10.21105/joss.03066.
- [3] E. F. Fama, "Efficient Capital Markets: A Review of Theory and Empirical Work," *J. Finance*, vol. 25, no. 2, p. 383, May 1970, doi: 10.2307/2325486.
- [4] N. JEGADEESH and S. TITMAN, "Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency," *J. Finance*, vol. 48, no. 1, pp. 65–91, Mar. 1993, doi: 10.1111/j.1540-6261.1993.tb04702.x.
- [5] W. F. M. De BONDT and R. THALER, "Does the Stock Market Overreact?," *J. Finance*, vol. 40, no. 3, pp. 793–805, Jul. 1985, doi: 10.1111/j.1540-6261.1985.tb05004.x.
- [6] R. Cont, "Empirical properties of asset returns: stylized facts and statistical issues," *Quant. Finance*, vol. 1, no. 2, pp. 223–236, Feb. 2001, doi: 10.1080/713665670.
- [7] G. L. . Gastineau, *The exchange-traded funds manual*. Wiley, 2010.
- [8] Investment Company Institute, "2025 Investment Company Fact Book," May 2026.
- [9] G. E. P. . Box, G. M. . Jenkins, and G. C. . Reinsel, *Time series analysis : forecasting and control*. Prentice Hall, 1994.
- [10] J. Douglas. Hamilton, *Time Series Analysis James D. Hamilton*. Princeton University Press, 2006.
- [11] J. Y. . Campbell, A. W. . Lo, and A. Craig. MacKinlay, *The econometrics of financial markets*. Princeton University Press, 1997.
- [12] H. Akaike, "A new look at the statistical model identification," *IEEE Trans. Automat. Contr.*, vol. 19, no. 6, pp. 716–723, Dec. 1974, doi: 10.1109/TAC.1974.1100705.
- [13] G. Schwarz, "Estimating the Dimension of a Model," *The Annals of Statistics*, vol. 6, no. 2, Mar. 1978, doi: 10.1214/aos/1176344136.

- [14] S. Gu, B. Kelly, and D. Xiu, "Empirical Asset Pricing via Machine Learning," *Rev. Financ. Stud.*, vol. 33, no. 5, pp. 2223–2273, May 2020, doi: 10.1093/rfs/hhaa009.
- [15] A. E. Hoerl and R. W. Kennard, "Ridge Regression: Biased Estimation for Nonorthogonal Problems," *Technometrics*, vol. 12, no. 1, pp. 55–67, Feb. 1970, doi: 10.1080/00401706.1970.10488634.
- [16] L. Breiman, "Random Forests," *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, Oct. 2001, doi: 10.1023/A:1010933404324.
- [17] J. H. Friedman, "Greedy function approximation: A gradient boosting machine.," *The Annals of Statistics*, vol. 29, no. 5, Oct. 2001, doi: 10.1214/aos/1013203451.
- [18] D. A. Dickey and W. A. Fuller, "Distribution of the Estimators for Autoregressive Time Series with a Unit Root," *J. Am. Stat. Assoc.*, vol. 74, no. 366a, pp. 427–431, Jun. 1979, doi: 10.1080/01621459.1979.10482531.
- [19] D. Kwiatkowski, P. C. B. Phillips, P. Schmidt, and Y. Shin, "Testing the null hypothesis of stationarity against the alternative of a unit root," *J. Econom.*, vol. 54, no. 1–3, pp. 159–178, Oct. 1992, doi: 10.1016/0304-4076(92)90104-Y.
- [20] G. M. LJUNG and G. E. P. BOX, "On a measure of lack of fit in time series models," *Biometrika*, vol. 65, no. 2, pp. 297–303, Aug. 1978, doi: 10.1093/biomet/65.2.297.
- [21] O. Ledoit and M. Wolf, "A well-conditioned estimator for large-dimensional covariance matrices," *J. Multivar. Anal.*, vol. 88, no. 2, pp. 365–411, Feb. 2004, doi: 10.1016/S0047-259X(03)00096-4.
- [22] B. Stellato, G. Banjac, P. Goulart, A. Bemporad, and S. Boyd, "OSQP: an operator splitting solver for quadratic programs," *Math. Program. Comput.*, vol. 12, no. 4, pp. 637–672, Dec. 2020, doi: 10.1007/s12532-020-00179-2.

APÉNDICES

Apéndice A - Registro de experimentos y resultados en Google Sheets

En este apéndice se recoge la organización de los archivos utilizados para guardar la traza de los experimentos de aprendizaje automático y de la cartera de Markowitz.

En concreto, se emplearon tres hojas principales:

- **Experimentos_diarios**, donde se almacenan los resultados de los modelos de aprendizaje automático entrenados con datos diarios.

https://docs.google.com/spreadsheets/d/1Qc1Q1OleSt1rMsGpo_xUQ90fhOG7RDeflyPn-cwVps0/edit?gid=1153965863#gid=1153965863

- **Experimentos_semanales**, donde se almacenan los resultados de los modelos de aprendizaje automático entrenados con datos semanales.

<https://docs.google.com/spreadsheets/d/17T0L6gza7vzD1vFh6OG2j3qOmlKCDRtFFu5HNma1Agk/edit>

- **Markowitz**, donde se guardan los resultados de las estrategias de optimización de carteras y la evolución de las carteras evaluadas.

<https://docs.google.com/spreadsheets/d/1SMWy1XzpUiMBZ0caEiQ9li6a2ZRU0kvjH5WQT8N4Rx4/edit?gid=0#gid=0>

Estas hojas permiten conservar una traza ordenada de las métricas obtenidas, las predicciones generadas, los pesos asignados a cada activo y los resultados de las carteras. De esta forma, fue posible revisar, comparar y recuperar los resultados sin tener que repetir todos los entrenamientos.

Además, los archivos de datos utilizados en el resto del proyecto se encuentran disponibles en formato CSV dentro de la carpeta **Datos_csv** del repositorio de código. Esta carpeta contiene los conjuntos de datos generados durante el preprocesado para ser utilizados posteriormente en los experimentos de series temporales y aprendizaje automático. Además, contiene los resultados de los modelos de series temporales, que por simplicidad para ellos no se creó una hoja de Google.