

OPTIMIZACIÓN DE CARTERAS BASADA EN LA
PREDICCIÓN DE RETORNOS MEDIANTE
MODELOS DE MACHINE LEARNING Y SERIES
TEMPORALES

DYNAMIC PORTFOLIO OPTIMIZATION BASED
ON RETURN FORECASTING USING TIME SERIES
AND MACHINE LEARNING MODELS



TRABAJO FIN DE MÁSTER
CURSO 2025-2026

AUTOR
ALEJANDRA LLORD MUÑOZ DE LA ESPADA

DIRECTOR
RAFAEL CABALLERO

MÁSTER EN INTELIGENCIA ARTIFICIAL
FACULTAD DE INFORMÁTICA
UNIVERSIDAD COMPLUTENSE DE MADRID

OPTIMIZACIÓN DE CARTERAS BASADA EN LA PREDICCIÓN DE RETORNOS MEDIANTE MODELOS DE MACHINE LEARNING Y SERIES TEMPORALES

DYNAMIC PORTFOLIO OPTIMIZATION BASED ON RETURN FORECASTING USING TIME SERIES AND MACHINE LEARNING MODELS

TRABAJO DE FIN DE MÁSTER EN INTELIGENCIA ARTIFICIAL
DEPARTAMENTO DE INFORMÁTICA

AUTOR
ALEJANDRA LLORD

DIRECTOR
RAFAEL CABALLERO

CONVOCATORIA: JUNIO 2026
CALIFICACIÓN:

MÁSTER EN INTELIGENCIA ARTIFICIAL
FACULTAD DE INFORMÁTICA
UNIVERSIDAD COMPLUTENSE DE MADRID

17 DE JUNIO DE 2026

DEDICATORIA

A Rafael,

porque un profesor como tú es difícil de encontrar

y tu pasión por enseñar, difícil de olvidar.

RESUMEN

Optimización de carteras basada en la predicción de retornos mediante modelos de Machine Learning y Series Temporales

Este trabajo estudia el uso de modelos predictivos para la construcción de carteras de inversión formadas por ETFs (Exchange Traded Funds), o fondos cotizados. Para ello, se analiza si la predicción de los retornos futuros de estos activos permite construir carteras con mejores resultados que las obtenidas mediante métodos tradicionales más sencillos, como la media histórica o el último valor observado.

El análisis parte de datos históricos de ETFs, a partir de los cuales se calculan retornos diarios y semanales. Esta doble frecuencia permite comparar una visión más inmediata del mercado con otra más estable y menos afectada por el ruido diario. Sobre ambas frecuencias se aplican modelos de series temporales y modelos de aprendizaje automático. En el primer caso se aplican modelos ARIMA a cada ETF de forma individual. En el segundo, se prueban modelos como Ridge, Random Forest y Gradient Boosting, incorporando información de varios activos, volumen y variables temporales.

Una vez comparados los modelos, las predicciones del mejor de ellos se incorporan a un proceso de optimización de carteras basado en Markowitz, donde se contrastan con las estrategias tradicionales descritas anteriormente. De este modo, el trabajo evalúa si las predicciones tienen utilidad no solo desde el punto de vista estadístico, sino también desde el económico.

Palabras clave

ETFs, Portfolio Optimization, Markowitz Model, Machine Learning, Time Series Forecasting, ARIMA, walk-forward, Backtesting

ABSTRACT

Dynamic portfolio optimization based on return forecasting using Time Series and Machine Learning

This thesis studies the use of predictive models for the construction of investment portfolios made up of ETFs (Exchange Traded Funds). The objective is to evaluate whether return forecasts for these ETFs can improve portfolio construction compared with simpler approaches, such as the historical mean or the last observed return.

The analysis starts from historical ETF data, from which daily and weekly returns are calculated. This double frequency makes it possible to compare a more immediate view of the market with a more stable one, less affected by daily noise. Time series models and machine learning models are applied to both frequencies. In the first case, ARIMA models are applied to each ETF individually. In the second, models such as Ridge, Random Forest and Gradient Boosting are tested, incorporating information from several assets, volume and temporal variables.

Once the models have been compared, the predictions from the best model are incorporated into a portfolio optimization process based on Markowitz, where they are contrasted with the traditional strategies described above. In this way, the work evaluates whether the predictions are useful not only from a statistical point of view, but also from an economic one.

Keywords

ETFs, Portfolio Optimization, Markowitz Model, Machine Learning, Time Series Forecasting, ARIMA, walk-forward, Backtesting

ÍNDICE DE CONTENIDOS

Dedicatoria.....	III
Resumen	V
Abstract.....	VI
Índice de contenidos.....	VII
Índice de figuras.....	X
Índice de tablas	XI
Capítulo 1 - INTRODUCCIÓN	1
1.1 Motivación.....	1
1.2 Objetivos.....	2
1.3 Plan de trabajo.....	3
1.4 Tecnologías utilizadas	4
Capítulo 2 - PRELIMINARES	7
2.1 Estado de la Cuestión	7
2.2 ETFs.....	7
2.3 Modelos de series temporales	8
2.4 Modelos de aprendizaje automático.....	10
2.4.1 Regresión lineal	10
2.4.2 Ridge.....	11
2.4.3 Random Forest	11
2.4.4 Gradient Boosting.....	12
2.5 Optimización de carteras y modelo de Markowitz.....	12
2.6 Métricas de evaluación.....	13
Capítulo 3 - DATOS.....	15

3.1 Descripción de los datos	15
3.1.1 Mercado estadounidense.....	15
3.1.2 Factores y estilos	15
3.1.3 Sectores económicos.....	16
3.1.4 Mercados internacionales	17
3.1.5 Renta fija (Bonos)	18
3.1.6 Materias primas y activos reales	19
3.2 Variables principales.....	19
3.3 Análisis descriptivo inicial	20
3.3.1 Estadística descriptiva	21
3.3.2 Histogramas.....	21
3.3.3 Boxplot	22
3.3.4 Matriz de correlaciones.....	24
3.3.5 Periodo de estudio y división temporal	25
Capítulo 4 - METODOS DE MODELIZACIÓN	26
4.1 Modelización mediante series temporales	26
4.1.1 Preprocesamiento de los datos.....	26
4.1.2 Modelo ARIMA	28
4.1.7 Resultados	36
4.1.3 Modelo semanal.....	39
4.2 Modelización mediante aprendizaje automático.....	43
4.2.1 Preprocesamiento de los datos.....	43
4.2.2 Selección de Modelos.....	46
4.2.3 Resultados	50
Capítulo 5 - OPTIMIZACIÓN DE CARTERAS - MARKOWITZ	58

5.1 Estrategias comparadas.....	58
Estrategia 1: Markowitz con media histórica.....	58
Estrategia 2: Markowitz con último valor observado	59
Estrategia 3: Markowitz con predicciones ARIMA	59
5.2 Matriz de covarianzas.....	59
5.3 Formulación del problema de optimización.....	60
5.4 Funcionamiento del <i>backtest</i> semanal.....	61
5.5 Métricas de evaluación de estrategias	62
5.6 Registro de resultados en Google <i>Sheets</i>	63
5.7 Resultados Markowitz	63
Capítulo 6 - Conclusiones y trabajo futuro	67
Chapter - Introduction	69
Chapter - Conclusions and future work	71
Bibliografía	73
Apéndices.....	75

ÍNDICE DE FIGURAS

Figura 3-1. Ejemplo de figura ¡Error! Marcador no definido.

ÍNDICE DE TABLAS

Tabla 3-1. Ejemplo de tabla ¡Error! Marcador no definido.

Capítulo 1 - INTRODUCCIÓN

1.1 Motivación

Predecir el comportamiento de los mercados financieros es uno de los problemas más estudiados y, al mismo tiempo, más difíciles de resolver en finanzas. Los precios de los activos dependen de muchos factores, como la situación económica, las decisiones políticas, los resultados de las empresas, los eventos internacionales o las expectativas de los inversores. Muchos de estos elementos son difíciles de medir y no siempre pueden incorporarse directamente a un modelo. Esto reduce la capacidad de cualquier modelo para predecir con precisión la evolución futura de los activos.

Esta dificultad es más alta en el caso de los retornos financieros. Los retornos suelen tener valores muy cercanos a cero, cambian de comportamiento según el periodo y tienen poca relación con sus valores pasados. Por ello, que un activo haya subido o bajado en un día no suele aportar mucha información sobre lo que hará en el siguiente.

En este contexto, este trabajo analiza si es posible obtener información predictiva a partir de los retornos de un conjunto amplio de ETFs. La elección de ETFs permite trabajar con activos diversificados y de distinto tipo, como renta variable, renta fija, sectores económicos, mercados internacionales y materias primas. Para estudiar el problema de predicción se comparan dos enfoques: modelos de series temporales y modelos de aprendizaje automático. Los primeros analizan cada ETF a partir de su propio histórico individual, mientras que los segundos pueden incorporar más variables, como información de otros activos, volumen o señales temporales.

El trabajo no se limita a medir el error de las predicciones. El objetivo final es comprobar si esas predicciones pueden ser útiles en una decisión de inversión, ya que una predicción con menor error no siempre implica una mejor cartera. Para ello, se incorporan a un modelo de optimización de carteras basado en Markowitz [1], donde se utilizan como estimaciones de rentabilidad esperada. De esta forma, el estudio permite analizar si el uso de predicciones puede mejorar la creación de una cartera en comparación a estrategias de construcción de carteras más sencillas.

1.2 Objetivos

El objetivo principal de este trabajo es estudiar, aplicar y comparar modelos de series temporales y aprendizaje automático para la predicción de retornos de ETFs, y analizar si sus predicciones pueden utilizarse posteriormente en la construcción de una cartera optimizada mediante el modelo de Markowitz.

Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

- Descargar, procesar y preparar datos históricos de un conjunto amplio de ETFs agrupados en distintas categorías de activos.
- Construir datasets diarios y semanales que permitan estudiar la predicción de retornos en dos frecuencias distintas.
- Aplicar modelos de series temporales ARIMA para predecir los retornos de cada ETF de forma individual.
- Aplicar modelos de aprendizaje automático añadiendo nuevas variables particulares por cada tipo de frecuencia.
- Evaluar los modelos mediante validación walk-forward, reentrenando en cada paso con la información disponible hasta ese momento.
- Analizar si la incorporación de información de periodos anteriores, mediante distintos números de retardos temporales (lags), mejora las predicciones de los modelos de aprendizaje automático.
- Comparar los modelos mediante métricas de error, RMSE y MAE, y frente a modelos de referencia simples, como el último valor observado y la predicción de retorno cero.
- Seleccionar el modelo predictivo con mejor rendimiento a partir de los resultados obtenidos.
- Incorporar las predicciones seleccionadas al modelo de Markowitz para construir y optimizar la cartera.
- Comparar la cartera basada en predicciones con dos estrategias de referencia, una basada en la media histórica y otra en el último retorno observado, para valorar si las predicciones permiten obtener mejores resultados de inversión.

1.3 Plan de trabajo

El desarrollo del trabajo se ha organizado en cuatro fases principales, siguiendo un orden progresivo desde la preparación de los datos hasta la evaluación final de las carteras. Esta estructura permite avanzar de forma ordenada y conectar cada parte del trabajo con la siguiente.

- La primera fase corresponde al **preprocesado y análisis inicial de los datos**. En esta etapa se descargan los datos históricos de los ETFs, se revisa su estructura y se construyen las variables necesarias para el estudio. También se calculan los retornos, se analiza la estacionariedad de las series y se realiza un primer análisis descriptivo mediante estadísticas y gráficos. El objetivo de esta fase es entender el comportamiento general de los activos antes de aplicar modelos de predicción.
- La segunda fase se centra en la **modelización de los retornos**. En esta parte se aplican modelos de series temporales y modelos de aprendizaje automático, tanto con datos diarios como con datos semanales. Para las series temporales se utilizan modelos ARIMA, mientras que en el caso del aprendizaje automático se prueban modelos como Ridge, Random Forest y Gradient Boosting. Además, se comparan los resultados frente a modelos base, como la predicción del último valor observado o la predicción de retorno cero. Esta fase permite identificar qué enfoque ofrece mejores resultados para el problema planteado.
- La tercera fase corresponde a la **optimización de carteras mediante el modelo de Markowitz**. Una vez seleccionadas las predicciones más adecuadas, estas se utilizan como rentabilidades esperadas dentro de una cartera de inversión. El objetivo de esta fase es comprobar si las predicciones no solo son útiles desde el punto de vista estadístico, sino también desde el punto de vista económico, es decir, si ayudan a construir una cartera con mejor comportamiento.
- Por último, la cuarta fase está dedicada a la **redacción de la memoria y cierre del trabajo**. En esta etapa se organizan los resultados obtenidos, se preparan las tablas y figuras necesarias, se redactan los distintos capítulos de la memoria y se revisa el documento final. También se incluyen las conclusiones del trabajo, las limitaciones encontradas y posibles líneas de mejora para futuros estudios.

Optimización de carteras basada en la predicción de retornos mediante modelos de Machine Learning y Series Temporales

Universidad Complutense de Madrid

Master en Inteligencia Artificial

Alejandra Llord

Inicio del proyecto: mi, 17/7/2026
Semana para mostrar: 1 5 de enero de 2026

TAREA	PROGRESO	INICIO	FIN	1	2	3	4	5	6	7	8	9	10	11
Tarea 1: Revisión conceptos y planificación del proyecto	100%	7-1-26	14-1-26											
Tarea 2: Descarga y entendimiento de datos históricos de ETFs con yfinance	100%	7-1-26	21-1-26											
Tarea 3: Preprocesado: cálculo de retornos y test de estacionariedad	100%	14-1-26	28-1-26											
Tarea 4: Construcción de los datasets diario y semanal	100%	14-1-26	31-1-26											
Tarea 5: Análisis descriptivo de retornos y correlaciones	100%	21-1-26	31-1-26											
Fase 2: Modelización series temporales y ML (8 semanas)														
Tarea 1: Modelos ARIMA diarios con walk-forward, baseline y zeros	100%	1-2-26	28-2-26											
Tarea 2: Modelos ARIMA semanales con walk-forward, baseline y zeros	100%	14-2-26	14-3-26											
Tarea 3: Modelos de Machine Learning: Ridge, Random Forest y GBR	100%	1-3-26	21-3-26											
Tarea 4: Exploración de lags [0-4] como variables predictoras	100%	7-3-26	21-3-26											
Tarea 5: Comparación de modelos y selección del mejor	100%	21-3-26	31-3-26											
Fase 3: Optimización de carteras Markowitz (5 semanas)														
Tarea 1: Diseño del backtest semanal con walk-forward	100%	1-4-26	14-4-26											
Tarea 2: Implementación de las estrategias de Markowitz	100%	7-4-26	21-4-26											
Tarea 3: Evaluación de resultados	100%	21-4-26	7-5-26											
Tarea 4: Análisis comparativo entre las tres estrategias	100%	14-4-26	10-5-26											
Tarea 5: Interpretación de los resultados del backtest	100%	28-4-26	10-5-26											
Fase 4: Redacción de la memoria y cierre (10 semanas)														
Tarea 1: Redacción de introducción, datos y estado del arte	100%	1-4-26	15-5-26											
Tarea 2: Redacción de metodología y resultados	100%	1-5-26	31-5-26											
Tarea 3: Preparación de figuras, tablas y apéndices	100%	15-5-26	5-6-26											
Tarea 4: Revisión final del documento	100%	25-5-26	7-6-26											
Tarea 5: Entrega del borrador (12 de junio de 2026)	100%	7-6-26	12-6-26											

1.4 Tecnologías utilizadas

Todo el proceso de análisis se ha realizado en Python, utilizando Jupyter Notebooks como entorno principal de desarrollo. A continuación, se describen las principales librerías y herramientas utilizadas en cada etapa.

- Para la obtención y manipulación de datos se utilizaron pandas y numpy. Los datos históricos de precios y volumen se descargaron mediante yfinance, que permite obtener información financiera desde Yahoo Finance.
- Para el análisis descriptivo y la visualización se usaron matplotlib y seaborn. Estas librerías permitieron generar histogramas, boxplots, matrices de correlación y gráficos de resultados.
- Los modelos de series temporales, en concreto los modelos ARIMA, se implementaron con statsmodels. Los modelos de aprendizaje automático se desarrollaron con scikit-learn.
- La optimización de carteras se realizó con PyPortfolioOpt, una librería de Python que permite aplicar el modelo de Markowitz. Para calcular el riesgo entre los ETFs se utilizó la matriz de

covarianzas con el método de Ledoit-Wolf. Después, el problema de optimización se resolvió con cvxpy y el solver OSQP.

- Para guardar los experimentos de aprendizaje automático y los resultados de la cartera se utilizó Google Sheets. Desde Python se conectó con la hoja de cálculo mediante la API de Google y la librería gspread. Así, se registraban automáticamente las métricas y predicciones de los modelos, los pesos de inversión y la evolución de cada cartera. Esto permitió revisar y comparar todos los resultados de forma más sencilla.
- **Añadir tema IA**

Capítulo 2 - PRELIMINARES

2.1 Estado de la Cuestión

La predicción de retornos financieros lleva décadas siendo uno de los temas más investigados en finanzas. Una de las teorías más conocidas es la hipótesis de los mercados eficientes, desarrollada por Eugene Fama [2]. Según esta teoría, en un mercado eficiente los precios de los activos reflejan la información disponible en cada momento. Esto implica que la información que aportan los precios y volúmenes pasados ya estaría incorporada en los precios actuales. Por tanto, sería difícil obtener predicciones consistentes utilizando únicamente datos históricos de mercado.

Sin embargo, algunos estudios han encontrado patrones en los retornos pasados que pueden estar relacionados con los retornos futuros. Jegadeesh y Titman [3] documentaron el efecto *momentum*, el cual dice que los activos que han tenido un buen comportamiento en los últimos meses tienden a seguir comportándose bien a corto plazo y viceversa. Por otro lado, DeBondt y Thaler [4] observaron que, a largo plazo, algunos activos con fuertes caídas previas tienden a recuperarse. Estos resultados no invalidan la hipótesis de los mercados eficientes [2], pero sí muestran que los datos históricos pueden tener ciertos patrones que merece la pena analizar.

Aun así, predecir retornos financieros es una tarea especialmente compleja. Cont [5] recopiló algunas de las propiedades estadísticas más habituales de los retornos financieros, como la presencia de movimientos extremos, la baja autocorrelación lineal y la existencia de periodos de alta volatilidad seguidos de otros más tranquilos. Estas características hacen que la señal sea débil y que gran parte de los movimientos observados estén dominados por ruido.

Por este motivo, este trabajo no parte de la idea de que el mercado pueda predecirse de forma exacta. El objetivo es más limitado: probar distintos modelos, medir qué capacidad predictiva tienen y analizar si sus predicciones pueden aportar valor dentro de una cartera de inversión.

2.2 ETFs

Un ETF (Exchange Traded Fund) es un producto financiero que agrupa muchas empresas o activos dentro de un solo fondo. En lugar de comprar acciones individuales que representan una sola empresa, como Apple o Banco Santander. Un ETF permite invertir en un conjunto amplio de empresas al mismo tiempo

(por ejemplo, el índice S&P 500 incluye las 500 principales empresas de Estados Unidos). Estos se compran y venden en bolsa de forma continua igual que una acción [6]

Desde su aparición en los años noventa, los ETFs han ganado una gran importancia dentro de los mercados financieros. Su crecimiento se debe a que permiten invertir de forma diversificada, sencilla y con costes reducidos. Por este motivo, se han convertido en instrumentos muy utilizados tanto por inversores individuales como por gestores de carteras [7].

La elección de ETFs en este trabajo se debe a que su comportamiento suele ser más estable que el de una acción individual. Una empresa concreta puede tener cambios muy bruscos por noticias o eventos propios. En cambio, un ETF incluye muchas empresas o activos, por lo que las subidas y bajadas de unas suelen compensarse con las de otras. Esto puede hacer que sus precios y retornos tengan cambios menos fuertes, lo que los hace adecuados para aplicar modelos de predicción.

2.3 Modelos de series temporales

Una serie temporal es un conjunto de observaciones ordenadas en el tiempo. En este trabajo, cada ETF puede entenderse como una serie temporal, ya que para cada activo se entiende por una secuencia de precios, volúmenes o retornos observados en distintos días. La característica principal de este tipo de datos es que el orden temporal importa, una observación no se interpreta de forma aislada, sino que se relaciona con las observaciones anteriores.

Los modelos de series temporales son métodos estadísticos que intentan describir y predecir la evolución de una variable a lo largo del tiempo. Su objetivo es identificar si existe algún patrón en el pasado que pueda ayudar a explicar el comportamiento futuro. En el contexto financiero, este tipo de modelos se ha utilizado para estudiar precios, retornos, volatilidad y otros indicadores de mercado [8].

Antes de modelizar una serie temporal, es necesario entender cómo se comporta. Algunas series tienen una tendencia, es decir, una subida o bajada mantenida durante el tiempo. Otras presentan estacionalidad, cuando ciertos patrones se repiten de forma regular, por ejemplo, cada mes o cada año. También hay que estudiar si la serie es estacionaria. Una serie estacionaria mantiene un comportamiento estable en el tiempo, con una media y una variabilidad similares, sin subidas y bajadas. Si la media o la variabilidad cambian con el tiempo, la serie es no estacionaria y requiere un tratamiento previo antes de aplicar modelos.

En finanzas, los precios de los activos suelen ser no estacionarios, porque pueden subir o bajar durante largos periodos. Por eso, en lugar de trabajar directamente con precios, se trabaja con retornos [9]. Los retornos miden la variación entre el precio de cierre de un día ($P_{i,t}$) y el del día anterior ($P_{i,t-1}$):

$$R_{i,t} = \frac{P_{i,t} - P_{i,t-1}}{P_{i,t-1}}$$

Los retornos suelen moverse alrededor de cero y no presentan una tendencia marcada como los precios. Por ello, son más estables para aplicar modelos de series temporales.

Para modelar y predecir este tipo de datos, uno de los enfoques más utilizados es el modelo ARIMA, cuyas siglas corresponden a AutoRegressive Integrated Moving Average [8]. El modelo ARIMA tiene tres componentes:

- Componente autorregresiva (AR): el valor actual se explica como una combinación lineal de los valores pasados de la propia serie. El parámetro p indica cuántos valores pasados se incluyen.
- Componente de integración (I): sirve para transformar una serie que no es estacionaria. Para ello, se calculan diferencias entre un valor y el anterior. En este trabajo no se trabaja con precios directamente, sino con retornos, que ya miden el cambio entre periodos y son estacionarios. Por eso, no se aplica ninguna diferencia adicional y se fija el parámetro $d = 0$.
- Componente de media móvil (MA): utiliza los errores de predicción pasados para corregir la predicción actual. El parámetro q indica cuántos errores pasados se incluyen.

Para seleccionar los parámetros p y q se sigue la metodología de Box, Jenkins y Reinsel [8], apoyándose en criterios como AIC y BIC. Estos criterios permiten comparar distintos modelos y seleccionar una opción que tenga buen ajuste sin aumentar innecesariamente la complejidad.

La principal ventaja de ARIMA es que es sencillo e interpretable. Su limitación es que analiza cada ETF por separado y solo detecta relaciones lineales. Por eso, en este trabajo se compara con modelos de aprendizaje automático, que pueden incorporar información de varios activos a la vez y capturar patrones más complejos.

2.4 Modelos de aprendizaje automático

El aprendizaje automático (Machine Learning) permite crear modelos que aprenden patrones a partir de datos. En este trabajo se utiliza aprendizaje supervisado, porque se quiere predecir una variable conocida en el histórico: el retorno futuro de cada ETF.

Estos modelos son útiles porque pueden trabajar con muchas variables al mismo tiempo, como retornos pasados, volumen, información de otros ETFs y variables temporales. Esto permite analizar si existen relaciones que no se observan al estudiar cada activo por separado.

Aun así, aplicar estos modelos a datos financieros presenta dificultades importantes. Los retornos suelen ser ruidosos, tienen una señal débil y cambian con el tiempo. Esto significa que un modelo puede ajustarse bien a los datos históricos, pero no necesariamente funcionar igual de bien en datos nuevos.

En este trabajo se utilizan varios modelos de aprendizaje automático supervisado: regresión lineal, Ridge, Random Forest y Gradient Boosting. Se han elegido estos porque permiten comparar modelos de distinta complejidad. La regresión lineal y Ridge representan enfoques más simples e interpretables, mientras que Random Forest y Gradient Boosting permiten estudiar relaciones más complejas y relaciones no lineales entre las variables. Se han seleccionado estos porque son los modelos más habituales en predicción financiera [10].

2.4.1 Regresión lineal

La regresión lineal es uno de los modelos más simples dentro del aprendizaje supervisado. Su objetivo es explicar una variable dependiente, en este caso el retorno futuro de un ETF, como una combinación lineal de varias variables explicativas. Estas variables pueden ser retornos pasados, cambios en el volumen, variables temporales u otras variables disponibles. Su fórmula es:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

Donde $\hat{y}$ representa la predicción del retorno futuro, $x_1, x_2, \dots, x_p$ son las variables explicativas utilizadas por el modelo y $\beta_0, \beta_1, \dots, \beta_p$ son los coeficientes estimados.

Su principal ventaja es la interpretabilidad. Cada coeficiente indica la relación entre una variable de entrada y el retorno que se quiere predecir. Sin embargo, esta simplicidad también es una limitación. La regresión lineal solo puede capturar relaciones lineales y puede tener problemas cuando hay muchas variables o cuando estas están muy correlacionadas entre sí. En este trabajo se incluye como modelo base para comprobar hasta qué punto un modelo lineal simple es suficiente para predecir retornos.

2.4.2 Ridge

Ridge es una extensión de la regresión lineal propuesta por Hoerl y Kennard [11]. La idea principal es mantener la estructura lineal del modelo, pero añadiendo una penalización sobre el tamaño de los coeficientes. Esta penalización, conocida como regularización del modelo, evita que algunos coeficientes tomen valores demasiado grandes y ayuda a reducir el sobreajuste.

La predicción de Ridge se escribe igual que en la regresión lineal:

$$\hat{y} = \hat{\beta}_0^{Ridge} + \hat{\beta}_1^{Ridge} x_1 + \hat{\beta}_2^{Ridge} x_2 + \dots + \hat{\beta}_p^{Ridge} x_p$$

Pero no estima los coeficientes β solo buscando reducir el error, sino que también penaliza esos coeficientes de la forma:

$$\hat{\beta}^{Ridge} = \arg \min_{\beta} \left[\sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right]$$

El primer término mide el error de predicción del modelo. El segundo término penaliza los coeficientes grandes. El parámetro λ controla la fuerza de la penalización: cuanto mayor es, más se reducen los coeficientes.

Este modelo ayuda a corregir las limitaciones de la regresión lineal, se utiliza cuando se trabaja con muchos datos de entrada y con variables relacionadas entre sí. En el caso de los ETFs, esto es importante porque muchos activos se mueven de forma parecida y pueden estar altamente correlacionados.

2.4.3 Random Forest

Random Forest es un modelo propuesto por Breiman [12] y basado en árboles de decisión. Un árbol de decisión separa los datos mediante reglas sencillas, por ejemplo comprobando si una variable supera cierto valor. Al hacer estas divisiones sucesivas, el modelo puede captar relaciones no lineales entre las variables, ya que no obliga a que la relación entre entrada y salida sea lineal.

En lugar de usar un solo árbol, Random Forest construye muchos árboles y combina sus resultados. Cada árbol se entrena con una parte distinta de los datos y con una selección de variables. Después, la predicción final se calcula como el promedio de las predicciones de todos los árboles. Esto hace que el modelo sea más estable que un árbol individual y reduce el riesgo de ajustarse demasiado a los datos de entrenamiento.

2.4.4 Gradient Boosting

Gradient Boosting también utiliza árboles de decisión, pero de una forma diferente. Mientras que Random Forest construye muchos árboles de forma paralela e independiente, Gradient Boosting los construye de manera secuencial. Cada nuevo árbol intenta corregir los errores generados por los árboles anteriores.

De esta manera, el modelo mejora poco a poco. Primero se construye un árbol sencillo. Después se observa dónde se ha equivocado más y se entrena un nuevo árbol para corregir esos errores.

Este enfoque fue propuesto por Friedman [13] y puede ser útil en predicción financiera porque es capaz de detectar patrones débiles y relaciones complejas entre variables. Su principal riesgo es el sobreajuste, es decir, que el modelo aprenda demasiado bien los datos de entrenamiento y luego no funcione con datos nuevos. Para evitarlo, es necesario ajustar parámetros como el número de árboles, su profundidad o la tasa de aprendizaje.

2.5 Optimización de carteras y modelo de Markowitz

La teoría moderna de carteras, formulada por Markowitz en 1952 [1], plantea que una cartera no debe analizarse solo por la rentabilidad esperada de cada activo, sino también por el riesgo de la cartera en conjunto. La idea principal es que combinar activos que no se mueven exactamente igual puede reducir el riesgo total. Este es el principio básico de la diversificación.

El modelo de Markowitz busca una combinación de activos que mantenga un equilibrio entre rentabilidad y riesgo. De forma simplificada, este equilibrio puede expresarse como:

$$\max_w (w^T \mu - \lambda w^T \Sigma w)$$

En esta expresión,

- w representa los pesos asignados a cada activo.
- μ es el vector de rentabilidades esperadas.
- Σ es la matriz de covarianzas entre los activos.
- El primer término, $w^T \mu$, representa la rentabilidad esperada de la cartera.
- El segundo término, $w^T \Sigma w$, representa el riesgo de la cartera, medido mediante la varianza.

- El parámetro λ indica la importancia que se da al riesgo, cuanto mayor es, más conservadora es la cartera.

Una de las partes más importantes del modelo es el vector de rentabilidades esperadas. Este vector representa la rentabilidad que se espera obtener de cada activo. Como esas rentabilidades futuras no se conocen, normalmente se estiman con métodos simples, como la media histórica de los retornos. En este trabajo se analiza si las predicciones obtenidas mediante modelos de series temporales y aprendizaje automático pueden utilizarse como una alternativa para estimar esas rentabilidades dentro del modelo de Markowitz.

2.6 Métricas de evaluación

Para evaluar la calidad de las predicciones se utilizan dos métricas de error habituales en problemas de regresión: RMSE y MAE. Ambas comparan el valor predicho por el modelo con el valor real observado.

El RMSE (Root Mean Squared Error) mide el error medio del modelo. Esta métrica da más peso a los errores grandes, porque eleva las diferencias al cuadrado antes de hacer la media. Su fórmula es:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

donde y_i es el valor real, $\hat{y}_i$ es la predicción del modelo y n es el número total de observaciones. Un valor más bajo de RMSE indica una mejor precisión.

El MAE (Mean Absolute Error) mide el error medio en valor absoluto. Es una métrica más directa de interpretar, porque indica cuánto se aleja, de media, la predicción del valor real. Su fórmula es:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Además, los resultados de cada modelo se comparan con dos modelos de referencia simples. El primero es el modelo naive, que predice que el retorno del siguiente periodo será igual al último retorno observado. El segundo es el modelo cero, que predice siempre un retorno igual a cero. Aunque es una regla muy simple, puede funcionar razonablemente bien ya que los retornos son pequeños y se mueven cerca de cero. Por eso, superar este modelo indica que la predicción aporta información adicional. Para

estos dos modelos también se calculan RMSE y MAE, de forma que todos los métodos se comparan con las mismas métricas.

De forma complementaria, se utiliza la Kappa de Cohen como métrica para estudiar si el modelo acierta la dirección del movimiento. Para ello, los retornos se clasifican como positivos o negativos. Esta métrica compara los aciertos reales del modelo con los aciertos que podrían darse por azar. Por eso resulta útil como complemento a RMSE y MAE, ya que permite analizar no solo el tamaño del error, sino también si el modelo predice correctamente el signo del movimiento. La Kappa de Cohen se define como:

$$\kappa = \frac{p_o - p_e}{1 - p_e}$$

donde p_o representa la proporción de aciertos reales entre la dirección predicha y la dirección observada, y p_e representa la proporción de aciertos que podrían darse simplemente por azar.

Un valor de κ cercano a 1 indica que la dirección predicha coincide con la dirección real. Un valor cercano a 0 indica que el modelo no mejora una coincidencia aleatoria. Si el valor es negativo significa que el modelo coincide menos con el valor real que una elección aleatoria.

Capítulo 3 - DATOS

3.1 Descripción de los datos

Para este trabajo se han seleccionado un conjunto de 60 ETFs con el objetivo de representar distintos tipos de activos y tener una muestra variada. Estos ETFs se agrupan en seis grandes categorías: renta variable estadounidense e internacional, estilos de inversión, sectores económicos, renta fija y materias primas. Esta clasificación permite trabajar con activos de diferente comportamiento y analizar si los modelos son capaces de predecir retornos en distintos sectores del mercado.

3.1.1 Mercado estadounidense

Esta categoría incluye ETFs que siguen algunos de los índices más importantes de Estados Unidos. Estos fondos permiten analizar el comportamiento general de la bolsa estadounidense, desde grandes empresas hasta empresas medianas y pequeñas.

ETF	Nombre comercial	Qué representa
SPY	SPDR S&P 500 ETF	Índice S&P 500
IVV	iShares Core S&P 500	
VOO	Vanguard S&P 500 ETF	
QQQ	Invesco QQQ Trust	Índice Nasdaq 100
VTI	Vanguard Total Stock Market	Mercado total de acciones de EEUU
ITOT	iShares Core Total US Market	
DIA	SPDR Dow Jones ETF	Índice Dow Jones Industrial Average
IWM	iShares Russell 2000	Empresas pequeñas de Estados Unidos
IJR	iShares Core S&P Small-Cap	Empresas pequeñas de Estados Unidos
MDY	SPDR S&P MidCap 400	Empresas medianas de Estados Unidos

3.1.2 Factores y estilos

Son ETFs que seleccionan empresas según determinadas características, como crecimiento, valor, calidad o baja volatilidad.

ETF	Nombre comercial	Qué representa
VUG	Vanguard Growth ETF	Empresas con altas expectativas de crecimiento
IWF	iShares Russell 1000 Growth	
VTV	Vanguard Value ETF	Empresas de valor con altas expectativas de crecimiento
IWD	iShares Russell 1000 Value	
SCHD	Schwab US Dividend Equity	Empresas que pagan dividendos
VIG	Vanguard Dividend Appreciation	
DVY	iShares Select Dividend	
MTUM	iShares MSCI USA Momentum	Activos con tendencia positiva reciente
QUAL	iShares MSCI USA Quality	Empresas con buenos indicadores financieros
USMV	iShares MSCI Minimum Volatility	Empresas con menor volatilidad, más estables
VLUE	iShares MSCI USA Value Factor	Empresas de valor

3.1.3 Sectores económicos

Esta categoría incluye ETFs que invierten en sectores concretos de la economía, como tecnología, finanzas, salud o energía. En lugar de seguir todo el mercado, se centran en una parte específica de la actividad económica.

ETF	Nombre comercial	Qué representa
XLK	Technology Select Sector SPDR	Tecnología
XLF	Financial Select Sector SPDR	Finanzas
XLV	Health Care Select Sector SPDR	Salud
XLV	Consumer Discretionary SPDR	Consumo cíclico

XLP	Consumer Staples SPDR	Consumo básico
XLE	Energy Select Sector SPDR	Energía
XLI	Industrial Select Sector SPDR	Industria
XLU	Utilities Select Sector SPDR	Servicios públicos
XLB	Materials Select Sector SPDR	Materiales
XLRE	Real Estate Select Sector SPDR	Sector inmobiliario

3.1.4 Mercados internacionales

Los ETFs internacionales permiten invertir en mercados fuera de Estados Unidos. Esta categoría incluye tanto países desarrollados como países emergentes.

ETF	Nombre comercial	Qué representa
VEA	Vanguard FTSE Developed Markets	Mercados desarrollados fuera de Estados Unidos
IEFA	iShares Core MSCI EAFE	Europa, Asia y otros mercados desarrollados
VWO	Vanguard Emerging Markets	Mercados Emergentes
IEMG	iShares Core Emerging Markets	
EEM	iShares MSCI Emerging Markets	
EFA	iShares MSCI EAFE	Mercados desarrollados fuera de Estados Unidos
EWJ	iShares MSCI Japan	Japón
EWG	iShares MSCI Germany	Alemania
EWU	iShares MSCI UK	Reino Unido
EWQ	iShares MSCI France	Francia
INDA	iShares MSCI India	India

EWZ	iShares MSCI Brazil	Brasil
FXI	iShares China Large-Cap	Grandes empresas de China
MCHI	iShares MSCI China	Mercado China
EWT	iShares MSCI Taiwan	Taiwán
EWY	iShares MSCI South Korea	Corea del Sur

3.1.5 Renta fija (Bonos)

Esta categoría incluye ETFs de bonos públicos y corporativos. Estos activos suelen tener un comportamiento diferente al de la renta variable y pueden aportar estabilidad a una cartera. Dentro del grupo se incluyen bonos de corto, medio y largo plazo, así como bonos corporativos con distinto nivel de riesgo.

ETF	Nombre comercial	Qué representa
BND	Vanguard Total Bond Market	Mercado amplio de bonos de Estados Unidos
AGG	iShares Core US Aggregate Bond	Bonos agregados de Estados Unidos
IEF	iShares 7-10 Year Treasury	Bonos del Tesoro a medio plazo
TLT	iShares 20+ Year Treasury	Bonos del Tesoro a largo plazo
SHY	iShares 1-3 Year Treasury	Bonos del Tesoro a corto plazo
LQD	iShares Investment Grade Corporate	Bonos corporativos de buena calidad
HYG	iShares High Yield Corporate	Bonos corporativos de mayor riesgo
JNK	SPDR Bloomberg High Yield Bond	Bonos de alto rendimiento
TIP	iShares TIPS Bond	Bonos ligados a inflación
BIL	SPDR 1-3 Month T-Bill	Letras del Tesoro a muy corto plazo

3.1.6 Materias primas y activos reales

Esta categoría incluye ETFs de activos físicos como oro, plata o petróleo, a índices de materias primas o del sector inmobiliario. Estos activos suelen comportarse de forma diferente a las acciones y los bonos, especialmente en momentos de inflación o incertidumbre económica.

ETF	Nombre comercial	Qué representa
GLD	SPDR Gold Shares	Oro
IAU	iShares Gold Trust	
SLV	iShares Silver Trust	Plata
USO	United States Oil Fund	Petróleo
DBC	Invesco DB Commodity Index	Materias primas
VNQ	Vanguard Real Estate ETF	Sector inmobiliario

3.2 Variables principales

Para cada ETF se recogieron dos variables principales: el precio ajustado de cierre y el volumen negociado.

- El **precio ajustado de cierre** es el precio del ETF al final de cada día, teniendo en cuenta dividendos y otros ajustes. Esta variable se utiliza porque permite analizar mejor cómo ha evolucionado el ETF en el tiempo. Llamaremos precio ajustado del activo i en el día t como: $P_{\{i,t\}}$
- El **volumen diario** indica cuántas participaciones del ETF se compraron y vendieron en un día. Un volumen alto significa que hubo mucha actividad en el mercado y que muchos inversores compraron o vendieron ese ETF. Se expresa como: $V_{\{i,t\}}$
- El **retorno simple** mide la variación porcentual entre el precio ajustado de cierre de un día y el del día anterior. Se calcula como:

$$R_{i,t} = \frac{P_{i,t} - P_{i,t-1}}{P_{i,t-1}}$$

donde $P_{i,t}$ es el precio ajustado de cierre del ETF i en el día t , y $P_{i,t-1}$ es el precio ajustado de cierre del día anterior. Este es más intuitivo porque indica directamente el porcentaje de subida o bajada entre un día y el anterior. Por ejemplo, si un ETF pasa de 100 a 102 euros, el retorno simple es del 2 %.

- El **retorno logarítmico** mide también la variación entre dos precios, pero transforma el retorno simple a logaritmo utilizando el logaritmo natural.

$$R_{i,t} = \frac{P_{i,t} - P_{i,t-1}}{P_{i,t-1}} \quad \rightarrow \quad 1 + R_{i,t} = \frac{P_{i,t}}{P_{i,t-1}} \quad \rightarrow \quad \ln(1 + R_{i,t}) = \ln\left(\frac{P_{i,t}}{P_{i,t-1}}\right)$$

Por lo tanto, el retorno logarítmico es:

$$r_{i,t} = \ln(1 + R_{i,t}) = \ln\left(\frac{P_{i,t}}{P_{i,t-1}}\right) = \ln(P_{i,t}) - \ln(P_{i,t-1})$$

Y su transformación para volver al retorno simple:

$$r_{i,t} = \ln(1 + R_{i,t}) \quad \rightarrow \quad e^{r_{i,t}} = 1 + R_{i,t} \quad \rightarrow \quad R_{i,t} = e^{r_{i,t}} - 1$$

En este trabajo se utiliza el retorno logarítmico porque facilita el análisis cuando se estudian retornos de varios días seguidos. La ventaja principal es que los retornos logarítmicos se pueden sumar. Es decir, si se quiere calcular el retorno de una semana, se pueden sumar los retornos diarios de esa semana y así analizar la evolución de los ETFs en distintos periodos.

Además, cuando los cambios de precio entre días son pequeños, como suele ocurrir en muchos retornos diarios, el retorno simple y el retorno logarítmico son muy parecidos. Por eso, el retorno logarítmico sigue teniendo una magnitud muy cercana al retorno simple, pero ofrece una forma más práctica de trabajar con series temporales financieras.

3.3 Análisis descriptivo inicial

Antes de aplicar modelos de predicción y construir carteras, se analizan las propiedades estadísticas básicas de los ETFs. Para poder entender cómo se comportan los retornos.

3.3.1 Estadística descriptiva

ETF	Retorno medio diario	Desv. típica diaria	Retorno mínimo	Percentil 5%	Percentil 25%	Mediana	Percentil 75%	Percentil 95%	Retorno máximo
SLV	0.000824	0.021201	-0.336037	-0.027873	-0.009590	0.000462	0.011420	0.032051	0.087487
USO	0.000662	0.021036	-0.123962	-0.033490	-0.011637	0.001509	0.013694	0.032124	0.076115
FXI	-0.000042	0.019867	-0.105268	-0.029030	-0.011263	-0.000725	0.010424	0.030209	0.192612
MCHI	-0.000132	0.019373	-0.114395	-0.028250	-0.010620	-0.000662	0.009846	0.030597	0.190103
EWZ	0.000329	0.017723	-0.077276	-0.029867	-0.009296	0.000973	0.011436	0.028281	0.093990
...	...	...	...	...	...	...	...	...	...
TIP	0.000035	0.003941	-0.016982	-0.006396	-0.002078	0.000092	0.002259	0.005759	0.017516
AGG	-0.000016	0.003798	-0.016529	-0.006085	-0.002254	0.000000	0.002203	0.006009	0.021243
BND	-0.000018	0.003760	-0.016284	-0.006109	-0.002221	0.000000	0.002222	0.006029	0.020491
SHY	0.000062	0.001222	-0.005101	-0.001844	-0.000494	0.000000	0.000605	0.001976	0.009924
BIL	0.000120	0.000185	-0.002841	-0.000109	0.000000	0.000109	0.000218	0.000437	0.007065

1 TABLA: Estadísticas descriptivas de retornos logarítmicos diarios por ETF

En primer lugar, se analiza la estadística descriptiva de los retornos logarítmicos diarios de los ETFs. La media diaria es muy cercana a cero en todos los casos. Esto indica que, en periodos cortos, las subidas y bajadas tienden a compensarse y que los retornos diarios suelen tener valores muy pequeños.

La desviación típica permite observar la volatilidad de cada ETF. Los activos relacionados con renta variable, materias primas o mercados más específicos presentan una mayor variabilidad, mientras que los ETFs de renta fija muestran valores más bajos. Esto confirma que no todos los activos tienen el mismo nivel de riesgo y que existen diferencias entre categorías.

También se analizan los valores mínimos, máximos y percentiles para detectar movimientos extremos en algunos ETFs. Por ejemplo, los activos de materias primas o de mercados concretos pueden presentar caídas o subidas más fuertes, como ocurre con SLV, que alcanza un retorno mínimo de -0,3360. En cambio, los fondos de renta fija tienden a mostrar movimientos más estables, como BIL, cuyo retorno mínimo es de -0,0028.

En conjunto, esta tabla muestra que los retornos diarios suelen ser pequeños y cercanos a cero, aunque la volatilidad cambia según el tipo de activo. Por esta razón, en el apartado de modelización de a continuación, se compara cada modelo con una referencia simple: predecir siempre un retorno igual a cero.

3.3.2 Histogramas

Los histogramas permiten visualizar la forma de la distribución de los retornos logarítmicos diarios.




Ilustración 1. Histogramas de retornos logarítmicos diarios

Observamos de nuevo que la mayoría de los retornos se concentran alrededor de cero. Además, las distribuciones tienen forma aproximadamente acampanada, aunque algunos ETFs presentan valores más repartidos que otros. Los ETFs amplios de mercado, como SPY, muestran retornos más concentrados alrededor de cero, por lo que sus cambios diarios suelen ser más moderados. En cambio, algunos ETFs de mercados internacionales o sectores más concretos, como EWG, tienen colas más largas, con más días de subidas y bajadas. Por otro lado, los ETFs de materias primas, como IAU, muestran una mayor dispersión y más valores extremos. Sus retornos pueden variar más de un día a otro, lo que muestra un comportamiento menos estable que el de los ETFs más amplios.

3.3.3 Boxplot

Los boxplots permiten complementar el análisis anterior mostrando: la mediana, el rango intercuartílico y outliers.




Ilustración 2. Boxplot SPY 500

En el caso del SPY, por ejemplo, se observa una mediana cercana a cero y un rango intercuartílico muy reducido. Además, encontramos algunos valores extremos tanto positivos como negativos, estos reflejan días con movimientos anormalmente altos, generalmente asociados a eventos macroeconómicos, crisis,

shocks de mercado... La presencia de estos valores extremos confirma que la volatilidad no es constante y que los mercados tienen momentos de alta incertidumbre, lo que afecta en la precisión de sus predicciones.




Ilustración 3. Boxplots globales de retornos logarítmicos de ETFs

El boxplot conjunto permite comparar visualmente la volatilidad entre activos. Podemos observar:

- Los ETFs de renta variable (SPY, QQQ, VTI o IWM) presentan mayor dispersión que los de renta fija (BND, AGG, SHY o BIL). Esto es lógico ya que las acciones suelen moverse más que los bonos. Por eso, los ETFs de renta variable presentan cambios más fuertes, mientras que los de renta fija suelen tener movimientos más pequeños.
- Materias primas (GLD, SLV o USO) y algunos mercados emergentes (EEM, EWZ o FXI) presentan un mayor rango de variación y una mayor cantidad de outliers, reflejando episodios de mayor inestabilidad.
- Los activos del mismo tipo tienden a mostrar comportamientos similares.

Este resultado es coherente con la teoría financiera: activos con mayor riesgo presentan mayor variabilidad de retornos.

3.3.4 Matriz de correlaciones

La matriz de correlación permite analizar cómo se mueven conjuntamente los activos.




Ilustración 4. Matriz de correlación de retornos

En la matriz de correlaciones se observa cómo se relacionan los retornos de los distintos ETFs. Los tonos más rojos indican una correlación más alta, es decir, activos que tienden a moverse en la misma dirección.

El gráfico muestra varios bloques de color más intenso. Esto significa que existen grupos de ETFs con comportamientos parecidos. Por ejemplo, muchos ETFs de renta variable estadounidense presentan correlaciones elevadas entre sí, ya que dependen en gran parte de la evolución general del mercado. En cambio, otros activos, como algunos ETFs de renta fija o materias primas, muestran una relación menor con el resto.

Este resultado es importante para el trabajo por dos razones. Por un lado, muestra que muchos ETFs están relacionados entre sí, algo que puede afectar a los modelos lineales cuando usan muchas variables parecidas. Por ello se incluye Ridge, que ayuda a controlar este problema mediante regularización. Por otro lado, también es importante para la optimización de carteras, si todos los ETFs se movieran igual, no habría beneficio por combinarlos. Al existir correlaciones distintas entre grupos, Markowitz puede repartir el peso entre activos con comportamientos diferentes.

3.3.5 Periodo de estudio y división temporal

El periodo de estudio abarca desde enero de 2021 hasta febrero de 2026, con datos diarios de mercado. A partir de estos datos se calculan los retornos logarítmicos utilizados después en los modelos de predicción.

Para evaluar los modelos de forma ordenada, el conjunto de datos se divide en dos partes: entrenamiento y test. El periodo de entrenamiento se utiliza para ajustar los modelos, mientras que el periodo de prueba se reserva para comprobar cómo funcionan con datos no vistos por el modelo anteriormente.

La división temporal se mantiene fija durante todo el trabajo. En el periodo de entrenamiento se utilizan los datos comprendidos desde la semana 2021-W01, que comienza el 4 de enero de 2021, hasta la semana 2024-W29, que finaliza el 21 de julio de 2024. El periodo de prueba comienza en la semana 2024-W30, 22 de julio de 2024, y finaliza en la semana 2026-W06, el 8 de febrero de 2026. Esto supone aproximadamente un 70 % de datos para entrenamiento y un 30 % para test. Esta separación permite comparar los resultados de los distintos modelos bajo las mismas condiciones.

Esta forma de dividir los datos es importante porque en series temporales tiene que respetarse el orden de los datos. En cada predicción, el modelo solo debe utilizar información disponible hasta ese momento. Por ello, en series temporales no se utiliza una división clásica en entrenamiento, validación y test, ya que una validación aleatoria podría romper el orden temporal de los datos.

En los modelos de aprendizaje automático sí se realiza una validación para elegir los mejores hiperparámetros, pero también siempre respetando el orden temporal. Este proceso se detalla de forma más desarrollada en el apartado siguiente.

Capítulo 4 - METODOS DE MODELIZACIÓN

4.1 Modelización mediante series temporales

Una vez explicados los fundamentos de los modelos ARIMA en los preliminares, este apartado describe su aplicación a la predicción de retornos de ETFs. A continuación, se explica la preparación de los datos, la selección de los parámetros p , d y q , el proceso de predicción y los criterios utilizados para evaluar los resultados.

4.1.1 Preprocesamiento de los datos

Construcción de la serie de retornos

El punto de partida es el archivo `adj_close.csv`, que contiene los precios de cierre ajustados de los 63 ETFs para el periodo comprendido entre el 4 de enero de 2021 y el 2 de febrero de 2026, con un total de 1.276 días de cotización. A partir de estos precios se calculan, como hemos visto previamente, los retornos logarítmicos diarios:

$$r_{i,t} = \ln(P_{i,t}) - \ln(P_{i,t-1})$$

La variable objetivo que se modela con ARIMA es esta, los retornos logarítmicos, no los precios. Esta decisión es debido a que el precio ajustado de un ETF tiene una tendencia creciente a largo plazo y, por ello, no suele ser estacionario. En cambio, los retornos logarítmicos suelen tener un comportamiento más estable. Trabajar con retornos simplifica el análisis y facilita su uso posterior en el modelo de Markowitz, que utiliza retornos como variable de entrada.

El estudio se realiza con frecuencia diaria y semanal para analizar cómo afecta la agrupación temporal al rendimiento del modelo ARIMA. Los datos diarios parten de más observaciones y reflejan cambios más inmediatos, aunque también presentan más ruido. En cambio, los datos semanales reducen parte de esa variación, pero cuentan con menos observaciones.

- **Serie diaria.** Para el modelo ARIMA diario se trabaja directamente con esta serie: cada observación es el retorno logarítmico de un día de trading. El modelo se ajusta ETF a ETF y se evalúa sobre el periodo de test con datos de frecuencia diaria.
- **Serie semanal.** Para el modelo ARIMA semanal, los retornos diarios se agrupan por semana del calendario ISO (YYYY-Www). El retorno semanal de cada ETF se obtiene como la media de sus

retornos diarios de esa semana. Esta misma agregación se usa en el preprocesado de los modelos de machine learning, lo que garantiza coherencia entre los dos enfoques.

Estacionariedad

Como se ha explicado anteriormente, una serie temporal es estacionaria cuando sus propiedades estadísticas como media y varianza no cambian a lo largo del tiempo. Esta propiedad es importante tenerla para poder aplicar los modelos ARIMA. Una serie no estacionaria tiene una tendencia o varianza cambiante que el modelo no podría capturar correctamente. Para evaluar la estacionariedad se aplican dos tests complementarios sobre los retornos logarítmicos de cada ETF:

- ADF (Augmented Dickey-Fuller): su hipótesis nula establece que la serie no es estacionaria.
 - Si el p-valor es menor que 0,05, se rechaza esta hipótesis y el resultado tiende a que la serie es estacionaria.
 - Si el p-valor es mayor que 0,05, no se puede rechazar que la serie sea no estacionaria. El resultado tiende a que la serie sea no estacionaria.
- KPSS (Kwiatkowski-Phillips-Schmidt-Shin): este test parte de la hipótesis contraria, es decir, que la serie sí es estacionaria.
 - Si el p-valor es menor que 0,05, se rechaza la hipótesis y los resultados tienden a que la serie sea no ser estacionaria.
 - Si el p-valor es mayor que 0,05, no se rechaza esa hipótesis y se considera que la serie puede ser estacionaria.

Como ambas pruebas parten de hipótesis contrarias, sus resultados se analizan de forma conjunta:

ADF	KPSS	Conclusión
$p < 0,05$	$p > 0,05$	Estacionaria
$p > 0,05$	$p < 0,05$	No estacionaria
$p > 0,05$	$p > 0,05$	No concluyente
$p < 0,05$	$p < 0,05$	Inconsistente

La tabla x muestra los resultados obtenidos para el ETF AGG como ejemplo para entender por qué trabajamos con retornos:

ETF	Formato de los datos	Conclusión Estacionariedad
AGG	Adj_close	No estacionario
AGG	log(Adj_close)	No estacionario
AGG	retorno_simple	Estacionario
AGG	retorno_logarítmico	Estacionario

El resultado para AGG es el esperado: el precio y su logaritmo no son estacionarios, mientras que los retornos sí lo son. Este patrón se repite en la mayoría de ETFs. Sin embargo, cinco ETFs (BIL, EWY, GLD, IAU y SHY) presentan retornos no estacionarios o con resultados inconsistentes. Estos activos se eliminaron para trabajar con series que cumplieran las mismas condiciones y aplicar el mismo procedimiento a todos los ETFs. El conjunto final consta de 58 ETFs, que son los que se usan en todos los modelos del trabajo.

4.1.2 Modelo ARIMA

Estructura del modelo ARIMA

Como se explicó en el apartado 2.3, un modelo $ARIMA(p,d,q)$ combina tres componentes. La parte autorregresiva, $AR(p)$, utiliza los p valores anteriores de la serie para estimar el valor actual. La parte de integración, $I(d)$, aplica diferencias cuando la serie no es estacionaria. Por último, la parte de media móvil, $MA(q)$, utiliza los q errores de predicción anteriores para ajustar la nueva predicción.

La forma general utilizada es:

$$r_t = c + \sum_{i=1}^p \phi_i r_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

- r_t : retorno a predecir.
- c : constante del modelo.
- r_{t-i} : retornos de periodos anteriores.

- ϕ_i : coeficientes de la parte autorregresiva. Indican cuánto influye cada retorno pasado en el retorno a predecir.
- ε_t : error del modelo, la parte que no consigue explicar.
- ε_{t-j} : errores cometidos en periodos anteriores.
- θ_j : coeficientes de la parte de media móvil. Indican cuánto influye cada error pasado en la predicción actual.
- p : número de retornos anteriores utilizados.
- q : número de errores anteriores utilizados.

Como los retornos logarítmicos utilizados en el estudio son estacionarios, no es necesario aplicar nuevas diferencias y se fija $d = 0$. Esta diferenciación no aparece en la ecuación, ya que la se realizaría antes de ajustar el modelo. Por tanto, todos los modelos tienen la forma $ARIMA(p,0,q)$, equivalente a un modelo $ARMA(p, q)$. El modelo se ajusta de forma independiente para cada ETF. De este modo, cada serie puede tener valores distintos de p y q , seleccionados mediante el procedimiento que se explicará en los apartados posteriores.

Análisis de autocorrelación: ACF y PACF


Antes de seleccionar los parámetros del modelo $ARIMA$, se analiza si los retornos actuales están relacionados con los retornos de periodos anteriores. Para ello se utilizan la función de autocorrelación (ACF) y la función de autocorrelación parcial (PACF).

La ACF mide la relación entre el retorno actual y sus valores pasados para distintos retardos. Por ejemplo, el retardo 1 compara el retorno actual con el del periodo anterior, mientras que el retardo 2 lo compara con el de dos periodos anteriores. Esta gráfica sirve como una orientación para elegir el parámetro q , asociado a la componente de media móvil.


La PACF mide la relación directa entre el retorno actual y un retardo concreto, eliminando el efecto de los retardos intermedios. Por ello, se utiliza como orientación inicial para elegir el parámetro autorregresivo p .

En ambas gráficas, el valor del primer retardo tiene un valor de 1, ya que representa la relación de la serie consigo misma. La zona sombreada muestra el intervalo dentro del cual la autocorrelación puede considerarse cercana a cero.

En el trabajo estudiamos los gráficos de ACF y PACF para cada ETF. Para simplificar, vamos a ver los gráficos de un ETF concreto, en este caso SPY500. Como observamos en el gráfico siguiente, la mayoría de los valores están cerca de cero y dentro del intervalo sombreado. Aunque aparecen algún retardo fuera de este intervalo, no se observa una relación fuerte ni un patrón que se mantenga durante varios periodos.



Si vemos el gráfico PACF de la misma serie. De nuevo, la mayoría de los valores son pequeños y se encuentran dentro del intervalo de confianza. No aparece una caída clara después de uno o varios retardos concretos, por lo que la gráfica tampoco señala un valor claro para p .



En conjunto, ambas figuras muestran que los retornos de SPY tienen poca relación lineal con sus valores anteriores. Tampoco se observa un patrón que se repita de forma regular, por lo que no habría patrones de estacionalidad en el modelo. Este comportamiento se repite en todos los ETFs. Como las gráficas no permiten elegir con claridad los parámetros p y q , se prueban distintas combinaciones y se comparan mediante los criterios: AIC, BIC y el test de Ljung-Box.

Criterios de selección de los parámetros del modelo ARIMA: AIC, BIC y test de Ljung-Box

Como se trabaja con retornos logarítmicos estacionarios, no es necesario aplicar una nueva diferencia. Por ello, el parámetro de integración se fija en $d = 0$.

La búsqueda se centra en los parámetros p y q . Tanto para los modelos diarios como semanales se prueban todas las combinaciones comprendidas entre 0 y 5 (36 combinaciones):

$$p, q \in \{0, 1, 2, 3, 4, 5\}$$

Para cada ETF se ajusta un modelo ARIMA $(p, 0, q)$ por cada combinación. Después, los modelos candidatos se comparan mediante el AIC, el BIC y el test de Ljung-Box.

- **Criterio AIC.** AIC se calcula como:


$$AIC = 2k - 2 \ln(L)$$

donde k es el número de parámetros del modelo y L indica lo bien que el modelo explica los datos observados.

El AIC busca un equilibrio entre ajuste y complejidad. Un modelo con más parámetros puede ajustarse mejor, pero también puede aprender demasiado los datos de entrenamiento. Por ello, el AIC añade una penalización por cada parámetro nuevo. Se elige el modelo con el AIC más negativo.

En este trabajo se utiliza el AIC como criterio principal porque el objetivo es predecir retornos futuros. Como se ha explicado, estos dependen de muchos factores que no se incluyen directamente en el modelo y que pueden reflejarse en los errores de predicción. Al penalizar menos la complejidad que el BIC, el AIC puede mantener componentes de media móvil que utilizan esos errores anteriores y que podrían aportar información adicional. Su utilidad se analizará posteriormente en los resultados.

En el gráfico x se muestran los valores de AIC obtenidos para las distintas combinaciones probadas en SPY. Cada punto representa un modelo ARIMA diferente. Se observan diferencias entre los modelos, lo que muestra que algunas de las 36 combinaciones de p y q se ajustan mejor que otras.



[AIC de los modelos candidatos para SPY]

En la gráfica x, los valores más bajos corresponden a ARIMA(0,0,0) y ARIMA(0,0,3). El modelo (0,0,0) se excluye porque no utiliza retornos ni errores pasados, por lo que realiza siempre la misma predicción, normalmente la media de la serie. Una vez eliminado, se selecciona ARIMA(0,0,3), que utiliza los errores de los tres periodos anteriores para ajustar la predicción.


- **Criterio BIC.** El Criterio BIC se calcula como:

$$BIC = k \ln(n) - 2 \ln(L)$$

donde n es el número de observaciones utilizadas para ajustar el modelo y de nuevo, L indica lo bien que el modelo explica los datos observados.

El BIC también compara el ajuste y la complejidad, pero penaliza más los modelos con muchos parámetros. Por eso, suele elegir modelos más sencillos que el AIC.

En la gráfica se muestran los valores de BIC de los modelos candidatos para SPY. Igual que en el AIC, el modelo preferido es el que presenta el valor más bajo. En este trabajo, el BIC se utiliza como criterio secundario. Si dos modelos presentan valores de AIC muy parecidos, se elige el que tenga el BIC más bajo.



[BIC de los modelos candidatos para SPY]


En la gráfica x del AIC veíamos que los modelos ARIMA(0,0,0) y ARIMA(0,0,3) tenían valores muy parecidos. Esto significa que, para el AIC, la mejora obtenida al incluir parámetros compensa el aumento de complejidad. En cambio, en la gráfica y del BIC existe una diferencia mucho mayor entre los primeros modelos más óptimos, ya que el BIC penaliza con más fuerza los parámetros adicionales y favorece claramente al modelo ARIMA(0,0,0).

- **Test de Ljung-Box.** Después de ajustar cada modelo, se analiza si los residuos mantienen autocorrelación. Los residuos son la diferencia entre el retorno real y el retorno predicho:

$$\varepsilon_t = r_t - \hat{r}_t$$

Si los residuos tienen autocorrelación, significa que todavía queda información en la serie que el modelo no ha conseguido entender. El test de Ljung-Box permite comprobar si existe esta información. Su hipótesis nula establece que los residuos obtenidos después de ajustar el modelo no presentan autocorrelación.

- Si el p-valor es mayor que 0,05, no se rechaza la hipótesis nula. No se encuentra una relación clara entre los residuos y el modelo se considera válido.
- Si el p-valor es menor o igual que 0,05, se rechaza la hipótesis nula, por lo que el modelo puede haber dejado información sin explicar



[P-valores del test de Ljung-Box para los modelos de SPY]

El gráfico x muestra los p-valores del test de Ljung-Box para los modelos candidatos de SPY. Todos los valores son superiores a 0,05, por lo que no quedaría autocorrelación significativa en sus residuos y ninguno de los modelos queda descartado por este criterio.

Relación entre la ACF, la PACF y el modelo seleccionado

Las gráficas ACF y PACF vistas antes, mostraban que la autocorrelación de los retornos era generalmente baja y ambas tenderían por el modelo (0,0,0). En el proceso de búsqueda hemos seleccionado modelos con $p > 0$ o $q > 0$, esto no supone una contradicción ya que las gráficas muestran que no existe una dependencia fuerte, pero puede haber relaciones pequeñas que ayuden a reducir el error posterior de la predicción. El AIC permite comprobar si esa mejora compensa el aumento de complejidad del modelo.

Por tanto, la ACF y la PACF se utilizan para comprender la serie y orientar la búsqueda, mientras que la elección definitiva se realiza mediante los valores de AIC, BIC y Ljung-Box.

Predicción *walk-forward*

La evaluación de los modelos diarios y semanales se realiza mediante el método *walk-forward*. Este procedimiento simula cómo se utilizaría el modelo en una situación real, donde solo se dispone de la información conocida hasta el momento de realizar cada predicción.

En cada paso se sigue el mismo proceso:

1. El modelo se ajusta con todos los datos disponibles hasta ese momento.
2. Se genera la predicción del periodo siguiente.

3. La predicción se guarda para compararla después con el valor real y poder calcular errores de predicción.
4. Cuando se conoce el retorno real, este se añade al conjunto histórico.
5. El modelo se vuelve a entrenar con todo el conjunto histórico actualizado y el proceso se repite.

En el análisis diario, el modelo predice el retorno del siguiente día de mercado. En el análisis semanal, predice el retorno de la semana siguiente. Se mantiene la partición temporal de entrenamiento y test definida en el capítulo de datos. El reentrenamiento en cada paso permite que el modelo utilice toda la información disponible hasta esa fecha y así ajustarse a los cambios del mercado. Esto es importante en datos financieros, ya que su comportamiento puede variaren periodos cortos de tiempo.

Evaluación de las predicciones

Las métricas utilizadas para evaluar los modelos son el RMSE, el MAE y la Kappa de Cohen, que se explicaron en el apartado 2.6. En esta fase se calculan estas métricas para todas las predicciones obtenidas durante el test.

El RMSE se utiliza como métrica principal, ya que da más peso a los errores grandes. El MAE se emplea como medida complementaria para conocer cuánto se aleja, de media, la predicción del retorno real. También se calcula la Kappa de Cohen para estudiar si el modelo acierta la dirección del retorno. Esta métrica permite comprobar si el modelo acierta las subidas y bajadas más de lo que podría esperarse por azar.

Los resultados, además, se comparan con dos modelos de referencia:

- Modelo naive: utiliza el retorno observado en el periodo anterior como predicción del siguiente.
- Modelo zero: predice siempre un retorno igual a cero.

Para estos dos modelos también se calculan RMSE y MAE. De esta forma, no solo se comparan los distintos modelos ARIMA entre sí, sino que también se comprueba si mejoran sus métricas de predicción.

La selección final se hace comparando principalmente el RMSE de cada uno de los 3 modelos (ARIMA, naive y zeros), pero se revisan también el MAE y la Kappa de Cohen para obtener una valoración más completa. Un modelo puede tener un error bajo y, al mismo tiempo, no acertar correctamente la dirección de los retornos, por lo que ambas formas de evaluación aportan información diferente.

Tras completar este proceso para todos los ETFs y para las dos frecuencias (semanal y diaria), se presentan los resultados obtenidos en el siguiente apartado

4.1.7 Resultados

Modelo diario

El modelo diario se aplica a 56 de los 58 ETFs seleccionados. En los casos de HYG y JNK, ninguna de las combinaciones ARIMA probadas supera el test de Ljung-Box, ya que sus residuos siguen presentando autocorrelación. La siguiente tabla resume los errores medios obtenidos por ARIMA y por los dos modelos de referencia durante el test.

Modelo	RMSE medio	MAE medio
ARIMA	0,01127	0,00787
Baseline (t-1)	0,01613	0,01149
Zeros	0,01124	0,00785

ARIMA mejora al modelo baseline, tanto en RMSE como en MAE. Sin embargo, sus resultados son muy parecidos a los del modelo zeros y ligeramente peores de media. Esta comparación es importante porque los retornos diarios suelen tomar valores muy cercanos a cero. Por ello, una predicción constante de cero puede obtener un error reducido sin detectar ningún patrón. Si ARIMA consigue mejorar este resultado, significa que está aprovechando información de los retornos pasados para acercarse más al valor real.

La siguiente tabla presenta los resultados por grupos de activos. Las dos últimas columnas muestran cuántos ETFs de cada grupo obtienen un RMSE menor que el baseline y que el modelo zeros:

Grupo	N	RMSE ARIMA	RMSE BASE	RMSE ZEROS	MAE ARIMA	Bate base	Bate zeros
Core US	10	0,01190	0,01730	0,01187	0,00802	10/10	1/10
Factores	11	0,01055	0,01518	0,01051	0,00722	11/11	0/11
Sectores	11	0,01176	0,01686	0,01171	0,00841	11/11	0/11

Internacional	15	0,01232	0,01764	0,01230	0,00870	15/15	3/15
Renta fija	6	0,00403	0,00557	0,00403	0,00312	6/6	3/6
Materias primas	3	0,01921	0,02657	0,01921	0,01311	3/3	1/3

ARIMA diario obtiene un RMSE menor que el baseline en todos los ETFs analizados, con una reducción media del error del 30,13 %. El baseline utiliza el último retorno observado como predicción del siguiente, pero los retornos diarios suelen tener poca relación con el día anterior. Por ello, repetir el último valor genera un error mayor que las predicciones de ARIMA.



ARIMA diario solo supera al modelo cero en 8 de los 56 ETFs. Como los retornos suelen estar cerca de cero, predecir siempre cero produce poco error. ARIMA intenta predecir si el retorno subirá o bajará, pero no siempre acierta la dirección. Por eso, en la mayoría de los ETFs no consigue mejorar al modelo cero.

Las diferencias de RMSE entre grupos están relacionadas principalmente con la volatilidad de los activos. La renta fija presenta el menor error, con un RMSE medio de 0,00403, porque sus retornos diarios suelen tener cambios más pequeños. Además, 3 de sus 6 ETFs superan al modelo zeros, el mejor resultado entre los grupos.


Las materias primas tienen el error más alto. Activos como la plata o el petróleo pueden tener movimientos fuertes por cambios en la oferta, la demanda o el contexto internacional, factores que no se incluyen directamente en ARIMA.


En conjunto, el modelo diario reduce de forma clara el error frente al baseline, pero casi no mejora la predicción constante de cero. Esto muestra que gran parte de su buen resultado se debe a generar valores pequeños, pero que la información temporal que consigue extraer de los retornos es limitada.

A modo de ejemplo, el gráfico siguiente muestra las predicciones del modelo ARIMA para dos ETFs: SPY y DVY, durante el periodo de test. En la versión a escala original se observa cómo las predicciones son de magnitud muy pequeña comparada con los retornos reales y en la versión de ARIMA multiplicada por 10 para aumentar su escala, se pueden ver la forma de las predicciones que el modelo genera.



[Predicciones ARIMA vs real vs baseline — SPY diario (escala original)]






[Predicciones ARIMA×10 vs real vs baseline — SPY diario]

En cuanto a la dirección del movimiento, el modelo ARIMA diario obtiene una Kappa media de $-0,0012$ y un porcentaje medio de aciertos del 49,65%. Estos valores están muy cerca del azar, que sería aproximadamente un 50%.

Los resultados cambian según el ETF. Una Kappa negativa indica que la dirección predicha coincide con la real menos de lo que se esperaría por azar. En el gráfico x, las barras verdes representan valores positivos de Kappa para cada ETF y las rojas valores negativos.



[Kappa de Cohen por ETF — ARIMA vs baseline — diario]

4.1.3 Modelo semanal

El modelo semanal se aplica a los 58 ETFs seleccionados. En esta frecuencia, todos los activos encuentran al menos una combinación ARIMA válida según el test de Ljung-Box. La agrupación semanal reduce parte de las variaciones diarias y permite trabajar con series más estables. La tabla siguiente muestra los errores medios globales en el período de test:

Modelo	RMSE medio	MAE medio
ARIMA	0,00492	0,00365
Baseline (t-1)	0,00714	0,00537
Zeros	0,00492	0,00367

ARIMA supera al baseline en los 58 ETFs y reduce el RMSE medio un 31 % más bajo Frente al modelo cero, el RMSE es el mismo. Sin embargo, ARIMA obtiene un MAE ligeramente menor, de 0,00365 frente a 0,00367. Además, ARIMA semanal supera al modelo cero en 30 de los 58 ETFs, frente a solo 8 en el análisis diario. Esto indica que agrupar los datos por semanas consigue aprovechar mejor la información de periodos anteriores.

La siguiente tabla muestra los resultados por tipo de activo. Las dos últimas columnas, como en el caso anterior, indican cuántos ETFs de cada grupo presentan un RMSE menor que el baseline y que el modelo cero.

Grupo	N	RMSE ARIMA	RMSE BASE	RMSE ZEROS	MAE ARIMA	Bate base	Bate zeros
Core US	10	0,00509	0,00777	0,00513	0,00383	10/10	10/10
Factores	11	0,00458	0,00694	0,00461	0,00344	11/11	9/11
Sectores	11	0,00521	0,00769	0,00519	0,00400	11/11	5/11
Internacional	15	0,00551	0,00765	0,00547	0,00417	15/15	2/15
Renta fija	8	0,00187	0,00269	0,00185	0,00139	8/8	2/8
Materias primas	3	0,00973	0,01311	0,00971	0,00666	3/3	2/3



Los mejores resultados frente al modelo cero aparecen en Core US y Factores. Esto supone una gran mejora respecto al análisis diario y muestra que los índices estadounidenses tienen un comportamiento más aprovechable cuando se estudian por semanas. La renta fija vuelve a presentar los errores más bajos. Sin embargo, solo 2 de los 8 ETFs superan al modelo cero, precisamente porque sus retornos están muy concentrados alrededor de ese valor. Las materias primas siguen teniendo el RMSE más alto, con un valor medio de 0,00973.

En conjunto, la frecuencia semanal mantiene la mejora frente al baseline y aumenta el número de ETFs que superan al modelo cero. La reducción del ruido diario permite que ARIMA obtenga mejores resultados.

En los gráficos semanales se observa que las predicciones de ARIMA son mucho más pequeñas que los retornos reales y se mantienen cerca de cero. Por eso, el modelo no capta del todo bien las semanas con subidas o bajadas fuertes. Al multiplicar las predicciones por 10 para ver mejor la dirección del modelo, se aprecia que en algunos ETFs, como SPY, ARIMA sigue parte de los cambios de dirección, aunque no acierta su tamaño. En otros, como DVY, la predicción se mantiene casi plana, lo que muestra que hay poca información útil en los valores anteriores.




[Predicciones ARIMA vs real vs baseline — SPY semanal (escala original)]



[Predicciones ARIMA×10 vs real vs baseline — SPY semanal]

En cuanto a la dirección, el modelo semanal obtiene una Kappa media de 0,0290 y una accuracy del 50,30%. Los mejores resultados aparecen en VIG, con una Kappa de 0,32 y un 65,4 % de aciertos, y en DIA, con una Kappa de 0,23 y un 60,5 % de aciertos. En cambio, sigue habiendo valores negativos.

En general, la kappa media mejora en comparación al caso anterior, los resultados cambian bastante entre ETFs y no siguen un patrón claro según el grupo de activos.



Comparación entre frecuencia diaria y semanal

En ambas frecuencias, ARIMA mejora al modelo baseline en aproximadamente un 30%. La diferencia más clara aparece al compararlos con el modelo cero. El modelo diario lo supera en 8 de los 56 ETFs, mientras que el semanal lo hace en 30 de los 58. Por tanto, al agrupar los datos por semanas, ARIMA consigue aprovechar mejor la información de los periodos anteriores.

La predicción de la dirección también mejora ligeramente. La Kappa media pasa de $-0,0012$ en diario a $0,0290$ en semanal. Aunque los valores siguen siendo bajos, la frecuencia semanal obtiene mejores resultados.

Por estos motivos, se selecciona el modelo ARIMA semanal como la mejor opción dentro de los modelos de series temporales. A continuación, se comparará con modelos de aprendizaje automático para decidir qué enfoque ofrece las predicciones más útiles para la cartera de Markowitz.

4.2 Modelización mediante aprendizaje automático

Después del análisis con modelos de series temporales, entramos la predicción de retornos mediante aprendizaje automático supervisado. La principal diferencia es que ARIMA analiza cada ETF por separado utilizando solo sus datos históricos. En cambio, los modelos de machine learning pueden usar al mismo tiempo información de todos los ETFs, del volumen y de variables temporales y así poder añadir relaciones entre activos.

4.2.1 Preprocesamiento de los datos

Se construyen de nuevo dos versiones de distinta frecuencia, una diaria y otra semanal. En ambas frecuencias se parte de los mismos datos de origen que en los modelos ARIMA: precios ajustados de cierre descargados con yfinance para el período 2021-01-04 a 2026-02-02, utilizando el 70% de las observaciones más antiguas para el conjunto de entrenamiento y el 30% restante para el conjunto de test. Además, los modelos de aprendizaje automático añaden el volumen diario por ETF como una variable de entrada adicional.

También se mantienen los mismos 58 ETFs. Se eliminan BIL, EWY, GLD, IAU y SHY porque sus retornos no mostraron un comportamiento estacionario. De esta forma, ambos enfoques trabajan con los mismos activos y sus resultados pueden compararse en las mismas condiciones.

Preprocesado para la frecuencia diaria

El dataset diario toma como base los retornos logarítmicos diarios y el cambio logarítmico del volumen. Cada fila representa un día de mercado y contiene el estado completo del universo en ese momento.

Variables de retorno logarítmico diario. Igual que en el análisis ARIMA, a partir de los precios ajustados de cierre se calculan los retornos diarios de los 58 ETFs, obteniendo una columna de retornos por cada activo.

Variables de diferencia logarítmica de volumen. Para cada ETF se calcula el cambio del volumen respecto al día anterior mediante logaritmos. Esta variable permite medir si la actividad de compra y venta ha aumentado o disminuido. En total, se añaden 58 columnas de volumen.

Variables de calendario. Se incluyen variables binarias para cada día de la y variables binarias que señalan si la fecha corresponde al inicio o al final de un mes y al inicio o al final de un trimestre. Estas variables permiten estudiar si el momento del calendario influye en los retornos, ya que en algunas fechas los inversores pueden comprar o vender de forma diferente. En total, se añaden nueve variables de calendario.

Variable objetivo (target). Para cada ETF se crea una columna llamada target con el retorno logarítmico real del día siguiente. Así, cada fila contiene la información conocida en el día actual y el valor que el modelo debe aprender a predecir. La última fila se elimina porque no existe un día posterior del que obtener el retorno. Durante el entrenamiento, el target se utiliza para que el modelo aprenda. En el periodo de test, se mantiene separado y solo se usa después para comparar el retorno real con la predicción obtenida.

Lags (retardos). Un lag es el valor que tuvo una variable en un periodo anterior. Por ejemplo, el lag 1 es el retorno del día anterior, el lag 2 es el retorno de hace dos días. Para comprobar si esta información mejora la predicción, se crean cinco versiones del conjunto de datos. La primera utiliza solo el retorno del día actual. Las demás añaden los retornos de uno, dos, tres o cuatro días anteriores

Las dimensiones de cada dataset diario son:

Dataset	Lags	Filas	Columnas
df_diario.csv	0	1.275	125
df_diario_1.csv	1	1.274	125 + 58 = 183
df_diario_2.csv	2	1.273	241
df_diario_3.csv	3	1.272	299
df_diario_4.csv	4	1.271	357

Al añadir cada retardo se incorporan 58 columnas nuevas, una por cada ETF. El número de filas disminuye en una observación por cada lag añadido, ya que los primeros días no tienen datos anteriores suficientes. Estas filas iniciales, que contienen valores vacíos, se eliminan del conjunto de datos.

Preprocesado para la frecuencia semanal

Para construir el conjunto de datos semanal, primero se agrupan los datos diarios por semanas del calendario ISO, con formato YYYY-Www.

Variables de retorno logarítmico semanal. Para cada ETF se calcula la media de los retornos logarítmicos diarios de cada semana. Se utiliza la misma forma de agrupación que en el modelo ARIMA semanal para poder comparar ambos enfoques en las mismas condiciones

Variables de diferencia logarítmica del volumen semanal. El volumen se calcula como la media diaria de cada semana. De esta forma, se pueden comparar semanas con distinto número de días de mercado. Después, se calcula su cambio logarítmico respecto a la semana anterior.

Variables de calendario. Se añaden cuatro variables binarias que indican si la semana contiene el inicio o el final de un mes o de un trimestre. Estas variables permiten comprobar si esos momentos del calendario influyen en los retornos.

Variable objetivo y lags. El target de cada ETF es el retorno de la semana siguiente. Igual que en el caso diario, se crean cinco versiones del conjunto de datos: sin retardos y con uno, dos, tres o cuatro retornos semanales anteriores. Las dimensiones de cada dataset semanal son:

Dataset	Lags	Filas	Columnas
df_semanal.csv	0	264	182
df_semanal_1.csv	1	264	240
df_semanal_2.csv	2	263	298
df_semanal_3.csv	3	262	356
df_semanal_4.csv	4	261	414

El primer retardo no reduce de nuevo el número de filas porque la primera semana ya se había eliminado al calcular la diferencia logarítmica del volumen. A partir del segundo retardo, cada lag adicional elimina una observación más por falta de información histórica. Estas cinco versiones permiten comprobar si los retornos de semanas anteriores aportan información útil y ayudan a mejorar la predicción del retorno de la semana siguiente.

4.2.2 Selección de Modelos

Se prueban cuatro modelos de regresión: Regresión Lineal, Ridge, Random Forest y Gradient Boosting. Su funcionamiento general se explicó en el capítulo de preliminares. Cada modelo se entrena con los cinco archivos CSV creados anteriormente, que contienen entre 0 y 4 lags. Así, se puede comparar tanto qué modelo obtiene mejores resultados como si añadir retardos al modelo mejora las predicciones. En este apartado se explican las decisiones tomadas para entrenar cada modelo y ajustar sus parámetros.

Regresión lineal

La regresión lineal se incluye como el modelo más sencillo y sirve como punto de partida para comparar el resto. No tiene hiperparámetros que ajustar, por lo que se entrena directamente con los datos disponibles.

Para este modelo, el número de variables es elevado en comparación con el número de observaciones, especialmente en el conjunto semanal. Al añadir retardos, el modelo dispone de muchas columnas y puede ajustarse demasiado a los datos de entrenamiento, pero no saber adaptarse con datos nuevos (sobreajuste).

Ridge

Ridge parte de una regresión lineal, pero añade una penalización que evita que los coeficientes alcancen valores demasiado altos. Esto es útil en nuestro caso ya que hay muchas variables iniciales.

Antes de entrenar el modelo, las variables se escalan mediante `StandardScaler`. Este paso coloca todas las variables en una escala parecida, evitando que la penalización afecte de forma distinta a variables como los retornos, el volumen o los indicadores de calendario.

El principal hiperparámetro de Ridge es α , que controla la fuerza de la penalización. Un valor mayor reduce más los coeficientes, mientras que un valor menor hace que el modelo se parezca más a una regresión lineal normal.

El valor de α se selecciona antes de comenzar la evaluación `walk-forward`. Para ello, se utiliza `RidgeCV` que prueba distintos valores de α entre 100 y 100.000 utilizando una validación temporal `TimeSeriesSplit` con cinco divisiones del conjunto de `train`. En cada división, el modelo se entrena con datos anteriores y se valida con un periodo posterior, sin mezclar observaciones futuras y pasadas. Tras las cinco comprobaciones, se elige el valor de α que obtiene el menor error medio. A continuación, el modelo se entrena de nuevo con el parámetro seleccionado y se aplica el proceso `walk-forward` durante todo el periodo de `test`.

Random Forest

Random Forest construye muchos árboles de decisión y calcula la predicción final como la media de todos ellos. Cada árbol utiliza una parte diferente de los datos y de las variables, lo que reduce la dependencia de un único árbol y ayuda a controlar el sobreajuste.

Este modelo puede detectar relaciones no lineales mediante reglas sucesivas sobre las variables. Además, no necesita escalado previo, ya que los árboles comparan cada variable con distintos valores límite y no dependen de que todas estén medidas en la misma escala.

Primero se realiza una fase de validación para encontrar los mejores hiperparámetros de Random Forest. Para ello, `RandomizedSearchCV` prueba 30 combinaciones elegidas al azar entre todas las posibles de `acotinaución` y utiliza también `TimeSeriesSplit` con cinco divisiones. Los parámetros probados son:

- `N_estimators`: número de árboles, con valores de 50, 100, 200 y 300.
- `Max_depth`: profundidad máxima de los árboles, con valores None, 3, 5, 10, 15 y 20.
- `Min_samples_leaf`: número mínimo de observaciones que debe contener cada hoja final del árbol, con valores 1, 2, 5 y 10.
- `Max_features`: cantidad de variables que puede utilizar cada árbol en una división, con valores sqrt, 30%, 50%, 70% y 100%. El valor sqrt utiliza la raíz cuadrada del número total de variables.

En total hay $4 \times 6 \times 4 \times 5 = 480$ combinaciones posibles de parámetros, pero solo se prueban 30 para reducir el tiempo de ejecución. La búsqueda se hace una vez por cada archivo CSV usando un ETF como referencia. Después, esos parámetros se aplican al resto de ETFs del mismo archivo. Esta decisión se toma para evitar un tiempo de cálculo demasiado elevado. Una vez elegida la configuración, comienza la evaluación walk-forward.

Gradient Boosting

Gradient Boosting también utiliza árboles de decisión, pero los construye de forma consecutiva. Cada nuevo árbol intenta corregir parte de los errores realizados por los anteriores.

Este modelo puede estudiar relaciones no lineales, aunque necesita un mayor control para evitar el sobreajuste, especialmente en el conjunto semanal, que contiene pocas observaciones.

La búsqueda de hiperparámetros sigue el mismo procedimiento que en Random Forest: RandomizedSearchCV con 30 combinaciones y una validación TimeSeriesSplit de cinco divisiones. Además, se añaden 2 nuevos hiperparámetros propios de este modelo:

- `Learning_rate`: controla cuánto influye cada nuevo árbol en la predicción final. Se prueban los valores 0'01, 0'05, 0'1 y 0'2. Un valor pequeño realiza correcciones más suaves y suele necesitar más árboles, mientras que un valor alto corrige más rápido, pero puede aumentar el riesgo de sobreajuste.
- `Subsample`: indica qué parte de las observaciones se utiliza para entrenar cada árbol. Se prueban valores del 60 %, 80 % y 100 % del conjunto de entrenamiento. Utilizar menos observaciones añade variedad entre los árboles y puede reducir el sobreajuste, mientras que un valor del 100 % utiliza todos los datos disponibles.

El espacio total contiene $4 \times 6 \times 4 \times 5 \times 4 \times 3 = 5760$ combinaciones posibles, de las que se prueban 30. Los parámetros `max_depth`, `learning_rate` y `subsample` ayudan a controlar cuánto aprende el modelo y evitan que se ajuste demasiado a los datos de entrenamiento.

Predicción walk-forward y evaluación de predicciones

La evaluación de los modelos de aprendizaje automático sigue el mismo procedimiento utilizado en ARIMA. Se mantiene la misma división temporal y se aplica el método de predicción walk-forward. En cada paso, el modelo se entrena con toda la información disponible hasta ese momento, predice el periodo siguiente y después incorpora el valor real al conjunto histórico y repite el proceso.

Para evaluar los resultados también se utilizan las mismas métricas y modelos de referencia que en ARIMA: RMSE, MAE y Kappa de Cohen, junto con el modelo base-line y el modelo cero. Mantener el mismo periodo de prueba, las mismas métricas y las mismas referencias permite comparar de forma directa los resultados de los modelos de series temporales y de aprendizaje automático.

Registro de experimentos con Google Sheets

La combinación de 5 archivos csv de datos por cada una de las frecuencias, 58 ETFs y 4 modelos ML, genera un total de 1.160 experimentos por frecuencia, 2.320 en total. Para gestionar este volumen, el notebook de entrenamiento está organizado como una cola de experimentos y los resultados se guardan automáticamente en una hoja de Google Sheets accesible en tiempo real mediante la API de Google Drive.

Cada fila de la hoja representa un experimento e incluye:

- Identificación: archivo de datos, modelo, ETF objetivo.
- Estado: pendiente, en ejecución, error o completado.
- Fechas de inicio y fin de ejecución.
- Resultados: RMSE, MAE, RMSE_baseline, RMSE_zeros, MAE_baseline, MAE_zeros.
- Hiperparámetros encontrados de los modelos: Alpha (Ridge), `n_estimators`, `max_depth`, `min_samples_leaf`, `max_features` (RF y GBR), `learning_rate`, `subsample` (GBR).
- Rango temporal de predicciones: `FechaPredIni`, `FechaPredFin`, `FechaTrainIni`, `FechaTrainFin`.

Este registro permite detener y reanudar la ejecución sin perder los resultados ya obtenidos. Esto es necesario porque el proceso necesita mucho tiempo de ejecución y puede interrumpirse por algún error o cierre inesperado. Además, la hoja se utiliza como base de datos para analizar y comparar posteriormente los resultados.

4.2.3 Resultados

De nuevo, para cada combinación de modelo y número de lags se calcula el RMSE y MAE medios sobre los 58 ETFs en el período de test. Los resultados se presentan primero para la frecuencia diaria, después para la semanal, y a continuación se comparan ambas frecuencias para seleccionar el modelo de aprendizaje automático con mejores resultados.

Resultados del modelo diario

Las tablas siguientes muestra el RMSE y MAE medio global por modelo y número de lags en frecuencia diaria del período de test (aproximadamente 385 días por ETF):


Lags	RMSE Lin. Reg.	RMSE Ridge	RMSE RF	RMSE GBR	RMSE base	RMSE Zeros
0	0,01203	0,01126	0,01124	0,01125	0,01616	0,01123
1	0,01278	0,01132	0,01129	0,01129	0,01616	0,01123
2	0,01364	0,01129	0,01127	0,01129	0,01616	0,01123
3	0,01432	0,01127	0,01126	0,01132	0,01616	0,01123
4	0,01485	0,01128	0,01126	0,01124	0,01616	0,01123

Lags	MAE Lin. Reg.	MAE Ridge	MAE RF	MAE GBR	MAE base	MAE Zeros
0	0,00852	0,00770	0,00769	0,00769	0,01124	0,00769
1	0,00898	0,00775	0,00771	0,00771	0,01124	0,00769
2	0,00959	0,00772	0,00771	0,00773	0,01124	0,00769
3	0,01014	0,00772	0,00770	0,00770	0,01124	0,00769
4	0,01078	0,00772	0,00770	0,00768	0,01124	0,00769

Ridge, Random Forest y Gradient Boosting obtienen resultados muy parecidos. En los tres modelos, añadir retardos no mejora la predicción y, en general, aumenta ligeramente el error. Esto confirma lo observado con ARIMA: los retornos de días anteriores aportan muy poca información sobre el retorno del día siguiente. En la regresión lineal, el empeoramiento es mucho más claro, ya que el aumento del número de variables tiende al sobreajuste.

Los tres modelos mejoran al baseline, con una reducción del RMSE cercana al 30 %. Sin embargo, sus resultados son prácticamente iguales y ligeramente peores que los del modelo cero. Random Forest con 0 lags obtiene uno de los menores MAE y el menor RMSE, con un valor de 0,01124. Por este motivo, se selecciona como la mejor configuración diaria para las comparaciones posteriores.

El gráfico siguiente muestra la evolución del RMSE de Random Forest para cada ETF al aumentar el número de lags. Las líneas se mantienen prácticamente horizontales, lo que confirma que añadir retornos de días anteriores casi no modifica el error de predicción.



[Evolución del RMSE diario por número de lags — Random Forest]

Una vez seleccionado Random Forest con 0 lags, se analizan sus resultados por grupos de ETFs. La tabla siguiente muestra el error medio de cada grupo y el número de ETFs que superan al baseline y al modelo cero.

Grupo	N	RMSE RF	RMSE BASE	RMSE CEROS	MAE RF	Bate base	Bate ceros
Core US	10	0,01236	0,01725	0,01236	0,00810	10/10	6/10

Factores	11	0,01106	0,01623	0,01105	0,00738	11/11	7/11
Sectores	11	0,01221	0,01714	0,01221	0,00856	11/11	3/11
Internacional	15	0,01209	0,01673	0,01210	0,00848	15/15	9/15
Renta fija	8	0,00376	0,00521	0,00378	0,00280	8/8	3/8
Materias primas	3	0,02029	0,02775	0,02021	0,01340	3/3	1/3

Los resultados por grupos siguen un patrón parecido al observado en ARIMA: la renta fija presenta los errores más bajos y las materias primas los más altos. Por tanto, las diferencias de RMSE dependen mucho del nivel de variación de cada tipo de activo.

Random Forest supera al baseline en todos los ETFs, pero los resultados frente al modelo cero son más variados. El grupo internacional obtiene el mejor resultado, habiendo 9 de 15 ETFs que superan a cero, seguido de Factores, con 7 de 11, y Core US, con 6 de 10. En los demás grupos, la mejora aparece en menos activos.

En conjunto, Random Forest con 0 lags tiene el mejor rendimiento en frecuencia diaria. Sin embargo, sus resultados son casi iguales a los del modelo cero, por lo que la mejora que aporta este modelo es muy pequeña.

Resultados del modelo semanal

Las tablas x e y muestran el RMSE y el MAE medios obtenidos por cada modelo según el número de lags utilizados.

Lags	RMSE Lin. Reg.	RMSE Ridge	RMSE RF	RMSE GBR	RMSE base	RMSE Zeros
0	0,00784	0,00490	0,00491	0,00494	0,00717	0,00494
1	0,01437	0,00492	0,00492	0,00491	0,00717	0,00494
2	0,02840	0,00492	0,00491	0,00493	0,00717	0,00494
3	0,01782	0,00492	0,00492	0,00491	0,00717	0,00494
4	0,01419	0,00492	0,00493	0,00498	0,00717	0,00494


Lags	MAE Lin. Reg.	MAE Ridge	MAE RF	MAE GBR	MAE base	MAE Zeros
0	0,00605	0,00365	0,00367	0,00372	0,00539	0,00369
1	0,01064	0,00366	0,00368	0,00367	0,00539	0,00369
2	0,02047	0,00367	0,00366	0,00369	0,00539	0,00369
3	0,01400	0,00366	0,00367	0,00366	0,00539	0,00369
4	0,01127	0,00366	0,00367	0,00378	0,00539	0,00369

Ridge, Random Forest y Gradient Boosting presentan resultados muy parecidos en todas las configuraciones. Igual que en el análisis diario, añadir retornos de semanas anteriores no mejora de forma clara la predicción, ya que el error se mantiene casi igual o aumenta ligeramente entre 0 y 4 lags. De nuevo, la regresión lineal muestra un comportamiento diferente. Al añadir retardos, su error aumenta de forma considerable, especialmente con 2 lags.

Además, Ridge, Random Forest y Gradient Boosting superan al baseline en todas las configuraciones y también obtienen un error algo menor que el modelo cero, algo que no ocurría en el análisis diario.

Ridge con 0 lags obtiene el menor RMSE, con un valor de 0,00490, y el menor MAE, con 0,00365. También supera al baseline en los 58 ETFs y al modelo cero en 44 de ellos. Por ello, se selecciona como la mejor configuración semanal de aprendizaje automático.

La gráfica x muestra la evolución del RMSE de Ridge para cada ETF al aumentar el número de lags. Al igual que en el modelo diario, las líneas se mantienen casi horizontales, lo que confirma que añadir retornos de semanas anteriores casi no cambia el error y apoya la elección de la configuración sin lags.



[Evolución del RMSE semanal por número de lags — Ridge)]

Los resultados por grupo de activos con Ridge 0 lags los observamos en la tabla x:

Grupo	N	RMSE Ridge	RMSE BASE	RMSE ZEROS	MAE Ridge	Bate base	Bate zeros
Core US	10	0,00507	0,00782	0,00514	0,00380	10/10	10/10
Factores	11	0,00455	0,00698	0,00462	0,00339	11/11	11/11
Sectores	11	0,00519	0,00773	0,00521	0,00394	11/11	7/11
Internacional	15	0,00550	0,00766	0,00550	0,00415	15/15	11/15
Renta fija	8	0,00186	0,00271	0,00186	0,00139	8/8	3/8
Materias primas	3	0,00974	0,01319	0,00975	0,00656	3/3	2/3

Los resultados por grupos mantienen el patrón observado anteriormente: la renta fija presenta el RMSE más bajo y las materias primas el más alto. La principal mejora aparece frente al modelo cero, ya que todos los ETFs de Core US y Factores consiguen superarlo. Sectores e Internacional muestran resultados intermedios, mientras que en renta fija solo 3 de 8 ETFs mejoran a cero, debido a que sus retornos suelen estar muy próximos a ese valor. En conjunto, Ridge con 0 lags supera al baseline en todos los ETFs y al modelo cero en la mayoría de ellos.

Comparación entre frecuencia semanal y diaria

El mejor resultado diario corresponde a Random Forest con 0 lags, mientras que en frecuencia semanal destaca Ridge con 0 lags. Ambos mejoran claramente al baseline, pero la diferencia principal aparece frente al modelo cero. En diario, Random Forest obtiene resultados prácticamente iguales a esta referencia. En cambio, Ridge semanal consigue mejorar ligeramente tanto el RMSE como el MAE y supera al modelo cero en 44 de los 58 ETFs. Por ello, Ridge con 0 lags en frecuencia semanal se selecciona como el mejor modelo de aprendizaje automático para estos datos.

4.3 Comparación entre ML y Series Temporales y selección del modelo predictor para Markowitz


En los apartados anteriores se seleccionó el mejor modelo de cada enfoque: ARIMA semanal para las series temporales y Ridge semanal con 0 lags para el aprendizaje automático. Ambos parten de las mismas condiciones: frecuencia semanal, mismo periodo de prueba y los mismos 58 ETFs.

ARIMA semanal

De los 58 ETFs analizados, ARIMA semanal obtiene un RMSE menor que el modelo cero en 30. Los resultados medios, como hemos visto antes, son:

Modelo	RMSE medio	MAE medio
ARIMA	0,00492	0,00365
Baseline (t-1)	0,00714	0,00537
Zeros	0,00492	0,00367

Los resultados de la Kappa de Cohen son positivos. 21 de los 58 ETFs presentan una Kappa negativa, mientras que en los 37 restantes ARIMA acierta la dirección semanal mejor que una elección al azar.



[Kappa de Cohen por ETF — ARIMA semanal ETFs]


Ridge 0 lags semanal

Ridge obtiene un RMSE menor que el modelo cero en 44 de los 58 ETFs. Las métricas medias de este conjunto son:

Modelo	RMSE medio	MAE medio
Ridge (0 lags)	0,00490	0,00365
Baseline (t-1)	0,00717	0,00539
Zeros	0,00494	0,00369

Sin embargo, los resultados de Kappa son menos favorables. Solo 13 de los 58 ETFs tienen una Kappa positiva. En los 45 restantes, el modelo no acierta la dirección mejor que el azar.

Esto muestra que un RMSE bajo no significa que el signo de la predicción sea correcto. El RMSE mide cuánto se aleja la predicción del valor real, pero no indica si ambos tienen el mismo signo. Como los retornos suelen estar cerca de cero, *Ridge* puede obtener un error bajo, aunque no acierte si el ETF sube o baja. Por eso, la Kappa permite completar el análisis y comprobar si la dirección predicha es correcta.



[Kappa de Cohen por ETF — Ridge 0 lags semanal — ordenado de mayor a menor]

Comparativa final de los modelos

Aunque Ridge obtiene un RMSE ligeramente menor que ARIMA, ARIMA presenta mejores resultados al predecir la dirección del retorno: obtiene una Kappa positiva en 37 de los 58 ETFs, mientras que Ridge solo en 13 de 58.

Este resultado es importante para Markowitz, ya que el modelo utiliza los retornos esperados para repartir el peso de la cartera. Si se predice una subida, el optimizador puede asignar más peso a ese activo. Si el signo es incorrecto, la cartera puede aumentar la inversión en un ETF que finalmente baja o reducirla en uno que sube. Por ello, para esta aplicación no solo importa que el error sea pequeño, sino también acertar la dirección del movimiento.

Una posible explicación del mejor resultado direccional de ARIMA es que sus componentes de media móvil utilizan errores anteriores para ajustar nuevas predicciones. Estos errores pueden reflejar parte del efecto de noticias o cambios externos que no se incluyen directamente en los datos. Además, mediante el proceso *walk-forward*, el modelo se actualiza cada semana con la nueva información. Ridge con 0 lags, en cambio, no utiliza directamente el error de la predicción anterior. Esta diferencia puede ser la explicación de por qué ARIMA capta mejor algunos cambios de dirección.

Por estos motivos, se selecciona ARIMA semanal como predictor para la optimización de Markowitz. En el apartado siguiente se explica cómo se utilizan sus predicciones para construir y evaluar la cartera.

Capítulo 5 - OPTIMIZACIÓN DE CARTERAS - MARKOWITZ

Como se explicó en el capítulo de preliminares, el modelo de Markowitz reparte el capital entre distintos activos teniendo en cuenta dos elementos: la rentabilidad que se espera obtener y el riesgo de la cartera. Busca una combinación de activos que permita obtener una buena rentabilidad sin asumir un riesgo demasiado elevado. A partir de estos valores, el modelo calcula los pesos, es decir, el porcentaje del capital que debe invertirse en cada ETF. En este capítulo se aplica este método a los activos estudiados anteriormente.

La rentabilidad esperada es el retorno que se estima para cada ETF durante la semana siguiente. Para calcularla se comparan tres estrategias: la media histórica, el retorno de la última semana y la predicción de ARIMA.

El riesgo se calcula a partir de los retornos anteriores y tiene en cuenta tanto la variación de cada ETF como la relación entre ellos. Las tres estrategias utilizan los mismos 58 ETFs, el mismo periodo y la misma frecuencia semanal para que la comparación se realice en las mismas condiciones.

5.1 Estrategias comparadas

Se evalúan tres estrategias de Markowitz que utilizan distintas formas de calcular el retorno esperado μ de la semana siguiente. En todas se mantienen el mismo cálculo del riesgo y las mismas restricciones, por lo que las diferencias en los resultados se deben únicamente a la forma de estimar el retorno.

Estrategia 1: Markowitz con media histórica

En esta estrategia, el retorno esperado de cada ETF se calcula como la media de todos sus retornos semanales anteriores, donde:

$$\mu_{i,t+1} = \frac{1}{T} \sum_{s=1}^T r_{i,s}$$

$\mu_{i,t+1}$ es el retorno esperado del ETF i para la semana siguiente.

$r_{i,s}$ es el retorno semanal del ETF i en la semana s .

T es el número de semanas disponibles hasta ese momento.

Esta estimación utiliza toda la información histórica disponible, por lo que suele ser estable y cambia poco entre semanas. Sin embargo, tarda más en reflejar los cambios recientes del mercado, ya que los retornos antiguos tienen el mismo peso que los más actuales. Esta estrategia se utiliza como referencia porque es una forma sencilla y habitual de calcular el retorno esperado en Markowitz [1].

Estrategia 2: Markowitz con último valor observado

En este caso, se utiliza el retorno de la última semana como estimación para la semana siguiente:

$$\mu_{i,t+1} = r_{i,t}$$

Por tanto, se supone que el ETF continuará con el mismo comportamiento que tuvo en la semana anterior. Si el último retorno fue positivo, se espera una nueva subida; si fue negativo, se espera una bajada.

Esta estrategia responde de forma rápida a los cambios del mercado, pero también es muy sensible a movimientos puntuales. Un cambio muy fuerte en una semana puede hacer que el optimizador modifique bastante la distribución de la cartera, aunque ese comportamiento haya sido puntual y no continúe la semana siguiente.

Estrategia 3: Markowitz con predicciones ARIMA

En esta estrategia, el retorno esperado de cada ETF es la predicción obtenida mediante el modelo ARIMA semanal. Las predicciones se generan mediante el proceso *walk-forward*, por lo que en cada momento solo se utilizan datos anteriores.

5.2 Matriz de covarianzas

La matriz de covarianzas permite calcular el riesgo de la cartera. Por una parte, recoge cuánto varían los retornos de cada ETF. Por otra, muestra si dos activos suelen moverse en la misma dirección o de forma diferente. Esta relación es importante porque combinar ETFs que no se comportan igual puede reducir el riesgo total de la cartera.

Al trabajar con 58 ETFs, hay que calcular 58 x 58 relaciones diferentes a partir de un número limitado de semanas. Por ello, algunas estimaciones pueden cambiar mucho por movimientos puntuales del mercado. Como Markowitz utiliza estas relaciones para calcular los pesos, pequeñas variaciones en la matriz pueden producir cambios importantes en la distribución de la cartera y hacer que se concentre demasiado capital en unos pocos activos.

Para conseguir una estimación más estable se utiliza el método de *Ledoit-Wolf* [14]. Este método parte de la matriz calculada con los datos históricos y suaviza las relaciones menos fiables entre activos. De esta forma se reduce el ruido y se evita que el optimizador se apoye demasiado en valores extremos. Además, se aplica una corrección con PyPortfolioOpt para que la matriz cumpla las condiciones que necesita el optimizador.

La matriz se vuelve a calcular cada semana utilizando únicamente los retornos conocidos hasta ese momento. Así, la estimación del riesgo se actualiza con la nueva información sin utilizar datos futuros.

5.3 Formulación del problema de optimización

Como se explicó en el capítulo de preliminares, el modelo de Markowitz busca una combinación de activos que equilibre la rentabilidad esperada y el riesgo. En cada semana del *backtest*, es decir, de la simulación histórica de la cartera, se resuelve el siguiente problema de optimización:

$$\max_w (w^T \mu - \lambda w^T \Sigma w)$$

Los términos de esta expresión ya se explicaron anteriormente. En este capítulo, w contiene los pesos asignados a los 58 ETFs, μ recoge los retornos esperados calculados mediante cada una de las tres estrategias y Σ es la matriz de covarianzas estimada con el método *Ledoit-Wolf*.

La optimización debe cumplir varias restricciones. En primer lugar, la suma de los pesos debe ser igual a uno, por lo que todo el capital disponible se invierte en la cartera. Además, los pesos no pueden ser negativos, ya que eso significaría asignar una cantidad negativa de capital a un ETF. Por último, ningún ETF puede superar el peso máximo fijado mediante el parámetro *MAX_WEIGHT*.

Este límite permite controlar la concentración de la cartera. Por ejemplo, si *MAX_WEIGHT* es igual a 0,10, ningún ETF puede representar más del 10 % del capital, por lo que la inversión debe repartirse entre al menos diez activos.

El parámetro λ , representado en el código mediante *RISK_AVERSION*, controla la importancia que se da al riesgo en el optimizador. Un valor bajo hace que el modelo se centre más en los ETFs con mayor retorno esperado, mientras que un valor alto favorece carteras con menor variación.

El problema planteado es un problema de optimización porque existen muchas formas posibles de repartir el capital entre los 58 ETFs y se busca la combinación de pesos que ofrece el mejor equilibrio entre

rentabilidad esperada y riesgo, cumpliendo las restricciones establecidas. Para resolverlo se utiliza PyPortfolioOpt, una librería de Python que construye el problema matemático. A su vez, esta librería utiliza OSQP, un *solver* o programa encargado de realizar los cálculos numéricos necesarios para encontrar la mejor solución posible. OSQP se utiliza como primera opción porque está preparado para resolver este tipo de problemas de forma eficiente [15].

5.4 Funcionamiento del *backtest* semanal

El *backtest* simula cómo habría funcionado la cartera durante el periodo de prueba, comprendido entre 2024-W30 y 2026-W05. En total, se realizan 79 semanas de inversión. La cartera se actualiza una vez por semana. En cada semana se sigue el mismo proceso:

1. **Cálculo de la información disponible.** Se utilizan todos los retornos conocidos hasta esa semana para calcular la matriz de covarianzas. También se calcula el retorno esperado de cada ETF según la estrategia utilizada: media histórica, último retorno observado o predicción ARIMA.
2. **Cálculo de los pesos.** Markowitz utiliza los retornos esperados, la matriz de covarianzas, la aversión al riesgo y el peso máximo permitido para decidir qué porcentaje del capital debe asignarse a cada ETF.
3. **Inversión durante la semana siguiente.** Los pesos calculados se aplican a los retornos reales de la semana posterior. El retorno de la cartera se obtiene sumando el retorno de cada ETF multiplicado por su peso. Como los datos se encuentran en forma de retornos logarítmicos, primero se transforman en retornos simples.
4. **Actualización del capital.** El retorno obtenido se incorpora al capital disponible. El capital final de esa semana pasa a ser el capital inicial de la siguiente, se calculan métricas y el proceso vuelve a repetirse.

La cantidad de información histórica aumenta durante el *backtest*. En la primera decisión se dispone de los datos comprendidos entre 2021-W01 y 2024-W29. Después de cada semana, el nuevo retorno real se añade al historial y se utiliza en los siguientes cálculos. Por tanto, se emplea una ventana expandible.

La matriz de covarianzas se calcula una sola vez en cada semana y se utiliza en las tres estrategias. De esta forma, todas trabajan con la misma estimación del riesgo y las diferencias en los resultados dependen de la forma utilizada para calcular el retorno esperado.

5.5 Métricas de evaluación de estrategias

- **Capital final.** Indica el valor de la cartera al terminar el backtest, partiendo de un capital inicial de 100 euros. Cada semana, el capital se actualiza a partir del retorno obtenido por la cartera.
- **Rentabilidad acumulada.** Muestra el porcentaje total ganado o perdido durante todo el periodo de prueba. Se calcula comparando el capital final con el capital inicial:

$$\text{Rentabilidad acumulada} = \left(\frac{\text{Capital final}}{\text{Capital inicial}} - 1 \right) \times 100$$

- **Volatilidad anualizada.** Mide cuánto varía la cartera a lo largo del tiempo y expresa ese nivel de variación en términos anuales. Para calcular este valor, primero se obtiene el resultado semanal de la cartera teniendo en cuenta el peso asignado a cada ETF. Después, se obtiene la desviación típica de todos esos retornos semanales. Un valor bajo indica que la cartera tiene una evolución estable, mientras que un valor alto indica subidas y bajadas más fuertes. Finalmente, el resultado se multiplica por $\sqrt{52}$ para expresarlo en términos anuales. Aunque se presenta en escala anual, el cálculo utiliza todas las semanas del periodo de prueba.
- **Sharpe anualizado** Mide si la rentabilidad obtenida compensa el riesgo de la cartera. Primero se calcula la media de todos los retornos semanales obtenidos durante el periodo de prueba y se multiplica por 52 para expresarla en términos anuales. Después, este valor se divide entre la volatilidad anualizada de la cartera. En este trabajo se considera una tasa libre de riesgo igual a cero. Un valor más alto indica que la cartera ha obtenido una mayor rentabilidad en relación con las variaciones que ha sufrido.

$$\text{Sharpe} = \frac{\bar{R}_{\text{semanal}} \times 52}{\sigma_{\text{semanal}} \sqrt{52}}$$

donde $\bar{R}_{\text{semanal}}$ es la media de los retornos semanales de la cartera y σ_{semanal} es su desviación típica semanal.

- **Máximo drawdown.** Representa la mayor caída de la cartera desde un valor máximo hasta el mínimo alcanzado después. Por ejemplo, un valor del -15% significa que, en el peor momento, la cartera perdió un 15 % respecto al máximo que había alcanzado. Cuanto más cerca de cero se encuentre, menor habrá sido la peor caída.

5.6 Registro de resultados en Google Sheets

Los resultados del *backtest* se guardan automáticamente en Google Sheets al finalizar la ejecución. Esto permite consultarlos, compararlos y analizarlos sin tener que volver a ejecutar el notebook. La información se organiza en un resumen general y en varias hojas con el detalle semanal.

Tras probar distintos valores de *MAX_WEIGHT* y *RISK_AVERSION*, se seleccionan cuatro configuraciones representativas de diferentes perfiles de cartera. Cada una se evalúa con las tres estrategias de retorno esperado, por lo que el resumen general contiene 12 resultados. Para cada combinación se guardan los parámetros utilizados, el periodo analizado y las métricas finales: capital inicial y final, rentabilidad acumulada, volatilidad anualizada, *Sharpe* anualizado, máximo *drawdown* y número de semanas positivas.

Además, para cada configuración se guarda una hoja con los resultados de cada semana y estrategia. Como el periodo de prueba contiene 79 semanas y se comparan tres estrategias, cada hoja incluye 237 registros. Cada registro contiene la configuración y la estrategia utilizadas, las semanas de decisión e inversión, la evolución del capital, el retorno de la cartera, la rentabilidad acumulada y el *drawdown*. También se guardan los pesos asignados a los 58 ETFs, los retornos estimados utilizados por el optimizador y los retornos reales del histórico. Esta información permite revisar cualquier semana del *backtest* y comprobar qué decisión tomó el optimizador y cuál fue el resultado obtenido.

5.7 Resultados Markowitz

El objetivo del análisis no es elegir únicamente la cartera con mayor rentabilidad, sino encontrar un buen equilibrio entre rentabilidad y riesgo. Por ello, los resultados se valoran principalmente mediante *Sharpe*, aunque también se considera la rentabilidad acumulada, la volatilidad y el máximo *drawdown*. Una cartera puede obtener una rentabilidad elevada, pero no ser la mejor opción si para conseguirla presenta cambios muy fuertes o grandes caídas.

Se estudian cuatro configuraciones representativas, que permiten aumentar de forma progresiva la concentración de la cartera y modificar la importancia del riesgo. Cada una se evalúa con las tres formas de calcular el retorno esperado: media histórica, último valor observado y predicciones ARIMA. En total, se obtiene la tabla x con doce resultados, durante las 79 semanas del periodo de prueba y utilizando los mismos 58 ETF.

Config	Max Weight	Risk Aversion	Estrategia	Rent	Vol	Sharpe	Max Drawdown
Diversificada	10%	0.10	Media histórica	26.23 %	15.47 %	1.0701	-15.88 %
Diversificada	10%	0.10	Último valor	12.22 %	12.80 %	0.6573	-11.71 %
Diversificada	10%	0.10	ARIMA	22.96 %	12.85 %	1.1236	-12.11 %
Intermedia	20%	0.40	Media histórica	26.26 %	17.55 %	0.9639	-15.78 %
Intermedia	20%	0.40	Último valor	17.63 %	15.92 %	0.7509	-13.81 %
Intermedia	20%	0.40	ARIMA	18.78 %	13.65 %	0.8989	-15.07 %
Agresiva	30%	0.10	Media histórica	25.54 %	20.79 %	0.8253	-17.39 %
Agresiva	30%	0.10	Último valor	19.47 %	20.64 %	0.6697	-21.82 %
Agresiva	30%	0.10	ARIMA	21.19 %	15.46 %	0.8960	-16.44 %
Muy concentrada	50%	0.10	Media histórica	18.30 %	27.20 %	0.5421	-17.37 %
Muy concentrada	50%	0.10	Último valor	17.35 %	25.74 %	0.5365	-24.87 %
Muy concentrada	50%	0.10	ARIMA	11.40 %	18.94 %	0.4703	-18.92 %

[Evolución de las métricas utilizando las tres estrategias y las cuatro configuraciones]

Los resultados muestran que el peso máximo permitido por ETF influye de forma clara en el comportamiento de las carteras. Cuando este valor es bajo, el capital debe repartirse entre un mayor número de activos, lo que mantiene la diversificación y evita que el resultado dependa demasiado de un único ETF. En cambio, al aumentar el peso máximo, el optimizador puede concentrar una parte mayor del capital en pocos activos. Si la estimación del retorno esperado no se cumple, el efecto negativo sobre la cartera también es mayor.

Este patrón se observa especialmente en ARIMA. Como sus predicciones suelen ser pequeñas y parecidas entre los ETFs, funcionan mejor para realizar pequeños ajustes en una cartera diversificada que para hacer una inversión elevada en un solo activo. En la configuración diversificada, con un peso máximo del 10 % y una aversión al riesgo de 0,10, ARIMA obtiene el mayor valor *Sharpe* de todas las configuraciones, con un valor de 1,124. Aunque la media histórica alcanza la mayor rentabilidad, ARIMA presenta una volatilidad

y una caída máxima (*Max Drawdown*) menores, por lo que ofrece una mejor relación entre rentabilidad y riesgo.

En la configuración intermedia, con un peso máximo del 20 % y una aversión al riesgo de 0,40, la media histórica obtiene el mayor *Sharpe* y la mayor rentabilidad. sus estimaciones de retorno son suficientemente grandes para orientar los pesos y el tener un valor más alto de aversión al riesgo evita una concentración excesiva. ARIMA mantiene una volatilidad menor, pero también consigue una rentabilidad más baja, por lo que no llega a superar a la media histórica.

En la configuración agresiva, con un peso máximo del 30 % y una aversión al riesgo de 0,10, ARIMA vuelve a obtener el mayor *Sharpe*. La media histórica consigue una rentabilidad más alta, pero también presenta una volatilidad mucho mayor. En este caso, la menor variación de la cartera ARIMA compensa su menor rentabilidad y permite obtener una mejor relación entre ambos valores.

Los peores resultados aparecen en la configuración muy concentrada, que permite asignar hasta el 50 % del capital a un solo ETF. En este caso se pierde gran parte de la diversificación y las tres estrategias empeoran. ARIMA es la más perjudicada, si el ETF seleccionado no se comporta como se esperaba, la pérdida afecta a una parte demasiado grande de la cartera. En esta configuración, la estrategia del último valor supera a ARIMA en rentabilidad y *Sharpe*. El retorno de la semana anterior suele tener una magnitud mayor en estimación de retornos comparado con las otras dos estrategias y puede llevar al optimizador a realizar apuestas más claras y concentradas. Si la tendencia de cada ETF continúa, la cartera puede obtener una ganancia elevada. Sin embargo, esta estrategia también presenta una volatilidad alta y el peor *drawdown*, lo que muestra que depender únicamente del último movimiento produce resultados poco estables.

En general, la media histórica obtiene la mayor rentabilidad acumulada en las cuatro configuraciones. Como se calcula con todos los datos anteriores, sus estimaciones cambian poco entre semanas y suelen favorecer a los activos con mejor comportamiento pasado. Cuando aumenta el peso máximo permitido, el optimizador puede concentrar más capital en esos activos, lo que reduce la diversificación y aumenta la volatilidad de la cartera.

La estrategia basada en el último valor es la más sensible a los movimientos puntuales. Después de una fuerte subida puede aumentar el peso de un ETF justo antes de una corrección y, después de una caída, puede reducirlo antes de una recuperación. Esto explica que presente los valores de *Sharpe* más bajos en todas las configuraciones.

ARIMA obtiene una rentabilidad superior al último valor en las configuraciones diversificada, intermedia y agresiva. Además, presenta una volatilidad menor que la media histórica en todos los casos y menor que la del último valor en tres de las cuatro configuraciones. Su principal ventaja no es conseguir siempre la mayor rentabilidad, sino construir carteras más estables y con una mejor relación entre rentabilidad y riesgo.

Para comprobar si este comportamiento se mantiene con otros valores de los parámetros, se realiza un análisis de sensibilidad con las tres estrategias. Para ello, se prueban distintos niveles de aversión al riesgo y diferentes pesos máximos por activo. Al aumentar la aversión al riesgo, Markowitz da más importancia a reducir la variación de la cartera y menos al retorno esperado. En ARIMA, esto reduce ligeramente la volatilidad, pero también disminuye la rentabilidad, ya que sus predicciones pequeñas influyen menos en el reparto de los pesos. Como la pérdida de rentabilidad es mayor que la reducción de la volatilidad, *Sharpe* también empeora. El efecto del peso máximo es más claro: con límites bajos las carteras están más diversificadas, mientras que una mayor concentración aumenta la volatilidad y las caídas. En conjunto, el peso máximo influye más que la aversión al riesgo.

Entre las doce combinaciones analizadas en la tabla x, ARIMA con la configuración diversificada obtiene el mayor valor de *Sharpe*. Aunque no alcanza la rentabilidad más alta, mantiene un resultado elevado con una de las volatilidades más bajas y una de las menores caídas máximas. Por ello, es la alternativa que ofrece el mejor equilibrio entre rentabilidad y riesgo durante el periodo estudiado.

Capítulo 6 - Conclusiones y trabajo futuro

Chapter - Introduction

“¡Error! No se encuentra el origen de la referencia.” Section must be translated to English if these Ms Thesis is written in Spanish.

Chapter - Conclusions and future work

“Conclusiones y trabajo futuro” section must be translated to English if these Ms Thesis is written in Spanish.

BIBLIOGRAFÍA

- [1] H. Markowitz, "Portfolio Selection," *J. Finance*, vol. 7, no. 1, p. 77, Mar. 1952, doi: 10.2307/2975974.
- [2] E. F. Fama, "Efficient Capital Markets: A Review of Theory and Empirical Work," *J. Finance*, vol. 25, no. 2, p. 383, May 1970, doi: 10.2307/2325486.
- [3] N. JEGADEESH and S. TITMAN, "Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency," *J. Finance*, vol. 48, no. 1, pp. 65–91, Mar. 1993, doi: 10.1111/j.1540-6261.1993.tb04702.x.
- [4] W. F. M. De BONDT and R. THALER, "Does the Stock Market Overreact?," *J. Finance*, vol. 40, no. 3, pp. 793–805, Jul. 1985, doi: 10.1111/j.1540-6261.1985.tb05004.x.
- [5] R. Cont, "Empirical properties of asset returns: stylized facts and statistical issues," *Quant. Finance*, vol. 1, no. 2, pp. 223–236, Feb. 2001, doi: 10.1080/713665670.
- [6] G. L. . Gastineau, *The exchange-traded funds manual*. Wiley, 2010.
- [7] Investment Company Institute, "2025 Investment Company Fact Book," May 2026.
- [8] G. E. P. . Box, G. M. . Jenkins, and G. C. . Reinsel, *Time series analysis : forecasting and control*. Prentice Hall, 1994.
- [9] J. Y. . Campbell, A. W. . Lo, and A. Craig. MacKinlay, *The econometrics of financial markets*. Princeton University Press, 1997.
- [10] S. Gu, B. Kelly, and D. Xiu, "Empirical Asset Pricing via Machine Learning," *Rev. Financ. Stud.*, vol. 33, no. 5, pp. 2223–2273, May 2020, doi: 10.1093/rfs/hhaa009.
- [11] A. E. Hoerl and R. W. Kennard, "Ridge Regression: Biased Estimation for Nonorthogonal Problems," *Technometrics*, vol. 12, no. 1, pp. 55–67, Feb. 1970, doi: 10.1080/00401706.1970.10488634.
- [12] L. Breiman, "Random Forests," *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, Oct. 2001, doi: 10.1023/A:1010933404324.
- [13] J. H. Friedman, "Greedy function approximation: A gradient boosting machine.," *The Annals of Statistics*, vol. 29, no. 5, Oct. 2001, doi: 10.1214/aos/1013203451.

- [14] O. Ledoit and M. Wolf, "A well-conditioned estimator for large-dimensional covariance matrices," *J. Multivar. Anal.*, vol. 88, no. 2, pp. 365–411, Feb. 2004, doi: 10.1016/S0047-259X(03)00096-4.
- [15] B. Stellato, G. Banjac, P. Goulart, A. Bemporad, and S. Boyd, "OSQP: an operator splitting solver for quadratic programs," *Math. Program. Comput.*, vol. 12, no. 4, pp. 637–672, Dec. 2020, doi: 10.1007/s12532-020-00179-2.

APÉNDICES

Apéndice A - Título del primer apéndice

Los apéndices son secciones al final del documento en los que se agrega texto con el objetivo de ampliar los contenidos del documento principal.

Para el título del apéndice se utiliza el estilo Título 6. Los títulos de los apéndices no aparecen en el Índice de contenidos. Las secciones de los apéndices usan el estilo Título 7, como se ve a continuación.

Sección del apéndice (Título 7)

Para los títulos de las secciones de los apéndices se utiliza el estilo Título 7. Para las subsecciones se usa el estilo Título 8, como aparece a continuación.

Subsección del apéndice (Título 8)

Para los títulos de las subsecciones de los apéndices se utiliza el estilo Título 8. Para las sub-subsecciones se usa el estilo Título 9, como aparece a continuación.

Sub-subsecciones del apéndice (Título 9)

Para las sub-subsecciones de un apéndice se utiliza el estilo Título 9. No se recomienda añadir más niveles de subsección.

Apéndice B - Título del segundo apéndice

Se pueden añadir los apéndices que se consideren oportunos. Si se quieren separar por páginas entonces se recomienda, al igual que con los capítulos, y utilizar los *“Saltos de sección – página impar”*.

